Математическая статистика

Двинских Дарина Михайловна

17 мая 2026 г.

Содержание

Обозначения **4**

1 Введение и основные понятия **5**

1.1 Задачи математической статистики 5

2 Статистики и оценки **10**

2.1 Примеры статистик и оценок 10

2.1.1 Выборочные усреднения и функции от выборочных усреднений 10

2.1.2 Порядковые статистики 11

2.2 Свойства оценок 11

2.2.1 Несмещенность 11

2.2.2 Асимптотическая несмещенность 12

2.2.3 Состоятельность 12

2.2.4 Сильная состоятельность 13

2.2.5 Асимптотическая нормальность 13

2.3 Наследование свойств 14

2.4 Сравнение оценок 16

2.4.1 Равномерный подход 16

3 Линейные и квадратичные статистики от нормальных выборок **17**

3.1 Многомерный нормальный случайный вектор 17

3.2 Свойства выборочных среднего и дисперсии 19

4 Достаточные статистики **23**

4.1 Функция правдоподобия 23

4.2 Достаточные статистики . . . 24
4.3 Минимальные достаточные статистики . . . 27
4.4 Экспоненциальное семейство распределений . . . 28

5 Эффективные оценки **30**
5.1 Оптимальные оценки . . . 30
5.2 Информация Фишера. Условия регулярности . . . 31
5.3 Неравенство Рао-Крамера . . . 34
5.4 Эффективные оценки в регулярных экспоненциальных семействах . . . 36
5.5 Сверхэффективные оценки . . . 38
5.6 Многомерное неравенство Рао-Крамера. . . . 39

6 Методы получения оценок **40**
6.1 Метод моментов . . . 40
6.2 Метод максимального правдоподобия. . . . 42
6.2.1 Обоснование метода через дивергенцию Кульбака-Лейблера . . . 44

7 Оптимальные оценки **47**
7.1 Улучшение оценок . . . 47
7.2 Полная достаточная статистика и оптимальные оценки . . . 49

8 Оценка функции распределения **50**

9 Интервальное оценивание **54**
9.1 Метод центральной статистики . . . 54
9.2 Асимптотические доверительные интервалы . . . 57

10 Байесовский анализ **59**
10.1 Байесовские оценки . . . 60
10.2 Сопряженные распределения . . . 61
10.3 Интервальное оценивание в байесовской статистике . . . 63
10.4 Минимаксные оценки . . . 63
10.5 Три подхода в сравнении оценок . . . 66

11 Проверка статистических гипотез **67**
11.1 Ошибки первого и второго рода, уровень значимости. . . . 68

11.2 Параметрические гипотезы. 68

12 Критерий Неймана-Пирсона **71**

12.1 Простые гипотезы 71

12.2 Сложные гипотезы 73

12.3 Критерии согласия Колмогорова 75

12.4 Критерий Колмогорова. 75

13 Критерий хи-квадрат Пирсона **77**

13.1 Критерий согласия хи-квадрат Пирсона. Простая гипотеза 77

13.2 Критерий согласия хи-квадрат Пирсона. Сложная гипотеза 79

13.2.1 p-value 80

14 Гипотеза однородности **81**

14.1 Критерий хи-квадрат Пирсона. 81

14.2 Параметрический случай 83

15 Линейная регрессия **85**

15.1 Линейная регрессия 85

15.2 Метод наименьших квадратов 86

15.3 Статистические свойства и геометрическая интерпретация 87

15.4 Оптимальная оценка. Теорема Гаусса-Маркова 88

15.5 Проверка гипотез в модели линейной регрессии 89

15.6 Интервальное оценивание в модели наименьших квадратов 94

Обозначения

Распределения

$\mathrm{Bin}(n, p)$	Биномиальное распределение с n экспериментами и вероятностью успеха p
$\mathrm{Pois}(\theta)$	Распределение Пуассона с параметром $\theta > 0$
$\mathcal{N}(\mu, \sigma^2)$	Одномерное нормальное распределение со средним μ и дисперсией σ^2
$\mathrm{Exp}(\lambda)$	Экспоненциальное (показательное) распределение с параметром λ
$\mathcal{U}(a, b)$	Равномерное распределение на интервале $(a; b)$
$\chi^2(n)$	Распределение хи-квадрат с n степенями свободы
$\Gamma(k, \theta)$	Гамма-распределение с параметрами (k, θ)
$t(n)$	Распределение Стьюдента (t-распределение) с n степенями свободы
$F(m, n)$	Распределение Фишера (F-распределение)
$\mathcal{N}(\mu, \Sigma)$	Многомерное нормальное распределение со средним μ и ковариационной матрицей Σ

Вероятность

$\mathbb{P}(A)$	Вероятность события A
$\mathbb{E}[X]$	Математическое ожидание с.в. X
$\mathrm{Var}[X]$	Дисперсия с.в. X
$\mathrm{cov}(X, Y)$	Ковариация с.в. X и Y
$\overset{\text{i.i.d}}{\sim}$	независимые и одинаково распредленные (independent and identically distributed)
$\xrightarrow{a.s.}$	Сходимость почти наверное (almost surely)
$\xrightarrow{\mathbb{P}}$	Сходимость по вероятности (in probability)
$\xrightarrow{d}$	Сходимость по распределению (in distribution)

1 Введение и основные понятия

"Статистика – это математическая теория того, как узнать нечто о мире через опыт."

В. Томпсон, английский статистик.

1.1 Задачи математической статистики

Для того чтобы понять, какими задачами занимается математическая статистика, вспомним теорию вероятностей. Теория вероятностей позволяет при заданной вероятностной модели вычислять вероятности тех или иных событий. Математическая статистика фокусируется на обратных задачах – по результатам проводимых наблюдений выявляет структуру статистических моделей. Рассмотрим некотрые примеры задач.

Пример 1. Пусть имеется урна, содержащая белые и черные шары. Оценить долю белых шаров в урне.

В теории вероятностей ставилась обратная задача: зная количество белых и черных шаров в урне, определить вероятность некоторого события, например вероятность того, что среди трех вынутых шаров будет ровно два белых.

В любой статистической задаче мы будем имеет дело с некоторым набором данных, полученных в результате некоторого эксперимента.

Определение 1 (Выборка)**.** Набор $\mathbf{X} = (X_1, \ldots, X_n)$ независимых и одинаково распределенных случайных величин с распределением $\mathbb{P}_X$ называется *выборкой* размера n.

Определение 2 (Выборочное пространство)**.** Множество всех возможных значений $\mathbf{X}$ называется *выборочным пространством* и обозначается $\mathcal{X}$.

Мы будем считать, что $\mathbf{X}$ получен как результат случайного выбора из $\mathcal{X}$ с неизвестным распределением $\mathbb{P}_X$. Задача математической статистики заключается в том, чтобы восстановить те или иные свойства неизвестного распределения $\mathbb{P}_X$ на основе выборки $\mathbf{X}$ из данного распределения.

Замечание 1. Хотя нам изначально неизвестно $\mathbb{P}_X$, зачастую нам известен класс распределений $\mathcal{P}$, которому принадлежит $\mathbb{P}_X$. Если каждая вероятностная мера $\mathbb{P}_X$ из семейства допустимых мер $\mathcal{P}$ может быть параметризовано конечным числом параметров, то есть

$$\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta \subset \mathbb{R}^d\}$$

при $\mathbb{P}_{\theta_1} \neq \mathbb{P}_{\theta_2}$, если $\theta_1 \neq \theta_2$, то такая модель называется *параметрической*. Напротив, если такая параметризация невозможна то речь идет о *непараметрической* модели. Преимущество параметрического класса моделей в том, что вместо задачи восстановления распределения $\mathbb{P}_X$ достаточно решить более простую задачу оценивания параметра $\theta \in \Theta$.

Пример 2. Примеры параметрических моделей:

1. Биномиальное распределение $\mathrm{Bin}(n, \theta)$, $\theta \in (0; 1)$;

2. Нормальное распределение $\mathcal{N}(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$;

3. Равномерное распределение $\mathcal{U}(\theta_1, \theta_2)$, $\theta_1 < \theta_2$, $\theta = (\theta_1, \theta_2)$.

Иногда в задачах не столько важно само неизвестное распределение $\mathbb{P}_X$, сколько его свойства.

Пример 3. Требуется проверить, что закон распределения оставался неизменным в течение всего эксперимента. Формально, пусть имеются две выборки $\mathbf{X} = (X_1, \ldots, X_n)$ и $\mathbf{Y} = (Y_1, \ldots, Y_m)$, описывающие один и тот же процесс, но полученные в разное время. Требуется проверить, являются ли эти выборки однородными, то есть полученными из одного и того же распределения.

Пример 4. Для анализа влияния витамина С на профилактику простуды были взяты две равные группы. Одной группе давали витамин С, второй – плацебо. Проверить гипотезу о независимости заболеваемости от приема витамина С.

Итого задачи математической статистики можно описать следующими двумя разделами

1. задачи оценивания неизвестных параметров распределений случайных величин;

2. проверка статистических гипотез о свойствах этих величин.

А теперь перейдем к примеру из параметрической статистики, на котором вкратце проиллюстрируем, чем мы будем заниматься на курсе.

Пример 5 (Задача предсказания итогов выборов)**.** Пусть есть два кандидата: A и B. Пусть

- θ – доля людей, которые будут голосовать за кандидата A на выборах
$$\theta = \frac{\text{доля людей за A}}{N}$$
- $1 - \theta$ – доля людей, которые будут голосовать за кандидата B
$$\theta = \frac{\text{доля людей за B}}{N}$$

Как оценить θ? Для этого можно провести опросить n человек: $X_1, X_2, \ldots, X_n$ ($n \ll N$, где N - численность населения). Будем считать, что

$$X_i = \begin{cases} 1, & i\text{-ый человек голосует за } A \\ 0, & \text{иначе.} \end{cases}$$

Тогда $X_1, X_2, \ldots, X_n$ – случайные величины, распределенные по закону Бернулли

$$X_i \overset{\text{i.i.d}}{\sim} \mathcal{B}\text{er}(\theta).$$

Интуиция подсказывает, что можно воспользоваться следующей оценкой для неизвестного параметра θ

$$\widehat{\theta} = \frac{\text{доля людей за A из опроса}}{n} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Такую оценку в дальнейшем будем называть *выборочным средним*. Поскольку $X_1, X_2, \ldots, X_n$ – случайные величины, то и $\widehat{\theta}$ – случайная величина. Посчитаем ее моменты

- Математическое ожидание
$$\mathbb{E}\widehat{\theta} = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}X_i = \theta$$
- Дисперсия. Поскольку опрос проводился без возвращения, то величины $X_1, X_2, \ldots, X_n$ будут зависимы, однако поскольку $n \ll N$, то можно считать, что распределение $\mathcal{B}\text{er}(\theta)$ не менялось после каждого опрошенного человека, и $X_1, X_2, \ldots, X_n$ можно считать независимыми, тогда
$$\text{Var}(\widehat{\theta}) = \frac{1}{n^2}\sum_{i=1}^{n}\text{Var}(X_i) = \frac{\theta(1-\theta)}{n}.$$

Итого делаем вывод:

- в среднем оценка $\widehat{\theta}$ совпадает с истинным значением параметра θ. Такие оценки в дальнейшем будем называть *несмещенными*;
- чем больше n, тем меньше разброс оценки $\widehat{\theta}$ относительно истинного значения параметра θ.

Однако мы не ответили на главный вопрос: кто победит на выборах? Пусть мы опросили $n = 1000$ человек, из которых 540 проголосовали за кандидата A, и тогда $\widehat{\theta} = 0.54$, значит ли это, что $\theta = 0.54$? Разумеется нет! Для опроса мы выбрали случайных людей, значит и результат будет случайным, то есть $\widehat{\theta}$ – это случайная величина. И для того, чтобы построить прогноз того, кто же победит на выборах, нужно с некоторой степенью уверенности утверждать, что $\widehat{\theta} > 0.5$ или же $\widehat{\theta} < 0.5$. В статистике это называется построением *доверительных интервалов*. Пока что мы еще не знаем ни один метод построения доверительных интервалов, поэтому воспользуемся только знаниями из курса теории вероятностей, а именно правилом 2σ.

Утверждение 1 (Правило 2σ)**.** Пусть случайная величина $\xi \sim \mathcal{N}(\mu, \sigma^2)$ имеет нормальное распределение с конечными математическим ожиданием μ и дисперсией σ^2, тогда
$$\mathbb{P}(\mu - 2\sigma \leqslant \xi \leqslant \mu + 2\sigma) \approx 0.95.$$

Хотя наши данные $\mathbf{X}$ не из нормального распределения, мы можем воспользоваться центральной предельной теоремой (ЦПТ) и аппроксимировать их нормальным распределением.

Теорема 1. *(Центральная предельная теорема) Пусть $X_1, X_2, \ldots, X_n$ – выборка из распределения с конечными математическим ожиданием μ и дисперсией σ^2. Тогда при $n \to \infty$*
$$\frac{\sqrt{n}(\overline{X} - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1),$$
где $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ – выборочное среднее.

В нашем случае для оценки $\widehat{\theta}$ моменты равны

- $\mathbb{E}\widehat{\theta} = \theta$
- $\sigma^2 = \frac{\theta(1-\theta)}{n}$

Тогда в нашем случае

$$\mathbb{P}(\theta - 2\sigma \leqslant \widehat{\theta} \leqslant \theta + 2\sigma) \approx 0.95.$$

Нам нужно оценить в каком интервале лежат значения неизвестного параметра θ, поэтому перегруппируем слагаемые и получим

$$\mathbb{P}(\widehat{\theta} - 2\sigma \leqslant \theta \leqslant \widehat{\theta} + 2\sigma) \approx 0.95.$$

Поскольку истинную дисперсию σ^2 мы не знаем, так как θ неизвестно, оценим ее

$$\widehat{\sigma}^2 = \frac{\widehat{\theta}(1-\widehat{\theta})}{n}.$$

Тогда

$$\mathbb{P}(\widehat{\theta} - 2\widehat{\sigma} \leqslant \theta \leqslant \widehat{\theta} + 2\widehat{\sigma}) \approx 0.95.$$

Подставляя

$$\widehat{\theta} = 0.54$$
$$\widehat{\sigma} = \frac{\widehat{\theta}(1-\widehat{\theta})}{n} = 0.016$$

получим, что $\theta \in (0.508,\ 0.572)$ с вероятностью 95%. То есть с вероятностью 95% можно заключить, что на выборах одержит победу кандидат A.

Замечание 2. При практических применениях статистики никогда не стоит забывать о том, что к статистическим выводам нужно подходить с осторожностью. Обоснованность выводов зависит не только от корректности примененных математических методов, но и от адекватности статистической модели (предположений, лежащих в ее основе) и от качества входных данных. Если входные данные модели недостаточно репрезентативны, то все выводы, сделанные на ее основе, могут оказаться ошибочными. Приведем исторический пример. В 1936 году влиятельный американский еженедельный журнал 'The Literary Digest' провел беспрецедентный по охвату аудитории предвыборный опрос, чтобы предсказать результат выборов президента США. Нужно отметить, что до этого момента журнал проводил такие опросы регулярно перед каждыми выборами, начиная с 1916 года, и неизменно правильно предсказывал победителя. Итак, журнал разослал почти 10 миллионов анкет с вопросом: 'За кого Вы будете голосовать на предстоящих выборах: Франклина Рузвельта (демократа) или Альфреда Лэндона (республиканца)?'. Журнал получил примерно 2.27 миллиона ответов – астрономическое число для любого социологического опроса. По итогам обработки ответов в редакции пришли к выводу, что Альфред Лэндон должен победить Франклина Рузвельта с большим отрывом. В реальности же произошла оглушительная победа Франклина Рузвельта. Республиканец смог победить всего в 2 штатах – небывалая история для американских выборов. Удар по репутации журнала оказался настолько сильным, что меньше, чем через полтора года, в 1938-м, журнал закрылся.

Итак, где же ошиблись представители 'The Literary Digest'? Ведь учтенные ими 2.27 миллиона голосов – это действительно очень много. Здесь сказались сразу 2 критических ошибки. Во-первых, сказался принцип формирования базы данных адресов для рассылки анкет. Журнал разослал анкеты своим подписчикам, а также владельцам телефонов и автомобилей (эти базы данных были доступны). Но в 1936 году в Америке на фоне Великой Депрессии позволить себе телефон, подписку на литературный журнал или автомобиль могли только

состоятельные люди, которые составляли меньшинство избирателей, и были более склонны голосовать за республиканцев. Таким образом, не было соблюдено требование репрезентативности данных для опроса. Данный эффект в англоязычной статистической литературе называется **'sampling bias'**. Наряду с этим, возможно, сказался и еще один эффект. Люди, которым не нравился (действующий на тот момент) президент Рузвельт просто проявили больше желания потратить свое время, чтобы отправить анкету с ответом. Подобное смещение также часто отражается в социологических опросах и также имеет специальное название **'participation bias'** (или **'non-response bias'**).

2 Статистики и оценки

Определение 3 (Вероятностно-статистическая модель)**.** Тройка $(\mathcal{X}, \mathcal{F}, \mathbb{P})$, где $\mathcal{X}$ – выборочное пространство, $\mathcal{F}$ - σ – алгебра на нем, а $\mathbb{P}$ – семейство распределений (вероятностных мер) на $(\mathcal{X}, \mathcal{F})$, называется вероятностно-статистической моделью.

Пусть элементы выборки $(X_1, \ldots, X_n)$ определенные на вероятностном пространстве $(\mathcal{X}, \mathcal{F}, \mathbb{P})$.

Определение 4 (Статистика)**.** *Статистикой* $T = T(\mathbf{X})$ называется любая $\mathcal{F}$-измеримая функция от $\mathbf{X} = (X_1, \ldots, X_n)$.[1]

Измеримость нужна для того, чтобы были определены вероятности при всех t:

$$F_T(t) = \mathbb{P}(T(\mathbf{X}) \leqslant t).$$

То есть если на пространстве $\mathcal{X}$ задана вероятностная мера, то отображение T индуцирует эту меру на другое пространство.

Замечание 3. Подчеркнем, что если модель является параметрической, то отображение T в определении выше не должно зависеть от неизвестного параметра θ.

Определение 5 (Оценка)**.** Если статистика $T(\mathbf{X})$ принимает значения в множестве допустимых значений оцениваемой величины Θ, то ее можно назвать *оценкой* неизвестного параметра $\theta \in \Theta$.

Можно также оценивать функции $\tau(\theta)$ от параметра. В этом случае $T(\mathbf{X})$ должна принимать значения в $\tau(\theta)$.

Замечание 4. Мы будем использовать данные два термина (статистика и оценка) почти как эквивалентные.

2.1 Примеры статистик и оценок

Пусть дана выборка $X_1, ..., X_n$ из известного семейства распределений

$$\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta \subset \mathbb{R}^d\},$$

где значение параметра θ неизвестно.

2.1.1 Выборочные усреднения и функции от выборочных усреднений

1. $\overline{X} = \frac{1}{n}\sum\limits_{i=1}^{n} X_i$ – выборочное среднее;

2. $\overline{X^k} = \frac{1}{n}\sum\limits_{i=1}^{n} X_i^k$ – выборочный момент порядка $k \in \mathbb{N}$;

3. $S^2 = \overline{X^2} - (\overline{X})^2 = \frac{1}{n}\sum\limits_{i=1}^{n}(X_i - \overline{X})^2$ – выборочная дисперсия.

[1] Напомним, что отображение $T : \mathcal{X} \to E$ является измеримым, если для любого множества $B \in E$ выполнено

$$T^{-1}(B) = \{x : T(x) \in B\} \in \mathcal{F}.$$

2.1.2 Порядковые статистики

Упорядочим выборку $(X_1, \ldots, X_n)$ по возрастанию и введем обозначения:

$$\begin{aligned} X_{(1)} &= \min\{X_1, \ldots, X_n\}, \\ X_{(2)} &= \min\{(X_1, \ldots, X_n) \setminus X_{(1)}\}, \\ &\vdots \\ X_{(n)} &= \max\{X_1, \ldots, X_n\}. \end{aligned}$$

Определение 6 (вариационный ряд)**.** Упорядоченный набор $X_{(1)} \leqslant X_{(2)} \leqslant \ldots \leqslant X_{(n)}$ называется *вариационным рядом*, построенным по выборке $\mathbf{X}$.

Определение 7 ($k-$я порядковая статистика)**.** Элемент $X_{(k)}$ будем называть k-й порядковой статистикой. Элементы $X_{(1)}$ и $X_{(n)}$ называются минимальной и максимальной порядковыми статистиками соответственно.

2.2 Свойства оценок

Теперь поймем, какие мы хотели бы видеть свойства у оценок, чтобы можно было рассматривать их в качестве хороших.

2.2.1 Несмещенность

Определение 8 (Смещение)**.** *Смещением* оценки $\widehat{\theta}_n(\boldsymbol{X})$ называется величина

$$b_n(\theta) = \mathbb{E}_\theta \widehat{\theta}_n(\boldsymbol{X}) - \theta.$$

Запись $\mathbb{E}_\theta$ означает, что математическое ожидание берется по выборке $\mathbf{X}$ из неизвестного истинного распределения $\mathbb{P}_\theta$, индекс θ показывает, что $\mathbb{E}_\theta$ – это некая функция, зависящая от неизвестного параметра θ. Например, если вероятностная мера $\mathbb{P}_\theta$ абсолютно непрерывна и имеет плотность $p_\theta(x)$, то плотность вектора $\boldsymbol{X}$

$$p_{\boldsymbol{X}}(\boldsymbol{x}, \theta) = p_\theta(x_1) \cdot \cdots \cdot p_\theta(x_n), \qquad \boldsymbol{x} = (x_1, \ldots, x_n),$$

а математическое ожидание

$$\mathbb{E}_\theta \widehat{\theta}(\mathbf{X}) = \int_{\mathcal{X}} \widehat{\theta}(\boldsymbol{x}) p_{\boldsymbol{X}}(\boldsymbol{x}, \theta) d\boldsymbol{x}.$$

Определение 9 (Несмещенность)**.** Оценка $\widehat{\theta}_n(\boldsymbol{X})$ (или последовательность оценок) параметра θ называется *несмещенной*, если для всех $\theta \in \Theta$ выполняется

$$b_n(\theta) = 0.$$

Пример 6. Пусть $X_1, \ldots, X_n$ – выборка из распределения Бернулли $\mathrm{Bin}(1, \theta)$. Тогда X_1 и $\overline{X}$ – несмещенные оценки θ.

2.2.2 Асимптотическая несмещенность

Определение 10 (Асимптотическая несмещенность)**.** Оценка $\widehat{\theta}_n(\boldsymbol{X})$ (или последовательность оценок) параметра θ называется *асимптотически несмещенной*, если для всех $\theta \in \Theta$

$$b_n(\theta) \xrightarrow{n\to\infty} 0.$$

2.2.3 Состоятельность

Определение 11 (Состоятельность)**.** Оценка $\widehat{\theta}_n(\boldsymbol{X})$ (или последовательность оценок) называется *состоятельной* оценкой параметра θ, если для любого $\theta \in \Theta$ имеет место сходимость по вероятности

$$\widehat{\theta}_n(\boldsymbol{X}) \xrightarrow{\mathbb{P}_\theta} \theta, \text{ при } n \to \infty,$$

то есть для любого $\theta \in \Theta$ и любого $\varepsilon > 0$

$$\mathbb{P}_\theta\Big(\|\widehat{\theta}_n(\boldsymbol{X}) - \theta\|_2 \geqslant \varepsilon\Big) \xrightarrow{n\to\infty} 0.$$

Пример 7. Пусть $X_1, \ldots, X_n$ – выборка из распределения Бернулли $\mathrm{Bin}(1, \theta)$. Тогда по ЗБЧ $\overline{X}$ – состоятельная оценка.

Напомним ЗБЧ

Теорема 2. *(Закон больших чисел) Пусть $X_1, X_2, \ldots, X_n$ – выборка из распределения с конечными математическим ожиданием μ. Обозначим $\overline{X} = \frac{1}{n}\sum_{i=1}^n X_i$ – выборочное среднее. Тогда при $n \to \infty$*

$$\overline{X} \xrightarrow{\mathbb{P}} \mu.$$

Ограничимся одномерным вариантом. Пусть $\Theta \in \mathbb{R}$. Следующая лемма, бывает очень полезной для доказательства состоятельности.

Лемма 1 (Достаточное условие состоятельности)**.** *Если смещение $b_n(\theta) \xrightarrow{n\to\infty} 0$ и $\mathrm{Var}_\theta(\widehat{\theta}_n(\mathbf{X})) \xrightarrow{n\to\infty} 0$, то оценка $\widehat{\theta}_n(\mathbf{X})$ состоятельна.*

Для доказательство данной леммы понадобится следующее утверждение

Утверждение 2. Пусть дана выборка $\mathbf{X} = (X_1, \ldots, X_n)$ из распределения $\mathbb{P}_\theta, \theta \in \Theta \in \mathbb{R}^d$ и $\widehat{\theta}$ – произвольная оценка параметра θ. Тогда

$$\mathbb{E}_\theta\Big[(\widehat{\theta}_n(\mathbf{X}) - \theta)^2\Big] = b_n(\theta)^2 + \mathrm{Var}_\theta(\widehat{\theta}_n(\mathbf{X})).$$

Доказательство. Добавим и вычтем $\mathbb{E}_\theta\widehat{\theta}(\mathbf{X})$ из среднеквадратичной ошибки, а далее раскроем квадрат нормы

$$\begin{aligned}
\mathbb{E}_\theta\Big[(\widehat{\theta}(\mathbf{X}) - \theta)^2\Big] &= \mathbb{E}_\theta\Big[(\widehat{\theta}(\mathbf{X}) - \mathbb{E}_\theta\widehat{\theta}(\mathbf{X}) + \mathbb{E}_\theta\widehat{\theta}(\mathbf{X}) - \theta)^2\Big] \\
&= \mathbb{E}_\theta\Big[(\widehat{\theta}(\mathbf{X}) - \mathbb{E}_\theta\widehat{\theta}(\mathbf{X}))^2\Big] + 2\mathbb{E}_\theta\Big[(\widehat{\theta} - \mathbb{E}_\theta\widehat{\theta}(\mathbf{X}))(\mathbb{E}_\theta\widehat{\theta}(\mathbf{X}) - \theta)\Big] + \mathbb{E}_\theta\Big[(\mathbb{E}_\theta\widehat{\theta}(\mathbf{X}) - \theta)^2\Big] \\
&= \mathbb{E}_\theta\Big[(\widehat{\theta}(\mathbf{X}) - \mathbb{E}_\theta\widehat{\theta}(\mathbf{X}))^2\Big] + \Big(\mathbb{E}_\theta\widehat{\theta}(\mathbf{X}) - \theta\Big)^2 \\
&= \mathrm{Var}_\theta(\widehat{\theta}(\mathbf{X})) + b_n(\theta)^2.
\end{aligned}$$

□

Доказательство леммы 1. Воспользуемся неравенством Маркова для фиксированного $\varepsilon > 0$

$$\mathbb{P}(|\widehat{\theta}_n(\mathbf{X}) - \theta| > \varepsilon) \leqslant \frac{\mathbb{E}_\theta\Big[(\widehat{\theta}_n(\mathbf{X}) - \theta)^2\Big]}{\varepsilon^2} = \frac{b(\theta)^2 + \mathrm{Var}_\theta(\widehat{\theta}_n(\mathbf{X}))}{\varepsilon^2} \xrightarrow{n\to\infty} 0.$$

□

2.2.4 Сильная состоятельность

Определение 12 (Сильная состоятельность)**.** Оценка $\widehat{\theta}_n(\boldsymbol{X})$ (или последовательность оценок) называется *сильно состоятельной* оценкой параметра θ, если для любого $\theta \in \Theta$ имеет место сходимость почти наверное (с вероятностью 1)

$$\widehat{\theta}_n(\boldsymbol{X}) \xrightarrow{a.s.} \theta, \quad \text{при } n \to \infty\,,$$

то есть для любого $\theta \in \Theta$

$$\mathbb{P}_\theta\Big(\lim_{n\to\infty} \widehat{\theta}_n(\boldsymbol{X}) = \theta\Big) = 1\,.$$

Пример 8. Пусть $X_1, \ldots, X_n$ – выборка из распределения Бернулли $\mathrm{Bin}(1, \theta)$. Тогда по УЗБЧ $\overline{X}$ – сильно состоятельная оценка.

Напомним УЗБЧ

Теорема 3. *(Усиленный закон больших чисел) Пусть $X_1, X_2, \ldots, X_n$ – выборка из распределения с конечными математическим ожиданием μ. Обозначим $\overline{X} = \frac{1}{n}\sum_{i=1}^n X_i$ – выборочное среднее. Тогда при $n \to \infty$*

$$\overline{X} \xrightarrow{a.s.} \mu.$$

2.2.5 Асимптотическая нормальность

Ограничимся одномерным вариантом. Пусть $\Theta \in \mathbb{R}$.

Определение 13 (Асимптотическая нормальность)**.** Оценка $\widehat{\theta}_n(\boldsymbol{X})$ (или последовательность оценок) называется *асимптотически нормальной* оценкой параметра θ если для любого $\theta \in \Theta$ имеет место сходимость по распределению

$$\sqrt{n}\Big(\widehat{\theta}_n(\mathbf{X}) - \theta\Big) \xrightarrow{d_\theta} \mathcal{N}(0, \sigma^2(\theta)),\ n \to \infty, \tag{1}$$

где $\sigma^2(\theta)$ называется *асимптотической дисперсией* оценки $\widehat{\theta}_n(\mathbf{X})$.

Обозначим за $F_n(t)$ функцию распределения $\sqrt{n}\Big(\widehat{\theta}_n(\mathbf{X}) - \theta\Big)$ при любом $n \in \mathbb{N}$. Тогда (1) означает, что для любого $t \in \mathbb{R}$

$$\lim_{n\to\infty} F_n(t) = \Phi(t),$$

где $\Phi(t)$ – функция распределения нормальной величины.

Пример 9. Пусть $X_1, \ldots, X_n$ – выборка из распределения Бернулли $\mathrm{Bin}(1, \theta)$. Тогда по ЦПТ $\overline{X}$ – асимптотически нормальная оценка.

Следствие 1 (Дельта-метод)**.** *Пусть* $\widehat{\theta}_n = \widehat{\theta}_n(\mathbf{X})$ *– асимптотически нормальная оценка* $\theta \in \mathbb{R}$

$$\sqrt{n}\,(\widehat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2), \qquad \sigma^2 > 0,\ n \to \infty.$$

Пусть $g : \mathbb{R} \to \mathbb{R}$ *дифференцируемая функция и такая, что в точке* θ*:* $g'(\theta) \neq 0$*. Тогда* $g(\widehat{\theta}_n)$ *– асимптотически нормальная оценка для* $g(\theta)$

$$\sqrt{n}\left(g(\widehat{\theta}_n) - g(\theta)\right) \xrightarrow{d} \mathcal{N}\big(0,\ (g'(\theta))^2\sigma^2\big),\ n \to \infty.$$

Идея доказательства. Приведем основную идею доказательства (для полного доказательства нужен анализ остаточного члена ряда Тейлора). Так как g дифференцируема в точке θ, раскладывая в ряд Тейлора, имеем

$$g(\widehat{\theta}_n) \approx g(\theta) + g'(\theta)(\widehat{\theta}_n - \theta).$$

Тогда перегруппировка слагаемых дает

$$\sqrt{n}\left(g(\widehat{\theta}_n) - g(\theta)\right) = g'(\theta)\sqrt{n}(\widehat{\theta}_n - \theta). \tag{2}$$

Далее воспользуемся тем, что $\widehat{\theta}_n$ – асимптотически нормальная оценка $\theta \in \mathbb{R}$, значит

$$g'(\theta)\sqrt{n}(\widehat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}\big(0, (g'(\theta))^2\sigma^2\big).$$

Далее используем это для (2) мы получаем требуемое утверждение. □

Замечание 5. Асимптотические свойства (состоятельность, сильная состоятельность, асимптотическая нормальность) имеют смысл только в случае выборки большого (растущего) размера. Несмещенность – это конечное свойство.

Замечание 6. Оценивать можно не только сам параметр θ, но и функции от него $\tau(\theta)$. Определения свойств при этом сохраняются.

2.3 Наследование свойств

Пусть нам интересен не сам параметр θ, а некоторая функция от него $\tau(\theta)$. И пусть мы знаем как оценить параметр, то есть есть некая оценка $\widehat{\theta}(\mathbf{X})$. Следующая теорема позволяет оценить $\tau(\theta)$, используя известную оценку $\widehat{\theta}(\mathbf{X})$.

Теорема 4. *(О наследовании сходимости) Если* $\xi_n \xrightarrow{a.s./\mathbb{P}/d} \xi$*, а* h *— непрерывная относительно распределения* ξ *функция (т.е. существует множество* B *такое, что* $\mathbb{P}(\xi \in B) = 1$ *и* h *непрерывна на* B*), тогда*

$$h(\xi_n) \xrightarrow{a.s./\mathbb{P}/d} h(\xi).$$

Также бывает полезна Лемма Слуцкого.

Лемма 2. *(Слуцкого) Пусть* $\xi_n \xrightarrow{d} \xi$ *и* $\eta_n \xrightarrow{d} C$*, где* C *— константа. Тогда:*

$$\xi_n + \eta_n \xrightarrow{d} \xi + C$$

$$\xi_n \cdot \eta_n \xrightarrow{d} \xi \cdot C$$

Лемма 3. *Пусть C — константа, тогда $\xi_n \xrightarrow{d} C$ тогда и только тогда, когда $\xi_n \xrightarrow{\mathbb{P}} C$.*

Доказательство. 1. Для люой случайно величины ξ

$$\xi_n \xrightarrow{\mathbb{P}} \xi \quad \Longrightarrow \quad \xi_n \xrightarrow{d} \xi$$

2. В случае константы:

$$\xi_n \xrightarrow{d} C \quad \Longrightarrow \quad \xi_n \xrightarrow{\mathbb{P}} C.$$

□

Теперь мы можем доказать важное свойство.

Лемма 4 (Взаимосвязь свойств оценок)**.**

1. *Из асимптотической нормальности следует состоятельность.*
2. *Из сильной состоятельности следует состоятельность.*

Доказательство. 1. Пусть $\widehat{\theta}_n$ – асимптотически нормальная оценка $\theta \in \mathbb{R}$

$$\sqrt{n}\,(\widehat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2), \qquad \sigma^2 > 0.$$

Разложим последовательность $\{(\widehat{\theta}_n - \theta)\}$ на две последовательности

$$\widehat{\theta}_n - \theta = \frac{1}{\sqrt{n}} \sqrt{n}(\widehat{\theta}_n - \theta),$$

где $\frac{1}{\sqrt{n}} \xrightarrow{d} 0$ и $\sqrt{n}(\widehat{\theta}_n - \theta) \xrightarrow{d} \xi$, где $\xi \sim \mathcal{N}(0, \sigma^2)$ имеет нормальное распределение. Тогда по лемме Слуцкого

$$\widehat{\theta}_n - \theta = \frac{1}{\sqrt{n}} \sqrt{n}(\widehat{\theta}_n - \theta) \xrightarrow{d} 0 \cdot \xi = 0, \qquad n \to \infty.$$

Тогда по лемме 3 имеем

$$\widehat{\theta}_n \xrightarrow{\mathbb{P}} \theta,$$

то есть $\widehat{\theta}_n$ – состоятельная оценка $\theta \in \mathbb{R}$.

2. Доказательство этого пункта следует из того, что сходимость почти наверное влечет сходимость по вероятности.

□

2.4 Сравнение оценок

Предположим, мы смогли привести две оценки, тогда как же понять какая из них лучше? Чтобы сравнивать различные оценки, необходимо ввести метрику качества. Обычно для ее определения вводится борелевская неотрицательная функцию (далее именуемая как *функция потерь*)

$$\rho : \Theta \times \Theta \to \mathbb{R}_+.$$

Если $\widehat{\theta}$ – оценка параметра θ, то $\rho(\theta, \widehat{\theta})$ показывает величину потерь.

Пример 10. Примеры функций потерь.

1. Абсолютная функция потерь: $\rho(x, y) = |x - y|$.
2. Квадратичная функция потерь: $\rho(x, y) = (x - y)^2$.
3. Если $\theta \in \mathbb{R}^d$, $d > 1$, то для неотрицательно определенной матрицы $A \in \mathbb{R}^{d\times d}$ можно определить
$$\rho(x, y) = \langle A(x - y), x - y\rangle.$$

Далее в рамках курса будем считать функцию потерь квадратичной, если не сказано обратное. Поскольку $\widehat{\theta} = \widehat{\theta}(\mathbf{X})$ – это случайная величина, зависящая от выборки, то и функция потерь $\rho(\widehat{\theta}, \theta)$ будет тоже случайной величиной. Для того чтобы мера качества оценки не зависела от конкретной реализации выборки, вводят функцию риска.

Определение 14 (Функция риска)**.** При заданной функции потерь $\rho(x, y)$ функцией риска оценки $\widehat{\theta}_n(\mathbf{X})$ называется

$$R_\theta(\widehat{\theta}) = \mathbb{E}_\theta \rho(\theta, \widehat{\theta}_n(\mathbf{X})).$$

При квадратичной функции потерь функция риска именуется среднеквадратичной ошибкой. В качестве метрики качества будем рассматривать функцию риска. Теперь перейдем к сравнению оценок, базируясь на введенной функции риска.

2.4.1 Равномерный подход

Правило сравнения. Говорят, что оценка $\widehat{\theta}$ лучше оценивает параметр θ, чем оценка $\widetilde{\theta}$, если для всех $\theta \in \Theta$ выполнено

$$R_\theta(\widehat{\theta}) \leqslant R_\theta(\widetilde{\theta}),$$

причем для некоторого $\theta \in \Theta$ неравенство строгое.

Определение 15 (Наилучшая оценка)**.** Оценка $\widehat{\theta}$ называется *наилучшей* в классе $\mathcal{K}$, если она лучше любой другой оценки $\widetilde{\theta} \in \mathcal{K}$.

3 Линейные и квадратичные статистики от нормальных выборок

3.1 Многомерный нормальный случайный вектор

Определение 16 (Многомерное нормальное распределение)**.** Будем говорить, что случайный вектор $\mathbf{X} \in \mathbb{R}^n$ имеет многомерное нормальное распределение, если его характеристическая функция имеет вид

$$\varphi_{\mathbf{X}}(\mathbf{u}) = \mathbb{E}e^{i\langle \mathbf{u}, \mathbf{X}\rangle} = \exp\left\{ i\langle \mathbf{u}, \boldsymbol{\mu}\rangle - \frac{1}{2}\langle \mathbf{u}, \Sigma\mathbf{u}\rangle \right\}.$$

где $\mathbf{u} \in \mathbb{R}^n$, $\boldsymbol{\mu} \in \mathbb{R}^n$, а Σ – симметричная неотрицательно определенная матрица $(n \times n)$.

Нас будет интересовать невырожденное нормальное распределение. В этом случае можно сформулировать альтернативное определение

Определение 17 (Многомерное невырожденное нормальное распределение)**.** *Нормальным (гауссовским) распределением* $\mathcal{N}(\boldsymbol{\mu}, \Sigma)$, называется распределение случайной величины $\mathbf{X}$ с плотностью

$$p_{\mathbf{X}}(\boldsymbol{x}) = \frac{1}{(2\pi)^{n/2}\sqrt{\det(\Sigma)}} e^{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathsf{T}}\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{\mu})}, \quad \boldsymbol{x} \in \mathbb{R}^n.$$

где $\boldsymbol{\mu} \in \mathbb{R}^n$, а Σ – симметричная положительно определенная матрица $(n \times n)$.

Утверждение 3 (Свойства многомерного нормального распределения)**.** 1. Многомерное нормальное распределение устойчиво относительно линейных преобразований. Пусть $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$, а $A \in \mathbb{R}^{m\times n}$ – детерминированная матрица, то

$$A\mathbf{X} \sim \mathcal{N}(A\boldsymbol{\mu}, A\Sigma A^{\mathsf{T}}).$$

2. Если вектор $\mathbf{X} = (X_1, \ldots, X_n)$ имеет многомерное нормальное распределение, то его компоненты $X_i,\ i = 1, \ldots, n$, имеют одномерное нормальное распределение.

3. Если случайные величины $(X_1, \ldots, X_n)$ имеют одномерное нормальное распределение и совместно независимы, то случайный вектор $\mathbf{X} = (X_1, \ldots, X_n)$ имеет многомерное нормальное распределение. Матрица ковариаций Σ такого вектора диагональна.

4. Два гауссовских вектора $\mathbf{X}$ и $\boldsymbol{Y}$ независимы тогда и только тогда, когда их ковариация равна 0.

Доказательство пункта 1. Пусть $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$. Тогда характеристическая функция вектора $\mathbf{X}$:

$$\varphi_{\mathbf{X}}(\mathbf{u}) = \mathbb{E}\left[e^{i\langle \mathbf{u}, X\rangle}\right] = \exp\left(i\langle \mathbf{u}, \boldsymbol{\mu}\rangle - \frac{1}{2}\langle \mathbf{u}, \Sigma\mathbf{u}\rangle \right), \quad \mathbf{u} \in \mathbb{R}^n.$$

Рассмотрим $\boldsymbol{Y} = A\mathbf{X}$. Тогда:

$$\varphi_{\boldsymbol{Y}}(\mathbf{u}) = \mathbb{E}\left[e^{i\langle \mathbf{u}, \boldsymbol{Y}\rangle}\right] = \mathbb{E}\left[e^{i\langle \mathbf{u}, A\mathbf{X}\rangle}\right] = \mathbb{E}\left[e^{i\langle A^{\mathsf{T}}\mathbf{u}, \mathbf{X}\rangle}\right] = \exp\left(i\langle A^{\mathsf{T}}\mathbf{u}, \boldsymbol{\mu}\rangle - \frac{1}{2}\langle A^{\mathsf{T}}\mathbf{u}, \Sigma A^{\mathsf{T}}\mathbf{u}\rangle \right).$$

Это характеристическая функция нормального распределения с параметрами $A\boldsymbol{\mu}$ и $A\Sigma A^\intercal$. Следовательно,

$$\boldsymbol{Y} \sim \mathcal{N}(A\boldsymbol{\mu},\, A\Sigma A^\intercal).$$

□

При рассмотрении квадратичных форм от нормального вектора нам понадобится распределение хи-квадрат.

Определение 18 (Распределение хи-квадрат)**.** *Распределением хи-квадрат* $\chi^2(n)$ с $n > 0$ степенями свободы называется распределение случайной величины

$$Z = X_1^2 + \cdots + X_n^2, \qquad \text{где } X_i \overset{\text{i.i.d}}{\sim} \mathcal{N}(0,1).$$

Замечание 7. Распределение хи-квадрат $\chi^2(n)$ является частным случаем гамма-распределения $\text{Gamma}(\frac{n}{2}, \frac{1}{2})$.

В векторном виде определение 18 можно переписать следующим образом: *распределением хи-квадрат* $\chi^2(n)$ с $n > 0$ степенями свободы называется распределение случайной величины

$$Z = \mathbf{X}^\intercal\mathbf{X} = \mathbf{X}^\intercal I\mathbf{X}, \quad \mathbf{X} \sim \mathcal{N}(\mathbf{0}, I_n).$$

Теперь зададимся вопросом, можно ли вместо единичной матрицы в квадратичной форме использовать другие матрицы, которые бы тоже давали распределение хи-квадрат. Ответом служит следующая лема.

Лемма 5. *Пусть* $\boldsymbol{X} \sim \mathcal{N}(\mathbf{0}, I_n)$*, где* I_n *единичная матрица размера* $n \times n$*, и* A *— симметричная идемпотентная* ($A^2 = A$) *матрица. Тогда*

$$Q = \boldsymbol{X}^T A\boldsymbol{X} \sim \chi^2(\text{tr}(A)),$$

где $\text{tr}(A)$ *– это след матрицы* A*.*

Доказательство. Так как A симметрична, существует ортогональная матрица U, такая что

$$A = U\Lambda U^T,$$

где $\Lambda = \text{diag}(\lambda_1, \ldots, \lambda_n)$.

Из условия идемпотентности:

$$A^2 = A \Rightarrow \Lambda^2 = \Lambda \Rightarrow \lambda_i \in \{0, 1\}.$$

Рассмотрим замену:

$$\boldsymbol{Y} = U^T\boldsymbol{X}.$$

Так как $\boldsymbol{X} \sim \mathcal{N}(\mathbf{0}, I_n)$ и U ортогональна, то

$$\boldsymbol{Y} \sim \mathcal{N}(\mathbf{0}, I_n),$$

и компоненты $Y_i \sim \mathcal{N}(0,1)$ независимы стандартно нормальны.

Тогда:

$$Q = \boldsymbol{X}^T A \boldsymbol{X} = \boldsymbol{X}^T U \Lambda U^T \boldsymbol{X} = \boldsymbol{Y}^T \Lambda \boldsymbol{Y} = \sum_{i=1}^{n} \lambda_i Y_i^2.$$

$$Q \sim \chi^2(\mathrm{tr}(A)).$$

□

3.2 Свойства выборочных среднего и дисперсии

В общем случае статистики $\overline{X}$ и S^2 зависимы, но для выборок из нормального распределения можно доказать их независимость. Более того можно вывести их распределение. Этот результат известен как теорема Фишера.

Теорема 5 (Фишер)**.** *Пусть* $\mathbf{X} = (X_1, \ldots, X_n)$ *– выборка объема* n *из распределения* $\mathcal{N}(\mu, \sigma^2)$*. Пусть*

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \quad \textit{и} \quad S^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

– это выборочное среднее и выборочная дисперсия соответственно. Тогда статистики $\overline{X}$ *и* S^2 *независимы; и*

$$\overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right), \qquad \frac{nS^2}{\sigma^2} = \frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i - \overline{X})^2 \sim \chi^2(n-1).$$

Доказательство. Для начала покажем, что $\overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$. Поскольку $(X_1, \ldots, X_n)$ – выборка из $\mathcal{N}(\mu, \sigma^2)$, то и их линейная комбинация будет нормальной случайной величиной. Подсчет математического ожидания и дисперсии даст μ и $\frac{\sigma^2}{n}$.

Далее покажем независимость $\overline{X}$ и S^2. Рассмотрим вектор $\boldsymbol{X} = (X_1, \ldots, X_n)$. Так как $(X_1, \ldots, X_n)$ – независимы, то вектор $\boldsymbol{X} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 I_n)$ будет нормальным случайным вектором. Здесь $\boldsymbol{\mu} = (\mu, \ldots, \mu)$ – вектор размера n. Затем перейдем к стандартному нормальному случайному вектору

$$\boldsymbol{Y} = \frac{\boldsymbol{X} - \boldsymbol{\mu}}{\sigma} \sim \mathcal{N}(\mathbf{0}, I_n).$$

Введем единичный вектор размера n

$$\mathbb{1} = (1, \ldots, 1)$$

Тогда

$$\overline{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i = \frac{1}{n}\mathbb{1}^{\mathrm{T}}\boldsymbol{Y} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{X_i - \mu}{\sigma}\right) = \frac{\overline{X}}{\sigma} - \frac{\mu}{\sigma}.$$

$$S^2(\boldsymbol{Y}) = \frac{1}{n}\sum_{i=1}^{n}(Y_i - \overline{Y})^2 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{X_i - \mu}{\sigma} - \frac{\overline{X} - \mu}{\sigma}\right) = \frac{1}{n\sigma^2}\sum_{i=1}^{n}(X_i - \overline{X})^2 = \frac{1}{\sigma^2}S^2(\mathbf{X}).$$

Введем матрицы проекций P и Q

$$P = \frac{1}{n}\mathbf{1}\mathbf{1}^T;$$
$$Q = I_n - P.$$

P – это матрица проекции на подпространство, натянутое на вектор $\mathbb{1}$, а Q – это матрица проекции на ортогональное подпространство. Причем

$$P = P^\intercal = \left(\frac{1}{n}\mathbf{1}\mathbf{1}^T\right)^\intercal = \frac{1}{n}\mathbf{1}\mathbf{1}^T;$$
$$P = P^2 = \frac{1}{n^2}\mathbf{1}\mathbf{1}^T\mathbf{1}\mathbf{1}^T = \frac{1}{n}\mathbf{1}n\mathbf{1}^T = \frac{1}{n}\mathbf{1}\mathbf{1}^T;$$
$$Q = Q^\intercal;$$
$$Q = Q^2.$$

То есть

$$\boldsymbol{Y} = P\boldsymbol{Y} + Q\boldsymbol{Y},$$

где

$$P\boldsymbol{Y} = \frac{1}{n}\mathbf{1}\mathbf{1}^T\boldsymbol{Y} = \mathbf{1}\overline{Y};$$
$$Q\boldsymbol{Y} = (I_n - P)\boldsymbol{Y} = \boldsymbol{Y} - \mathbf{1}\overline{Y}$$

Перепишем $S^2(\boldsymbol{Y})$ как функцию от вектора $Q\boldsymbol{Y}$

$$S^2(\boldsymbol{Y}) = \frac{1}{n}\sum_{i=1}^{n}(Y_i - \overline{Y})^2 = \frac{1}{n}\|\boldsymbol{Y} - \overline{Y}\mathbf{1}\|_2^2 = \frac{1}{n}\|Q\boldsymbol{Y}\|_2^2 = \frac{1}{n}\langle Q\boldsymbol{Y}, Q\boldsymbol{Y}\rangle = \frac{1}{n}\boldsymbol{Y}^\intercal Q^\intercal Q\boldsymbol{Y} = \frac{1}{n}\boldsymbol{Y}^\intercal Q\boldsymbol{Y}. \tag{3}$$

Заметим, что $\overline{Y}$ – это функция от вектора $P\boldsymbol{Y}$, а $S^2(\boldsymbol{Y})$ – это функция от вектора $Q\boldsymbol{Y}$. Чтобы показать независимость $\overline{Y}$ и $S^2(\boldsymbol{Y})$, покажем, что векторы $P\boldsymbol{Y}$ и $Q\boldsymbol{Y}$ независимы. Векторы $P\boldsymbol{Y}$ и $Q\boldsymbol{Y}$ – это нормальные случайные векторы как линейные преобразования нормального вектора $\boldsymbol{Y}$. Поэтому их для доказательства их независимости достаточно, чтобы их ковариация была равно 0

$$\operatorname{cov}(P\boldsymbol{Y}, Q\boldsymbol{Y}) = \mathbb{E}\big[(P\boldsymbol{Y} - \mathbb{E}[P\boldsymbol{Y}])(Q\boldsymbol{Y} - \mathbb{E}[Q\boldsymbol{Y}])^\intercal\big] = \mathbb{E}\big[P(\boldsymbol{Y} - \mathbb{E}\boldsymbol{Y})(\boldsymbol{Y} - \mathbb{E}[\boldsymbol{Y}])^\intercal Q^\intercal\big] = P\operatorname{cov}(\boldsymbol{Y})Q^\intercal =$$

Покажем, что $PQ = 0$

$$PQ = \frac{1}{n}\mathbf{1}\mathbf{1}^T(I_n - \frac{1}{n}\mathbf{1}\mathbf{1}^T) = P - P = 0.$$

Тогда $\operatorname{cov}(P\boldsymbol{Y}, Q\boldsymbol{Y}) = 0$, и значит, $P\boldsymbol{Y}$ и $Q\boldsymbol{Y}$ независимы. Значит, и $\overline{Y}$ и $S^2(\boldsymbol{Y})$ независимы, поскольку $\overline{Y}$ – это функция от вектора $P\boldsymbol{Y}$, а $S^2(\boldsymbol{Y})$ – это функция от вектора $Q\boldsymbol{Y}$. Следовательно $\overline{X}$ и S^2 независимы.

Распределение $nS^2(\boldsymbol{Y})$ следует из леммы 5. Применим лемму к разложению (3).

$$\boldsymbol{Y}^T Q\boldsymbol{Y} \sim \chi^2(\operatorname{tr}(M)).$$

Осталось только посчитать след матрицы Q

$$\operatorname{tr}(M) = \operatorname{tr}\left(I_n - \frac{1}{n}\mathbf{1}\mathbf{1}^\intercal\right) = n - 1.$$

□

Альтернативное доказательство теоремы Фишера. Доказать теорему Фишера можно и через характеристические функции.

1. Докажем для начала независимость $\overline{X}$ и S_0^2. Доказательство данной теоремы разбиралось на семинарах, однако приведем его здесь тоже для справки. По условию $(X_1, \ldots, X_n)$ —па нормальный (гауссовский) вектор. Тогда, пользуясь свойством гауссовского вектора (см. лемму 3), можно получить, что вектор $(\overline{X}, X_1 - \overline{X}, \ldots, X_n - \overline{X})$ – тоже гауссовский вектор (то есть можно предъявить матрицу A такую, что итоговый вектор – это результат умножения этой матрицы A на исходный нормальный вектор).

   Проверим, что компонента нормального вектора $\overline{X}$ независима с остальными $(X_1 - \overline{X}, \ldots, X_n - \overline{X})$. В случае гауссовского вектора для независимости достаточно проверить некоррелированность (см. лемму 3).

$$\operatorname{cov}(\overline{X}, X_j - \overline{X}) = \operatorname{cov}(\overline{X}, X_j) - \operatorname{cov}(\overline{X}, \overline{X}) = \frac{\sigma^2}{n} - \frac{n\sigma^2}{n^2} = 0$$

   Теперь остается заметить, что S^2 – это функция от с.в. $X_j - \overline{X}$, а значит она тоже независима с $\overline{X}$. Что и требовалось доказать.

2. Теперь перейдем к распределениям. Первое утверждение $\sqrt{n} \cdot \frac{\overline{X}-\mu}{\sigma} \sim \mathcal{N}(0,1)$ следует из независимости элементов выборки и свойств гауссовского вектора (см. лемма 3). Перейдем к доказательству второго утверждения. Заметим, что

$$\begin{aligned}\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2 &= \sum_{i=1}^{n}\left(\frac{(X_i-\overline{X})+(\overline{X}-\mu)}{\sigma}\right)^2 \\ &= \sum_{i=1}^{n}\left(\frac{X_i-\overline{X}}{\sigma}\right)^2 + \sum_{i=1}^{n}\left(\frac{\overline{X}-\mu}{\sigma}\right)^2 + 2\left(\frac{\overline{X}-\mu}{\sigma}\right)\sum_{i=1}^{n}\left(\frac{X_i-\overline{X}}{\sigma}\right) \\ &= \sum_{i=1}^{n}\left(\frac{X_i-\overline{X}}{\sigma}\right)^2 + n\left(\frac{\overline{X}-\mu}{\sigma}\right)^2.\end{aligned}$$

   Значит

$$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2 = \sum_{i=1}^{n}\left(\frac{X_i-\overline{X}}{\sigma}\right)^2 + \left(\sqrt{n}\cdot\frac{\overline{X}-\mu}{\sigma}\right)^2$$

   Так как $X_i \sim \mathcal{N}(\mu, \sigma^2)$ для всех $i = 1, \ldots, n$,то

$$\frac{X_j-\mu}{\sigma} \sim \mathcal{N}(0,1) \quad \text{и} \quad \sqrt{n}\cdot\frac{\overline{X}-\mu}{\sigma} \sim \mathcal{N}(0,1)$$

   Тогда по определению распределения хи-квадрат понятно, что

$$\underbrace{\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2}_{\sim\chi^2_n} = \underbrace{\sum_{i=1}^{n}\left(\frac{X_i-\overline{X}}{\sigma}\right)^2}_{Y} + \underbrace{\left(\sqrt{n}\cdot\frac{\overline{X}-\mu}{\sigma}\right)^2}_{\sim\chi^2_1}$$

   Докажем через характеристические функции, что $Y \sim \chi^2(n-1)$. Для χ^2_n характеристическая функция имеет вид $\varphi_X(t) = (1-2it)^{-n/2}$. Тогда из независимости слагаемых справа от равенства получаем

$$(1-2it)^{-n/2} = \varphi_Y(t)\cdot(1-2it)^{-1/2}, \quad \varphi_Y(t) = (1-2it)^{-(n-1)/2}$$

Замечаем, что характеристическая функция Y соответствует распределению χ^2_{n-1}. Остается добавить, что характеристическая функция однозначно задает распределение. Поэтому

$$\frac{1}{\sigma^2}\sum_{i=1}^{n}\big(X_i - \overline{X}\big)^2 \sim \chi^2_{n-1}$$

Что и требовалось доказать.

□

4 Достаточные статистики

Некоторые статистические модели допускают сжатие информации – замену выборки $\mathbf{X} = (X_1, \ldots, X_n)$ размера n на статистику $T(\mathbf{X})$, которая "эквивалентна"всей выборке в задаче оценивания неизвестного параметра θ.

Для того чтобы не дублировать некоторые утверждения для дискретных и абсолютно непрерывных распределений введем понятия *обобщенной плотности* $p_\theta(x)$ и функции правдоподобия $\mathcal{L}(\theta)$.

4.1 Функция правдоподобия

Определение 19 (Обобщенная плотность)**.** Рассмотрим два случая.

1. Пусть X – абсолютно непрерывная случайная величина, то есть существует такая неотрицательная функция $p(x) \geqslant 0$, что для любого $B \in \mathcal{B}(\mathbb{R})$

$$\mathbb{P}_X(B) = \int_B p(x)dx\,.$$

   Тогда ее *обобщенная плотность* и есть обычная плотность $p_\theta(x)$.

2. Пусть X – дискретная случайная величина, принимающая не более чем счетный набор значений $(x_k)_{k\in\mathbb{N}}$. Тогда ее *обобщенной плотностью* будем называть величину

$$p(x) = \begin{cases} \mathbb{P}(X = x_k), & \text{если } x = x_k; \\ 0, \text{ иначе.} \end{cases}$$

Определение 20 (Функция правдоподобия)**.** Пусть $\boldsymbol{x} = (x_1, ..., x_n)$ – реализация выборки $\mathbf{X} = (X_1, \ldots, X_n)$ из некоторого распределения с обобщенной плотностью $p_\theta(x)$. *Функцией правдоподобия* называется функция

$$\mathcal{L}(\theta) = p_\theta(\boldsymbol{x}) = \prod_{i=1}^{n} p_\theta(x_i),$$

рассматриваемая при фиксированном $\boldsymbol{x}$ как функция от θ.

Замечание 8. Функция правдоподобия – это совместная плотность данных (плотность вектора $\mathbf{X}$), за исключением того, что это функция от параметра θ, то есть $\mathcal{L} : \Theta \to \mathbb{R}_+$. Функция правдоподобия как функция от θ показывает насколько правдоподобно значение параметра θ для данной выборки $\mathbf{X} = (X_1, \ldots, X_n)$. Она не является функцией плотности: в общем случае $\int_\Theta \mathcal{L}(\theta)d\theta \neq 1$.

Приведем несколько примеров вычисления функции правдоподобия и обобщенной плотности. Начнем с дискретного распределения.

Exercise 1. Пусть $X_1, \ldots, X_n$ – выборка из распределения Бернулли $\mathrm{Bin}(1, \theta)$, то есть

$$X_i = \begin{cases} 1, \text{ с вероятностью } \theta; \\ 0, \text{ с вероятностью } 1 - \theta\,. \end{cases}$$

Легко видеть, что (проверьте!) величины X_i имеют обобщенную плотность

$$p_\theta(x) = \theta^x(1-\theta)^{1-x}\,, \quad x \in \{0,1\}\,.$$

Соответствующая функция правдоподобия принимает вид

$$\mathcal{L}(\theta) = p_\theta(\mathbf{X}) = \prod_{i=1}^n p_\theta(X_i) = \theta^{\sum_{i=1}^n X_i}(1-\theta)^{n-\sum_{i=1}^n X_i}\,.$$

Теперь рассмотрим абсолютно непрерывное распределение.

Exercise 2. Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ - выборка из нормального распределения $\mathcal{N}(\theta, \sigma^2)$ с известной дисперсией σ^2. Тогда обобщенная плотность $p_\theta(x)$ величин X_i совпадает с обычной плотностью

$$p_\theta(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\theta)^2}{2\sigma^2}\right\}.$$

Функция правдоподобия параметра θ для выборки $\mathbf{X} = (X_1, \ldots, X_n)$:

$$\mathcal{L}(\theta) = p_\theta(\mathbf{X}) = \prod_{i=1}^n p_\theta(X_i) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp\left\{-\frac{\sum_{i=1}^n (X_i-\theta)^2}{2\sigma^2}\right\}.$$

4.2 Достаточные статистики

Определение 21 (Достаточная статистика)**.** Статистика T называется достаточной для параметра $\theta \in \Theta$, если для любого борелевского множества B и любого t условная вероятность

$$\mathbb{P}_\theta(\mathbf{X} \in B \,|\, T(\mathbf{X}) = t)$$

не зависит от $\theta \in \Theta$.

Другими словами, вся информация о параметре θ содержится в статистике $T(\mathbf{X})$. Поэтому вместо хранения всей выборки $\mathbf{X}$ можно оставить только значение достаточной статистики $T(\mathbf{X})$, сократив объем данных.

Замечание 9. Достаточная статистика всегда существует. Так, вся выборка $\mathbf{X}$ является достаточной статистикой для параметра θ, но в ряде случаев получается подобрать достаточные статистики существенно меньшей размерности.

Пример 11. Пусть $\mathbf{X} = (X_1, X_2, \ldots, X_n)$ — выборка из распределения Бернулли $\mathcal{B}\mathrm{er}(\theta)$ с параметром $\theta \in (0,1)$. Покажем, что статистика $T(\mathbf{X}) = \sum_{i=1}^n X_i$ является достаточной для параметра θ.

Функция правдоподобия:

$$\mathcal{L}(\theta) = \mathbb{P}_\theta(\mathbf{X} = \mathbf{x}) = \prod_{i=1}^n \theta^{x_i}(1-\theta)^{1-x_i} = \theta^{\sum x_i}(1-\theta)^{n-\sum x_i}, \quad x_i \in \{0,1\}.$$

По формуле условной вероятности:

$$\mathbb{P}_\theta\big(\mathbf{X} = \mathbf{x} \mid T = t\big) = \frac{\mathbb{P}_\theta(\mathbf{X} = \mathbf{x},\ T = t)}{\mathbb{P}_\theta(T = t)}.$$

Если $\sum x_i \neq t$, то условная вероятность равна нулю. Рассмотрим случай $\sum_{i=1}^n x_i = t$. Заметим, что событие $\{\mathbf{X} = \mathbf{x}\}$ автоматически влечёт $\sum x_i = t$, поэтому

$$\mathbb{P}_\theta(\mathbf{X} = \mathbf{x},\ T = t) = \mathbb{P}_\theta(\mathbf{X} = \mathbf{x}) = \mathcal{L}(\theta) = \theta^t(1-\theta)^{n-t}.$$

Статистика $T = \sum_{i=1}^n X_i$ имеет биномиальное распределение, поэтому

$$\mathbb{P}_\theta(T = t) = \binom{n}{t}\theta^t(1-\theta)^{n-t}, \quad t = 0, 1, \ldots, n.$$

Следовательно,

$$\mathbb{P}_\theta\big(\mathbf{X} = \mathbf{x} \mid T = t\big) = \frac{\theta^t(1-\theta)^{n-t}}{\binom{n}{t}\theta^t(1-\theta)^{n-t}} = \frac{1}{\binom{n}{t}},$$

На практике редко проверяют является ли статистика достаточной непосредственно по определению, гораздо удобнее воспользоваться критерием факторизации.[2]

Теорема 6 (Критерий факторизации)**.** *Пусть дана выборка $\mathbf{X} = (X_1, \ldots, X_n)$ из параметрического семейства $\mathcal{P} = \{p_\theta(x) : \theta \in \Theta\}$. Статистика $T(\mathbf{X})$ является достаточной для параметра $\theta \in \Theta$ тогда и только тогда, когда функция правдоподобия $\mathcal{L}(\theta)$ представима в виде*

$$\mathcal{L}(\theta) = g(T(\mathbf{X}), \theta)h(\mathbf{X}).$$

Доказательство. Доказательство проведем для дискретного случая.

1. Докажем, прямое утверждение, что если $T(\mathbf{X})$ является достаточной для параметра $\theta \in \Theta$ тогда функция правдоподобия $\mathcal{L}(\theta)$ представима в виде $\mathcal{L}(\theta) = g(T(\mathbf{X}), \theta)h(\mathbf{X})$. Если статистика $T(\mathbf{X})$ достаточная, то для любого элемента выборочного пространства $\boldsymbol{x}$ и любого t из области значений статистики условная вероятность $\mathbb{P}_\theta(\mathbf{X} = \boldsymbol{x} \,|\, T(\mathbf{X}) = t)$ не зависит от $\theta \in \Theta$. Обозначим

$$\varphi(\boldsymbol{x}, t) = \mathbb{P}_\theta(\mathbf{X} = \boldsymbol{x} \,|\, T(\mathbf{X}) = t) \quad \text{и} \quad g(t, \theta) = \mathbb{P}_\theta(T(\mathbf{X}) = t).$$

Применим формулу условной вероятности и заметим, что для любого $\boldsymbol{x}$ из выборочного пространства и $t = T(\boldsymbol{x})$ выполнено равенство

$$\mathbb{P}_\theta(\mathbf{X} = \boldsymbol{x}, T(\mathbf{X}) = t) = \mathbb{P}_\theta(\mathbf{X} = \boldsymbol{x}) = L(\mathbf{X}, \theta) = g(T(\boldsymbol{x}), \theta)\, h(\boldsymbol{x}) = g(t, \theta)\, h(\boldsymbol{x}).$$

Заметим, что выражение в числителе равно нулю, если $T(\boldsymbol{x}) \neq t$, поэтому достаточно рассмотреть только случай $T(\boldsymbol{x}) = t$. Значит, функция правдоподобия $L(\theta)$ представима в виде

$$\mathcal{L}(\theta) = \varphi(\mathbf{X}, T(\mathbf{X}))\, g(T(\mathbf{X}), \theta).$$

Обозначив $h(\mathbf{X}) = \varphi(\mathbf{X}, T(\mathbf{X}))$, получаем $L(\mathbf{X}, \theta) = g(T(\mathbf{X}), \theta)\, h(\mathbf{X})$.

2. Докажем, обратное утверждение, что если функция правдоподобия $\mathcal{L}(\theta)$ представима в виде $\mathcal{L}(\theta) = g(T(\mathbf{X}), \theta)h(\mathbf{X})$, то $T(\mathbf{X})$ является достаточной для параметра $\theta \in \Theta$. Заметим, что для любого $\boldsymbol{x}$ из выборочного пространства и $t = T(\boldsymbol{x})$ выполнено равенство

$$\mathbb{P}_\theta(\mathbf{X} = \boldsymbol{x}, T(\mathbf{X}) = t) = \mathbb{P}_\theta(\mathbf{X} = \boldsymbol{x}) = L(\mathbf{X}, \theta) = g(T(\boldsymbol{x}), \theta)\, h(\boldsymbol{x}) = g(t, \theta)\, h(\boldsymbol{x}). \tag{4}$$

[2] *Factor* (англ.) – множитель.

По определению условной вероятности, для любого $\boldsymbol{x}$ из выборочного пространства и любого t из области значений статистики $T(\mathbf{X})$, имеем

$$\mathbb{P}_\theta(\mathbf{X}=\boldsymbol{x}\,|\,T(\mathbf{X})=t)=\frac{\mathbb{P}_\theta(\mathbf{X}=\boldsymbol{x},T(\mathbf{X})=t)}{\mathbb{P}_\theta(T(\mathbf{X})=t)}. \tag{5}$$

Заметим, что выражение в числителе равно нулю, если $T(\boldsymbol{x})\neq t$, поэтому достаточно рассмотреть только случай $T(\boldsymbol{x})=t$. Для выражения в знаменателе справедливо соотношение

$$\mathbb{P}_\theta(T(\mathbf{X})=t)=\sum_{\boldsymbol{x}'}\mathbb{P}_\theta(\mathbf{X}=\boldsymbol{x}',T(\mathbf{X})=t),$$

где суммирование идет по всем элементам выборочного пространства. Подставляя это равенство в (5) и учитывая (4), получаем

$$\mathbb{P}_\theta(\mathbf{X}=\boldsymbol{x}\,|\,T(\mathbf{X})=t)=\frac{g(t,\theta)\,h(\boldsymbol{x})}{\sum\limits_{\boldsymbol{x}'}g(t,\theta)\,h(\boldsymbol{x}')}=\frac{h(\boldsymbol{x})}{\sum\limits_{\boldsymbol{x}'}h(\boldsymbol{x}')},$$

то есть условная вероятность не зависит от θ. □

Пример 12 (Достаточная статистика в схеме Бернулли)**.** Пусть $\mathbf{X}=(X_1,\cdots,X_n)$ – выборка из распределения Бернулли $\mathcal{B}\mathrm{er}(\theta)$. Покажем, что выборочное среднее $T(\mathbf{X})=\sum_{i=1}^n X_i$ является достаточной статистикой для параметра θ через критерий факторизации.

В данном случае функция правдоподобия записывается в виде

$$\mathcal{L}(\theta)=\prod_{i=1}^n p_\theta(X_i)=\theta^{\sum_{i=1}^n X_i}(1-\theta)^{n-\sum_{i=1}^n X_i}.$$

По критерию факторизации получаем

$$g(\theta,T(\mathbf{X}))=\theta^{\sum_{i=1}^n X_i}(1-\theta)^{n-\sum_{i=1}^n X_i}\quad\text{и}\quad h(\mathbf{X})=1.$$

Пример 13 (Достаточная статистика в нормальной модели)**.** Пусть $\mathbf{X}=(X_1,\cdots,X_n)$ – выборка из нормального распределения $\mathcal{N}(\theta,\sigma^2)$, где $\sigma>0$ известна. Покажем, что выборочное среднее $T(\mathbf{X})=\overline{X}$ является достаточной статистикой для параметра θ.

В данном случае функция правдоподобия записывается в виде

$$\begin{aligned}L(\theta)&=(2\pi\sigma^2)^{-n/2}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^n(X_i-\theta)^2\right\}\\&=(2\pi\sigma^2)^{-n/2}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^n(X_i^2-2X_i\theta+\theta^2)\right\}\\&=(2\pi\sigma^2)^{-n/2}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^n X_i^2\right\}\cdot\exp\left\{\frac{n\overline{X}\theta}{2\sigma^2}-\frac{n\theta^2}{2\sigma^2}\right\}.\end{aligned}$$

Взяв

$$g(\overline{X},\theta)=\exp\left\{\frac{\theta\sum_{i=1}^n X_1}{2\sigma^2}-\frac{n\theta^2}{2\sigma^2}\right\}\quad\text{и}\quad h(\mathbf{X})=(2\pi\sigma^2)^{-n/2}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^n X_i^2\right\}$$

и применяя критерий факторизации, получаем достаточность $\sum_{i=1}^n X_i$.

Замечание 10. Достаточная статистика не единственна. Любая биективная функция достаточной статистики – достаточная статистика. Предположим $T(\mathbf{X})$ – достаточная статистика, φ – биективная функция с обратной φ^{-1}. Рассмотрим статистику $S(\mathbf{X}) = \varphi(T(\mathbf{X}))$. По критерию факторизации, $\mathcal{L}(\boldsymbol{x}, \theta)$ можно представить в виде

$$\mathcal{L}(\boldsymbol{x}, \theta) = g(T(\boldsymbol{x}), \theta)h(\boldsymbol{x}) = g(\varphi^{-1}(S(\boldsymbol{x})), \theta)h(\boldsymbol{x}).$$

Обозначив $f(s, \theta) = g(\varphi^{-1}(s), \theta)$, получаем, что

$$L(\boldsymbol{x}, \theta) = f(S(\boldsymbol{x}), \theta)h(\boldsymbol{x}),$$

то есть, S также является достаточной статистикой для параметра θ.

4.3 Минимальные достаточные статистики

Пусть теперь нас интересует вопрос: как наиболее эффективно сжать выборку, не потеряв при этом никакой информации о неизвестном параметре.

Определение 22 (Минимальная достаточная статистика)**.** Статистика $T(\boldsymbol{x})$ называется *минимально достаточной* для параметра θ, если

- $T(\boldsymbol{x})$ достаточна для θ;
- для любой достаточной статистики $S(\boldsymbol{x})$ существует измеримая функция φ такая, что

$$T(\boldsymbol{x}) = \varphi(S(\boldsymbol{x})).$$

То есть минимальная достаточная статистика — это функция от любой другой достаточной статистики.

Замечание 11. Минимальная достаточная статистика не единственная, но все такие статистики взаимно однозначно преобразуемы.

Теорема 7 (Критерий минимальности)**.** *Достаточная статистика $T(\boldsymbol{x})$ является минимальной для параметра θ тогда и только тогда, когда для любых двух выборок $\mathbf{x} = (x_1, x_2, \ldots, x_n)$, $\mathbf{y} = (y_1, y_2, \ldots, y_n)$ выполняется*

$$\frac{p_\theta(\boldsymbol{x})}{p_\theta(\boldsymbol{y})} \text{ не зависит от } \theta \quad \Longleftrightarrow \quad T(\boldsymbol{x}) = T(\boldsymbol{y}).$$

Ключевая идея критерия: пусть у нас есть две выборки $\mathbf{X} = (X_1, \ldots, X_n)$ и $\mathbf{Y} = (Y_1, \ldots, Y_n)$ и мы хотим понять, содержат ли они одинаковую информацию о неизвестном параметре. Если отношение правдоподобий для этих двух выборок не зависит от θ, то эти выборки дают одинаковую информацию о параметре.

Пример 14. Пусть $X_1, \ldots, X_n$ — выборка из распределения Бернулли $\mathcal{B}\text{er}(\theta)$.

1. *Достаточность.* Запишем функцию правдоподобия:

$$p_\theta(\boldsymbol{x}) = \prod_{i=1}^{n} \theta^{x_i}(1-\theta)^{1-x_i} = \theta^{\sum x_i}(1-\theta)^{n-\sum x_i}.$$

Значит по критерию факторизации статистика $T(\boldsymbol{x}) = \sum_{i=1}^{n} x_i$ достаточна.

2. *Минимальность.* Для двух выборок x, y рассмотрим отношение

$$\frac{p_\theta(\boldsymbol{x})}{p_\theta(\boldsymbol{y})} = \theta^{\sum_{i=1}^n x_i - \sum_{i=1}^n y_i}(1-\theta)^{(n-\sum_{i=1}^n x_i)-(n-\sum_{i=1}^n y_i)} = \left(\frac{\theta}{1-\theta}\right)^{\sum_{i=1}^n x_i - \sum_{i=1}^n y_i}.$$

Это отношение не зависит от θ только если $\sum_{i=1}^n x_i = \sum_{i=1}^n y_i$. Значит по критерию минимальности 7 достаточная для параметра θ статистика $T(\mathbf{X}) = \sum_{i=1}^n X_i$ является минимальной.

Пример 15. Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ — выборка из распределения Пуассона Poisson(θ) с параметром $\theta > 0$:

$$P(X_i = x_i) = \frac{\theta^{x_i} e^{-\theta}}{x_i!}, \quad x_i = 0, 1, 2, \ldots$$

Значит по критерию факторизации статистика $T(\boldsymbol{x}) = \sum_{i=1}^n x_i$ достаточна.

1. *Достаточность.* Функция правдоподобия для выборки:

$$p_\theta(\boldsymbol{x}) = \prod_{i=1}^n \frac{\theta^{x_i} e^{-\theta}}{x_i!} = \theta^{\sum_{i=1}^n x_i} e^{-n\theta} \prod_{i=1}^n \frac{1}{x_i!}.$$

2. *Минимальность.* Рассмотрим отношение функции правдоподобия для двух выборок $x = (x_1, \ldots, x_n)$ и $y = (y_1, \ldots, y_n)$:

$$\frac{p_\theta(\boldsymbol{x})}{p_\theta(\boldsymbol{y})} = \frac{\theta^{\sum x_i} e^{-n\theta} \prod \frac{1}{x_i!}}{\theta^{\sum y_i} e^{-n\theta} \prod \frac{1}{y_i!}} = \theta^{\sum x_i - \sum y_i} \cdot \frac{\prod y_i!}{\prod x_i!}.$$

Отношение не зависит от θ тогда и только тогда, когда $\sum_{i=1}^n x_i = \sum_{i=1}^n y_i$. Значит по критерию минимальности 7 достаточная $T(\mathbf{X}) = \sum_{i=1}^n X_i$ является минимально достаточной статистикой для параметра θ.

4.4 Экспоненциальное семейство распределений

Всегда существует тривиальная (векторная) достаточная статистика – вся выборка. Важным является вопрос: для каких статистических моделей существуют достаточные статистики, размер которых не зависит от длины выборки? Примером класса таких моделей может служить *экспоненциальное семейство.*

Определение 23 (Однопараметрическое экспоненциальное семейство распределений)**.** Пусть $\mathcal{P} = \{\mathbb{P}_\theta \colon \theta \in \Theta \in \mathbb{R}\}$ – параметрическое семейство с обобщенной плотностью $p_\theta(x)$. Будем говорить, что распределение $\mathbb{P}_\theta$ принадлежит к экспоненциальному классу распределений, если его обобщенная плотность представляется в виде

$$p_\theta(x) = \exp\{\eta(\theta)T(x) - A(\theta)\}h(x), \tag{6}$$

где $\eta, T,$ — некоторые функции, h – неотрицательная функция, A – нормировочная константа.

Утверждение 4. Пусть дана выборка $\mathbf{X} = (X_1, \ldots, X_n)$ из экспоненциального семейства, тогда и распределение вектора $\mathbf{X}$ также принадлежит экспоненциальному семейству.

Доказательство. Действительно

$$p_\theta(\boldsymbol{x}) = \prod_{i=1}^n p_\theta(x_i) = \prod_{i=1}^n \exp\{\eta(\theta)T(x_i) - A(\theta)\}h(x_i)$$
$$= \exp\left\{\eta(\theta)\sum_{i=1}^n T(x_i) - nA(\theta)\right\}\prod_{i=1}^n h(x_i).$$

□

По критерию факторизации статистика $T(\mathbf{X}) = \sum_{i=1}^n T(X_i)$ является досаточной статистикой.

Экспоненциальное семейство из определения 23 является однопараметрическим. В случае векторного параметра $\theta \in \Theta \in \mathbb{R}^d$ рассмотрим следующее определение.

Определение 24 (d-параметрическое экспоненциальное семейство распределений)**.** Пусть $\theta \in \Theta \in \mathbb{R}^d$. Будем говорить, что распределение $\mathbb{P}_\theta$ принадлежит к экспоненциальному классу распределений, если его обобщенная плотность представляется в виде

$$p_\theta(x) = \exp\left\{\sum_{k=1}^d \eta_k(\theta)T_k(x) - A(\theta)\right\}h(x).$$

где $\eta_1, \ldots, \eta_d,\ T_1, \ldots, T_d$ — некоторые функции, h – неотрицательная функция, а A – нормировочная константа.

Класс экспоненциальных распределений достаточно широк. Убедимся в этом на следующих примерах.

Пример 16. Рассмотрим распределение Пуассона $\mathrm{Pois}(\theta)$ и $\theta > 0$. Обобщенная плотность

$$p_\theta(x) = \frac{\theta^x e^{-\theta}}{x!} = \exp\left\{\ln\left(\theta^x e^{-\theta}\right)\right\}\frac{1}{x!} = \exp\{x\ln\theta - \theta\}\frac{1}{x!}.$$

Тогда $\eta(\theta) = \ln\theta,\ T(x) = x,\ A(\theta) = -\theta,\ h(x) = \frac{1}{x!}$. Если дана выборка $\mathbf{X} = (X_1, \ldots, X_n)$, то $T(\mathbf{X}) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$ – достаточная.

Пример 17. Рассмотрим распределение Бернулли $\mathrm{Bin}(1, \theta)$ и $\theta \in \{0, 1\}$. Обобщенная плотность

$$p_\theta(x) = \theta^x(1-\theta)^{1-x} = \exp\{x\ln\theta + (1-x)\ln(1-\theta)\} = \exp\{x(\ln\theta - \ln(1-\theta)) + \ln(1-\theta)\}.$$

Тогда $\eta(\theta) = \ln\theta - \ln(1-\theta),\ T(x) = x,\ A(\theta) = -\ln(1-\theta),\ h(x) = 1$. Если дана выборка $\mathbf{X} = (X_1, \ldots, X_n)$, то статистика $T(\mathbf{X}) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$ – достаточная.

Пример 18. Рассмотрим нормальное распределение $\mathcal{N}(\theta, \sigma^2)$ с неизвестным средним θ и известной дисперсией σ^2. Рассмотрим плотность распределения

$$p_\theta(x) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left\{-\frac{(x-\theta)^2}{2\sigma^2}\right\} = \frac{1}{\sqrt{2\pi}\sigma}\exp\left\{\frac{\theta x}{\sigma^2} - \frac{\theta^2}{2\sigma^2} - \frac{x^2}{2\sigma^2}\right\}.$$

Тогда $\eta(\theta) = \frac{\theta}{\sigma^2},\ T(x) = x,\ A(\theta) = \frac{\theta^2}{2\sigma^2},\ h(x) = \exp\{-\frac{x^2}{2\sigma^2}\}$. Если дана выборка $\mathbf{X} = (X_1, \ldots, X_n)$, то $T(\mathbf{X}) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$ – достаточная.

Замечание 12. Отметим также, что равномерное распределение на отрезке $[0, \theta]$ и двухпараметрическое экспоненциальное распределение со сдвигом θ не входят в экспоненциальное семейство распределений.

5 Эффективные оценки

В данном разделе мы сосредоточимся на поиске наилучших оценок в классе несмещенных оценок неизвестных параметров для *регулярных семейств.*

Напомним, что мы сравниваем оценки через их функции рисков, являющимися функциями от параметра $\theta \in \Theta$. И вообще говоря неочевидно, что будет существовать такая оценка, риск которой равномерно минимален. Более того, если мы рассмотрим всевозможные оценки, то наилучшей оценки в соответствии с определением 15 не существует.

Утверждение 5. Рассмотрим $\Theta \subseteq \mathbb{R}$, класс всевозможных оценок $\mathcal{K}$, и квадратичную функцию потерь $\rho(x, y) = (x - y)^2$. Тогда наилучшей оценки не существует.

Доказательство. Для любого $\theta_0 \in \Theta$ можно рассмотреть оценку $\widehat{\theta}_0(\mathbf{X}) \equiv \theta_0$. Тогда в точке $\theta = \theta_0$ ее функция риска обращается в нуль:

$$R(\widehat{\theta}_0(\mathbf{X}), \theta_0) = \mathbb{E}_{\theta_0}\Big(\widehat{\theta}_0(\mathbf{X}) - \theta_0\Big)^2 = 0$$

Это означает, что если наилучшая оценка $\widehat{\theta}(\mathbf{X})$ существует, то в каждом $\theta \in \Theta$ должно достигаться значение $R(\widehat{\theta}(\mathbf{X}), \theta) = 0$, а значит должно быть выполнено $R(\widehat{\theta}(\mathbf{X}), \theta) \equiv 0$. Поскольку $R(\widehat{\theta}(\mathbf{X}), \theta) = \mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X}) - \theta)^2]$, должно выполняться $\widehat{\theta}(x) \equiv \theta$ для всех $\theta \in \Theta$. Противоречие, так как оценка не может зависеть от неизвестного параметра. □

В данном примере отсутствие наилучшей оценки объясняется тем, что рассматриваемый класс оценок чрезмерно широкий. Оказывается если его сузить, то оптимальная оценка может существовать, например если рассматривать только несмещенные оценки.

5.1 Оптимальные оценки

Напомним, что среднеквадратичный риск раскладывается в сумму квадрата смещения и дисперсии (лемма 2). Тогда в случае несмещенных оценок определение 15 уточняется и для сравнения оценок достаточно сравнить их дисперсии. Наилучшие оценки в классе несмещенных оценок мы будем называть оптимальными оценками.

Определение 25 (Оптимальная оценка)**.** Пусть $\mathcal{K}$ - класс несмещенных оценок с ограниченной дисперсией. Оптимальной оценкой параметра θ называется такая оценка $\widehat{\theta}$, что

- $\widehat{\theta} \in \mathcal{K}$;
- Оценка $\widehat{\theta}$ имеет равномерно минимальную дисперсию в классе $\mathcal{K}$, то есть для любой *несмещенной* оценки $\widetilde{\theta} \in \mathcal{K}$ при всех $\theta \in \Theta$ выполнено

$$\mathrm{Var}_\theta(\widehat{\theta}) \leqslant \mathrm{Var}_\theta(\widetilde{\theta}).$$

Вспомним, что дисперсия оценки показывает ее разброс относительно истинного значения параметра и чем этот разброс меньше, тем точнее оценка. А теперь наконец сформулируем основное преимущество нашего выбора рассматривать лишь несмещенные оценки.

Лемма 6. *Если оптимальная оценка существует, то она единственна.*

Доказательство. Докажем от противного. Пусть существуют две оптимальные оценки $\widehat{\theta}_1$ и $\widehat{\theta}_2$ для параметра θ. Тогда $\mathbb{E}_\theta(\widehat{\theta}_1) = \mathbb{E}_\theta(\widehat{\theta}_2) = \theta$, и в силу их оптимальности

$$\mathrm{Var}_\theta(\widehat{\theta}_1) = \mathrm{Var}_\theta(\widehat{\theta}_2)\,. \tag{7}$$

Построим теперь новую оценку $\widehat{\theta}_3 = \frac{\widehat{\theta}_1+\widehat{\theta}_2}{2}$ и вычислим ее математическое ожидание и дисперсию:

$$\mathbb{E}_\theta\widehat{\theta}_3 = \frac{1}{2}\mathbb{E}_\theta(\widehat{\theta}_1 + \widehat{\theta}_2) = \theta\,,$$

то есть $\widehat{\theta}_3$ также является несмещенной. Вычислим теперь дисперсию оценки $\widehat{\theta}_3$:

$$\mathrm{Var}_\theta(\widehat{\theta}_3) = \frac{1}{4}\Big(\mathrm{Var}_\theta(\widehat{\theta}_1) + \mathrm{Var}_\theta(\widehat{\theta}_2) + 2\mathrm{cov}_\theta(\widehat{\theta}_1,\widehat{\theta}_2)\Big) = \frac{1}{2}\Big(\mathrm{Var}_\theta(\widehat{\theta}_1) + \mathrm{cov}_\theta(\widehat{\theta}_1,\widehat{\theta}_2)\Big).$$

По неравенству Коши-Буняковского-Шварца (КБШ)

$$\mathrm{cov}_\theta(\widehat{\theta}_1,\widehat{\theta}_2) \leqslant \sqrt{\mathrm{Var}_\theta(\widehat{\theta}_1)}\sqrt{\mathrm{Var}_\theta(\widehat{\theta}_2)} \leqslant \mathrm{Var}_\theta(\widehat{\theta}_1),$$

значит, с учетом (7), получим

$$\mathrm{Var}_\theta(\widehat{\theta}_3) \leqslant \mathrm{Var}_\theta(\widehat{\theta}_1)\,.$$

Так как оценки $\widehat{\theta}_1$ и $\widehat{\theta}_2$ – оптимальные, предыдущее неравенство должно обратиться в равенство. Это возможно, только если $\widehat{\theta}_1$ и $\widehat{\theta}_2$ линейно связаны

$$\widehat{\theta}_2 = a\widehat{\theta}_1 + b,$$

для некоторых постоянных a и b. Найдем эти константы. Из КБШ имеем

$$\mathrm{cov}_\theta(\widehat{\theta}_1,\widehat{\theta}_2) = \mathrm{cov}_\theta(\widehat{\theta}_1, a\widehat{\theta}_1 + b) = \mathrm{cov}_\theta(\widehat{\theta}_1, a\widehat{\theta}_1) = \mathbb{E}_\theta(\widehat{\theta}_1 - \theta)(a\widehat{\theta}_1 - a\theta) = a\mathbb{E}_\theta(\widehat{\theta}_1 - \theta)^2 = a\mathrm{Var}_\theta(\widehat{\theta}_1).$$

Но $\mathrm{cov}_\theta(\widehat{\theta}_1,\widehat{\theta}_2) = \mathrm{Var}_\theta(\widehat{\theta}_1)$, значит $a = 1$. Из несмещенности получим $b = 0$. Следовательно, оценки $\widehat{\theta}_1$ и $\widehat{\theta}_2$ совпадают и значит если существует оптимальная оценка, то она единственна. □

Можно ли по заданной выборке $\mathbf{X}$ построить оценку $\widehat{\theta}(\mathbf{X})$ со сколь угодно малой дисперсией? Далее мы покажем, что если рассматриваемая вероятностно-статистическая модель удовлетворяет *условиям регулярности*, то имеет место нижняя оценка для дисперсии любой несмещенной оценки. Но прежде чем переходить к формулировке основных результатов, нам потребуется ввести несколько определений.

5.2 Информация Фишера. Условия регулярности

Определение 26 (Вклад выборки)**.** Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ – выборка с обобщенной плотностью $p_\theta(x)$. *Вкладом* выборки $\mathbf{X}$ называется величина

$$U_\theta(\boldsymbol{X}) = \frac{\partial}{\partial\theta}\ln p_\theta(\boldsymbol{X}).$$

Определение 27 (Информация Фишера)**.** Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ – выборка с обобщенной плотностью $p_\theta(x)$. *Информацией Фишера* выборки $\mathbf{X}$ называется величина

$$\mathcal{I}_n(\theta) = \mathbb{E}_\theta\big[U_\theta(\boldsymbol{X})^2\big].$$

Информация Фишера показывает количество информации, содержащееся в выборке $\mathbf{X}$, о параметре θ. Информацией, содержащейся в одном наблюдении, называют величину

$$i(\theta) = \mathcal{I}_1(\theta) = \mathbb{E}_\theta\big[U_\theta(X_1)^2\big].$$

Exercise 3. Пусть X_1 – выборка размера 1 из нормального распределения $\mathcal{N}(\theta, \sigma^2)$ с известной дисперсией σ^2. Посчитаем информацию о неизвестном параметре θ, содержащуюся в одном элементе. Начнем с лог-правдоподобия.

$$\ln p_\theta(X_1) = -\frac{1}{2}\ln\big(2\pi\sigma^2\big) - \frac{(X_1-\theta)^2}{\sigma^2}.$$

Теперь посчитаем вклад одного элемента

$$U_\theta(X_1) = \frac{(X_1-\theta)}{\sigma^2}.$$

Значит информация Фишера равна

$$i(\theta) = \frac{1}{\sigma^4}\mathbb{E}_\theta(X_1-\theta)^2 = \frac{\mathrm{Var}_\theta(X_1)}{\sigma^4} = \frac{1}{\sigma^2}.$$

Получили, что информация о неизвестном параметре θ обратно пропорциональна дисперсии, то есть чем меньше дисперсия, тем больше информации содержится в выборке, тем точнее мы сможем оценить θ. И действительно, чем меньше разброс и тем лучше случайная величина будет концентрироваться около своего среднего, в данном случае около θ.

Пример 19. Пусть X_1 - выборка размера 1 из распределения Бурнулли $\mathcal{B}\mathrm{er}(\theta)$. Посчитаем информацию о неизвестном параметре θ, содержащуюся в одном элементе. Запишем обобщенную плотность

$$\mathcal{L}(\theta) = \mathbb{P}(X_1 = x) = \theta^x(1-\theta)^{1-x}, \qquad x \in \{0,1\}$$

Тогда лог-правдоподобие

$$\ln p_\theta(X_1) = X_1\log\theta + (1-X_1)\log(1-\theta)$$

$$\frac{\partial \ln p_\theta(X_1)}{\partial\theta} = \frac{X_1}{\theta} - \frac{1-X_1}{1-\theta}$$

$$\mathcal{I}(p) = \mathbb{E}_\theta\left[\left(\frac{\partial \ln p_\theta(X_1)}{\partial\theta}\right)^2\right] = \mathbb{E}_\theta\left[\left(\frac{X_1}{\theta} - \frac{1-X_1}{1-\theta}\right)^2\right] = \frac{\mathbb{E}[(X_1-\theta)^2]}{\theta^2(1-\theta)^2} = \frac{\mathrm{Var}_\theta(X_1)}{\theta^2(1-\theta)^2} = \frac{1}{\theta(1-\theta)}.$$

Итого, снова получаем, что информация Фишера равна величине, обратной дисперсии, то есть чем меньше дисперсия, тем больше информации о параметре содержится в выборке.

$$\mathcal{I}(\theta) = \frac{1}{\theta(1-\theta)}.$$

Оказывается при выполнении некоторых условий (*условий регулярности*, перечисляемых ниже) можно указать нижнюю оценку на дисперсию несмещенных оценок. Данное утверждение будет называется неравенством Рао-Крамера.[3]

Предположение 1 (Условия регулярности).

1. Параметрическое множество Θ – открытое подмножество $\mathbb{R}$.
2. Множество $A = \{\boldsymbol{x} : p_\theta(\boldsymbol{x}) > 0\}$ не зависит от параметра θ.[4]
3. Для любой статистики $T(\boldsymbol{X})$ такой, что $\mathbb{E}_\theta[T^2(\boldsymbol{X})] < \infty$, законно дифференцирование по параметру под знаком интеграла:

$$\frac{\partial}{\partial\theta}\mathbb{E}_\theta T(\boldsymbol{X}) = \mathbb{E}_\theta T(\boldsymbol{X})U_\theta(\boldsymbol{X}), \text{ где } U_\theta(\boldsymbol{X}) = \frac{\partial}{\partial\theta}\ln p_\theta(\boldsymbol{X}).$$

   Покажем, почему соотношение выше и есть дифференцирование под знаком интеграла:[5]

$$\begin{aligned}\frac{\partial}{\partial\theta}\mathbb{E}_\theta T(\boldsymbol{X}) &= \frac{\partial}{\partial\theta}\int_A T(\boldsymbol{x})p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x} = \int_A T(\boldsymbol{x})\frac{\partial p_\theta(\boldsymbol{x})}{\partial\theta}\mathrm{d}\boldsymbol{x}\\ &= \int_A T(\boldsymbol{x})\left(\frac{1}{p_\theta(\boldsymbol{x})}\frac{\partial p_\theta(\boldsymbol{x})}{\partial\theta}\right)p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x}\\ &= \int_A T(\boldsymbol{x})\frac{\partial \ln p_\theta(\boldsymbol{x})}{\partial\theta}p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x} = \mathbb{E}_\theta T(\boldsymbol{X})U_\theta(\boldsymbol{X}).\end{aligned}$$

4. Информация Фишера выборки $\boldsymbol{X}$ положительна и конечна при всех $\theta \in \Theta$:

$$0 < \mathcal{I}_n(\theta) < \infty.$$

Замечание 13. Большинство известных распределений удовлетворяют условиям регулярности, кроме равномерного распределения $\mathrm{Uniform}(0,\theta)$, в котором носитель зависит от параметра, то есть условие 2 не выполняется.

Перед тем как перейти к неравенству Рао-Крамера, докажем ряд полезных утверждений.

Лемма 7. *Пусть* $\mathbf{X} = (X_1, \ldots, X_n)$ *– выборка из регулярного семейства с обобщенной плотностью* $p_\theta(x)$. *Тогда* $\mathbb{E}_\theta U_\theta(\mathbf{X}) = 0$.

Доказательство. Воспользуемся условием регулярности 3 для $T(\mathbf{X}) \equiv 1$:

$$\frac{\partial}{\partial\theta}\mathbb{E}_\theta T(\mathbf{X}) = \frac{\partial}{\partial\theta}\mathbb{E}_\theta 1 = 0 = \mathbb{E}_\theta U_\theta(\mathbf{X}).$$

Следовательно, $\mathbb{E}_\theta U_\theta(\mathbf{X}) = 0$. □

[3] Неравенство Рао-Крамера может быть также обобщено на случай смещенных оценок Ивченко [2010]. Мы же рассматриваем более простой вариант этого неравенства, потому что именно в случае несмещенных оценок среднеквадратичный риск совпадает с дисперсией.

[4] Данное требование обусловлено тем, что нам придется неоднократно дифференцировать по θ под знаком интеграла функции, определенные на выборочном пространстве.

[5] В машинном обучении и особенно в обучении с подкреплением такой переход к логарифму функции правдоподобия называют log-derivative trick. Он часто возникает при практическом применении оценок, полученных с помощью методов Монте-Карло. Например, см. ссылку и блог.

Следующая лемма говорит о том, что в регулярных моделях, информация Фишера линейно возрастает с ростом объема выборки n.

Лемма 8. *Пусть* $\mathbf{X} = (X_1, \dots, X_n)$ *– выборка из регулярного семейства с обобщенной плотностью* $p_\theta(x)$*. Тогда*

$$\mathcal{I}_n(\theta) = ni(\theta)\,.$$

Доказательство. Воспользуемся леммой 7 и определением вклада выборки

$$\mathcal{I}_n(\theta) = \mathbb{E}_\theta\big[(U_\theta(\boldsymbol{X}))^2\big] = \mathrm{Var}_\theta\left[\frac{\partial}{\partial\theta}\ln p_\theta(\boldsymbol{X})\right] = \mathrm{Var}_\theta\left[\sum_{i=1}^n \frac{\partial}{\partial\theta}\ln p_\theta(X_i)\right] = n\mathrm{Var}_\theta\left[\frac{\partial}{\partial\theta}\ln p_\theta(X_1)\right]$$
$$= ni(\theta)\,.$$

□

Следующая лемма дает альтернативный способ вычисления информации Фишера в регулярных моделях.

Лемма 9. *Пусть* $\mathbf{X} = (X_1, \dots, X_n)$ *– выборка из регулярного семейства с обобщенной плотностью* $p_\theta(x)$*, дважды дифференцируемая по* θ*. Тогда информация Фишера*

$$\mathcal{I}_n(\theta) = -\mathbb{E}\left[\frac{\partial}{\partial\theta}U_\theta(\boldsymbol{X})\right].$$

Доказательство. Воспользуемся леммой 7, условием регулярности 3 и продифференцируем еще раз по θ

$$\begin{aligned}
0 = \frac{\partial}{\partial\theta}\mathbb{E}_\theta U_\theta(\mathbf{X}) &= \frac{\partial}{\partial\theta}\int_A U_\theta(\mathbf{X})p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x}\\
&= \frac{\partial}{\partial\theta}\int_A\left(\frac{\partial}{\partial\theta}\ln p_\theta(\boldsymbol{x})\right)p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x}\\
&= \int_A\left(\frac{\partial^2}{\partial\theta^2}\ln p_\theta(\boldsymbol{x})\right)p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x} + \int_A\left(\frac{\partial}{\partial\theta}\ln p_\theta(\boldsymbol{x})\right)\frac{\partial}{\partial\theta}p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x}\\
&= \int_A\left(\frac{\partial^2}{\partial\theta^2}\ln p_\theta(\boldsymbol{x})\right)p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x} + \int_A\left(\frac{\partial}{\partial\theta}\ln p_\theta(\boldsymbol{x})\right)^2 p_\theta(\boldsymbol{x})\mathrm{d}\boldsymbol{x}\\
&= \mathbb{E}\left[\frac{\partial}{\partial\theta}U_\theta(\mathbf{X})\right] + \mathbb{E}\big[U_\theta(\mathbf{X})^2\big] = \mathbb{E}\left[\frac{\partial}{\partial\theta}U_\theta(\mathbf{X})\right] + \mathcal{I}_n(\theta).
\end{aligned}$$

Откуда получаем требуемое равенство. □

5.3 Неравенство Рао-Крамера

Теперь перейдем к основному результату, а имменно к нижней границе на дисперсию несмещенных оценок в регулярных моделях.

Теорема 8 (Неравенство Рао-Крамéра)**.** *Пусть* $\mathbf{X} = (X_1, \dots, X_n)$ *– выборка из регулярного семейства с обобщенной плотностью* $p_\theta(x)$*. Пусть* $\tau(\theta)$ *— дифференцируемая функция, и* $\widehat{\theta}(\mathbf{X})$ *— несмещённая оценка параметра* $\tau(\theta)$ *такая, что* $\mathbb{E}_\theta[\widehat{\theta}^2(\mathbf{X})] < \infty$*. Тогда для всех* $\theta \in \Theta$

$$\mathrm{Var}_\theta(\widehat{\theta}(\boldsymbol{X})) \geqslant \frac{(\tau'(\theta))^2}{ni(\theta)}.$$

Доказательство. Из несмещенности имеем

$$\mathbb{E}_\theta[\widehat{\theta}(\boldsymbol{X})] = \tau(\theta).$$

воспользуемся свойством регулярности 3, продифференцировав это уравнение по θ

$$\tau'(\theta) = \frac{\partial}{\partial\theta}\mathbb{E}_\theta\widehat{\theta}(\boldsymbol{X}) = \mathbb{E}_\theta[\widehat{\theta}(\boldsymbol{X})U_\theta(\boldsymbol{X})]$$

Сведем математическое ожидание в правой части равенство к ковариации, а затем воспользуемся неравенством Коши-Буняковского-Шварца. Для этого применим лемму 7 к уравнению выше

$$\begin{aligned}\tau'(\theta) = \mathbb{E}_\theta[\widehat{\theta}(\boldsymbol{X})U_\theta(\boldsymbol{X})] &= \mathbb{E}_\theta[(\widehat{\theta}(\boldsymbol{X}) - \tau(\theta))U_\theta(\boldsymbol{X})] + \mathbb{E}_\theta[\tau(\theta)U_\theta(\boldsymbol{X})] \\ &= \mathbb{E}_\theta[(\widehat{\theta}(\boldsymbol{X}) - \tau(\theta))U_\theta(\boldsymbol{X})] \\ &= \mathbb{E}_\theta[(\widehat{\theta}(\boldsymbol{X}) - \tau(\theta))(U_\theta(\boldsymbol{X}) - \mathbb{E}_\theta U_\theta(\boldsymbol{X}))] \\ &= \operatorname{cov}_\theta(\widehat{\theta}(\boldsymbol{X}), U_\theta(\boldsymbol{X})).\end{aligned}$$

Теперь, применяя неравенство Коши-Буняковского-Шварца, получим

$$(\tau'(\theta))^2 = \operatorname{cov}_\theta(\widehat{\theta}(\boldsymbol{X}), U_\theta(\boldsymbol{X}))^2 \leqslant \operatorname{Var}_\theta(\widehat{\theta}(\boldsymbol{X}))\operatorname{Var}_\theta(U_\theta(\boldsymbol{X})) = \operatorname{Var}_\theta(\widehat{\theta}(\boldsymbol{X}))I_n(\theta). \tag{8}$$

Следовательно,

$$\operatorname{Var}_\theta(\widehat{\theta}(\boldsymbol{X})) \geqslant \frac{(\tau'(\theta))^2}{\mathcal{I}_n(\theta)}.$$

Далее остается только применить лемму 8 и получить требуемое неравенство. □

Таким образом, в регулярной модели мы не можем рассчитывать на оценку искомого параметра θ с дисперсией, убывающей быстрее чем $1/n$ с ростом размера выборки n.

Определение 28 (Эффективная оценка)**.** Пусть выполнены условия регулярности. Несмещенная оценка $\widehat{\theta}(\boldsymbol{X})$ для $\tau(\theta)$ называется *эффективной*, если при любом $\theta \in \Theta$ для неё достигается равенство в неравенстве Рао-Крамера, то есть для всех $\theta \in \Theta$

$$\operatorname{Var}_\theta(\widehat{\theta}(\boldsymbol{X})) = \frac{(\tau'(\theta))^2}{ni(\theta)}.$$

Замечание 14. Если $\tau(\theta) = \theta$, то определение (28) упрощается

$$\operatorname{Var}_\theta(\widehat{\theta}(\boldsymbol{X})) = \frac{1}{ni(\theta)}.$$

Для доказательства эффективности часто бывает полезен следующий критерий эффективности

Следствие 2 (Критерий эффективности)**.** *Пусть выполнены условия регулярности. Оценка эффективна тогда и только тогда, когда оценка $\widehat{\theta}(\mathbf{X})$ является линейной функцией вклада выборки $U_\theta(\boldsymbol{X})$, то есть*

$$\widehat{\theta}(\boldsymbol{X}) - \tau(\theta) = c(\theta)U_\theta(\boldsymbol{X}), \text{ где } c(\theta) = \frac{\tau'(\theta)}{ni(\theta)}.$$

Доказательство. Неравенство Коши-Шварца (8) переходит в равенство тогда и только тогда, когда между случайными величинами есть линейная зависимость, то есть существуют функции $c(\theta)$ и $a(\theta)$ такие, что

$$\widehat{\theta}(\boldsymbol{X}) = c(\theta)U_\theta(\boldsymbol{X}) + a(\theta)\,. \tag{9}$$

Найдем эти функции. Для начала возьмём матожидание от этого равенства и воспользуемся леммой 7

$$\mathbb{E}_\theta\widehat{\theta}(\boldsymbol{X}) = \mathbb{E}_\theta[c(\theta)U_\theta(\boldsymbol{X}) + a(\theta)].$$

Тогда получаем

$$\tau(\theta) = c(\theta)\cdot 0 + a(\theta) \implies a(\theta) = \tau(\theta).$$

Теперь умножим обе части равенства (9) на $U_\theta(\boldsymbol{X})$ и возьмём матожидание:

$$\mathbb{E}_\theta[(\widehat{\theta}(\boldsymbol{X}) - \tau(\theta))U_\theta(\boldsymbol{X})] = \mathbb{E}_\theta[c(\theta)U_\theta^2(\boldsymbol{X})].$$

Тогда по свойству регулярности 3 получаем

$$\mathbb{E}_\theta[\widehat{\theta}(\boldsymbol{X})U_\theta(\boldsymbol{X})] - \tau(\theta)\mathbb{E}_\theta[U_\theta(\boldsymbol{X})] = \frac{\partial}{\partial\theta}\mathbb{E}_\theta\widehat{\theta}(\boldsymbol{X}) = \tau'(\theta) = c(\theta)\mathcal{I}_n(\theta) \quad \Longrightarrow \quad c(\theta) = \frac{\tau'(\theta)}{\mathcal{I}_n(\theta)}.$$

□

Лемма 10. *Если оценка $\widehat{\theta}(\mathbf{X})$ — эффективная оценка для $\tau(\theta)$, то она также является оптимальной. Обратное неверно.*

Доказательство. Утверждение леммы следует из теоремы 8 и определения оптимальной оценки 25.

Обратное утверждение неверно, потому что в нерегулярных моделях дисперсия может быть меньше нижней границы неравенства Рао-Крамера. □

5.4 Эффективные оценки в регулярных экспоненциальных семействах

Следующая теорема позволяет наиболее просто находить эффективные оценки и функции, для которых существуют эффективные оценки для распределений из экспоненциального семейства.

Теорема 9. *Пусть $\mathbf{X} = (X_1, X_2, \ldots, X_n)$ — выборка из регулярной модели $\{\mathbb{P}_\theta\colon \theta \in \Theta \subseteq \mathbb{R}\}$. Эффективная оценка $\widehat{\theta}(\mathbf{X})$ для некоторой функции $\tau(\theta)$ существует тогда и только тогда, когда $\mathbb{P}_\theta$ принадлежит экспоненциальному семейству, причём*

$$\widehat{\theta}(\mathbf{X}) = \frac{1}{n}\sum_{i=1}^{n} T(X_i), \quad \textit{и} \quad \tau(\theta) = \frac{A'(\theta)}{\eta'(\theta)}. \tag{10}$$

(последние два равенства следует понимать с точностью до одного и того же аффинного преобразования обеих величин).

Доказательство. 1. Докажем сначала прямое утверждение, то есть пусть существует эффективная оценка $\widehat{\theta}(\mathbf{X})$ для некоторой $\tau(\theta)$, тогда покажем, что распределение принадлежит экспоненциальному семейству.

Если $\widehat{\theta}(\mathbf{X})$ – эффективная оценка, то для нее должен выполняться критерий эффективности (Следствие 2)

$$\widehat{\theta}(\mathbf{X}) = \tau(\theta) + \frac{\tau'(\theta)}{ni(\theta)} U_\theta(\mathbf{X}) = \tau(\theta) + \frac{\tau'(\theta)}{ni(\theta)} \sum_{i=1}^{n} U_\theta(X_i), \tag{11}$$

так как

$$U_\theta(\mathbf{X}) = \frac{\partial}{\partial\theta} \ln p_\theta(\mathbf{X}) = \frac{\partial}{\partial\theta} \ln \prod_{i=1}^{n} p_\theta(X_i) = \sum_{i=1}^{n} \frac{\partial}{\partial\theta} \ln p_\theta(X_i) = \sum_{i=1}^{n} U_\theta(X_i).$$

Заметим теперь, что левая часть (11) не зависит от неизвестного параметра θ (по определению оценки), значит и правая часть (11) не должна зависеть от θ. Тогда обозначим правую часть (11) за $\frac{1}{n}\sum_{i=1}^{n} C(X_i)$, то есть

$$\widehat{\theta}(\mathbf{X}) = \frac{1}{n} \sum_{i=1}^{n} C(X_i) = \frac{1}{n} \sum_{i=1}^{n} \left(\tau(\theta) + \frac{\tau'(\theta)}{i(\theta)} U_\theta(X_i) \right). \tag{12}$$

Теперь из этого уравнения выразим вклад одного наблюдения:

$$U_\theta(x) = \frac{\partial}{\partial\theta} \ln p_\theta(x) = \frac{i(\theta)}{\tau'(\theta)} C(x) - \frac{i(\theta)\tau(\theta)}{\tau'(\theta)}.$$

Возьмем неопределенный интеграл от этого выражения

$$\ln p_\theta(x) = C(x) \int \frac{i(\theta)}{\tau'(\theta)} \mathrm{d}\theta - \int \frac{i(\theta)\tau(\theta)}{\tau'(\theta)} \mathrm{d}\theta + B(x).$$

Тогда получаем, что распределение принадлежит экспоненциальному семейству с

$$\eta(\theta) = \int \frac{i(\theta)}{\tau'(\theta)} \,\mathrm{d}\theta\,, \quad T(x) = C(x), \quad A(\theta) = \int \frac{i(\theta)\tau(\theta)}{\tau'(\theta)} \,\mathrm{d}\theta\,.$$

Используем это в (12) и получим вид эффективных оценок

$$\widehat{\theta}(\mathbf{X}) = \frac{1}{n} \sum_{i=1}^{n} T(X_i). \tag{13}$$

Теперь заметим, что отношение $A'(\theta)$ и $\eta'(\theta)$ и есть $\tau(\theta)$, то есть получим требуемое утверждение

$$\tau(\theta) = \frac{A'(\theta)}{\eta'(\theta)}.$$

2. Докажем теперь утверждение в обратную сторону. Пусть распределение принадлежит экспоненциальному семейству, то есть обобщенная плотность представляется в виде

$$p_\theta(x) = \exp\{\eta(\theta)T(x) - A(\theta)\}h(x),$$

Теперь остается лишь проверить, что критерий эффективности выполняется для $\hat{\theta}(X) = \frac{1}{n}\sum_{i=1}^{n} T(X_i)$ и $\tau(\theta) = \frac{A'(\theta)}{\eta'(\theta)}$. Для экспоненциального семейства вклад выборки представим в виде

$$U_\theta(\mathbf{X}) = \frac{\partial}{\partial\theta}\log p_\theta(\mathbf{X}) = \sum_{i=1}^{n}(\eta'(\theta)T(X_i) - A'(\theta)) = n\eta'(\theta)\left(\frac{1}{n}\sum_{i=1}^{n} T(X_i) - \frac{A'(\theta)}{\eta'(\theta)}\right).$$

Перепишем

$$\frac{1}{n}\sum_{i=1}^{n} T(X_i) - \frac{A'(\theta)}{\eta'(\theta)} = \frac{1}{n\eta'(\theta)}U_\theta(\mathbf{X}).$$

Тогда по критерию эффективности $\hat{\theta}(X) = \frac{1}{n}\sum_{i=1}^{n} T(X_i)$ будет оценкой функции $\tau(\theta) = \frac{A'(\theta)}{\eta'(\theta)}$.

□

5.5 Сверхэффективные оценки

Интересно отметить, что при нарушении условий регулярности дисперсия может убывать значительно быстрее, чем граница в неравенстве Рао-Крамера, такие оценки называют *сверхэффективными*.

Пример 20. Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ – выборка из равномерного распределения $U[0, \theta]$, где $\theta > 0$. Покажем, что несмещенная оценка параметра θ

$$\widehat{\theta}(\mathbf{X}) = \frac{n+1}{n}X_{(n)}.$$

обладает дисперсией $\mathrm{Var}_\theta(\widehat{\theta}(\mathbf{X})) = \frac{\theta^2}{n(n+2)}$

Данная модель не будет регулярна, поскольку нарушено условие 2 (пределы интегрирования во всех последующих вычислениях зависят от θ, и поэтому дифференцировать под знаком интеграла уже не получится). Заметим, что функция распределения $n-$й порядковой статистики имеет вид

$$\mathbb{P}_\theta(X_{(n)} \leqslant t) = \mathbb{P}_\theta(X_1 \leqslant t, \ldots, X_n \leqslant t) = \prod_{i=1}^{n}\mathbb{P}_\theta(X_i \leqslant t) = \begin{cases} 0, t \leqslant 0 \\ \left(\frac{t}{\theta}\right)^n, 0 < t < \theta \\ 1, t \geqslant \theta\,. \end{cases}$$

Следовательно, ее плотность распределения имеет вид

$$p_\theta(t) = \begin{cases} \frac{nt^{n-1}}{\theta^n}\,, 0 < t < \theta \\ 0,\ \text{иначе}\ . \end{cases}$$

Посчитаем моменты, а затем вычислим дисперсию

$$\mathbb{E}_\theta\left[\frac{n+1}{n}X_{(n)}\right] = \frac{n+1}{n}\int_0^\theta \frac{nt^n}{\theta^n}\mathrm{d}t = \theta$$

$$\mathbb{E}_\theta\left[\left(\frac{n+1}{n}X_{(n)}\right)^2\right] = \frac{(n+1)^2}{n^2}\int_0^\theta \frac{nt^{n+1}}{\theta^n}\mathrm{d}t = \frac{(n+1)^2}{n(n+2)}\theta^2$$

Тогда дисперсия оценки будет

$$\mathrm{Var}_\theta\left[\frac{n+1}{n}X_{(n)}\right] = \mathbb{E}_\theta\left[\left(\frac{n+1}{n}X_{(n)}\right)^2\right] - \left(\mathbb{E}_\theta\left[\frac{n+1}{n}X_{(n)}\right]\right)^2 = \frac{(n+1)^2}{n(n+2)}\theta^2 - \theta^2 = \frac{\theta^2}{n(n+2)}\,.$$

Таким образом мы получили, что дисперсия оценки $\widehat{\theta}(\mathbf{X}) = \frac{n+1}{n}X_{(n)}$ убывает с ростом n как n^{-2} в то время как нижняя граница в неравенстве Рао-Крамера соответствует n^{-1}. Подобные оценки называются *сверхэффективными*, они возможны только в нерегулярных моделях.

5.6 Многомерное неравенство Рао-Крамера.

Определенные выше понятия и критерии оптимальности непосредственно переносятся и на случай векторного параметра $\theta = (\theta_1, \ldots, \theta_r) \in \mathbb{R}^r$. В этом случае под вкладом выборки $\mathbf{X}$ мы понимаем вектор $\mathbf{U}_\theta(\mathbf{X}) = (U_{\theta,1}(\mathbf{X}), \ldots, U_{\theta,r}(\mathbf{X}))$, где

$$U_{\theta,i}(\mathbf{X}) = \frac{\partial}{\partial\theta_i}\ln p_\theta(\boldsymbol{X})\,.$$

Аналогом информации Фишера (см. определение 27) является информационная матрица Фишера:

$$\mathbf{I}_n(\theta) \in \mathbb{R}^{r\times r}\,, (\mathbf{I}_n(\theta))_{i,j} = \mathbb{E}_\theta[U_{\theta,i}(\mathbf{X})U_{\theta,j}(\mathbf{X})]\,.$$

При этом информационная матрица одного наблюдения имеет вид

$$\mathbf{I}_1(\theta) \in \mathbb{R}^{m\times m}\,, (\mathbf{I}_1(\theta))_{i,j} = \mathbb{E}_\theta\left[\frac{\partial}{\partial\theta_i}\ln p_\theta(X_1)\frac{\partial}{\partial\theta_j}\ln p_\theta(X_1)\right] = -\mathbb{E}_\theta\left[\frac{\partial^2}{\partial\theta_i\partial\theta_j}\ln p_\theta(X_1)\right]\,.$$

Последнее равенство верно для дважды дифференцируемых плотностей и проверяется интегрированием по частям. Теперь мы можем сформулировать многомерный аналог неравенства Рао-Крамера:

Теорема 10 (Многомерное неравенство Рао-Крамéра)**.** *Пусть* $\mathbf{X}$ *- выборка из* $\mathbb{P} \in \{\mathbb{P}_\theta : \theta \in \Theta \in \mathbb{R}^r\}$*, удовлетворяющего условиям регулярности. Пусть* $\tau(\theta) : \mathbb{R}^r \mapsto \mathbb{R}$ *— дифференцируемая функция, и* $\widehat{\theta}(\mathbf{X})$ *— несмещённая оценка* $\tau(\theta)$ *такая, что* $\mathbb{E}_\theta[\widehat{\theta}^2(\mathbf{X})] < \infty$*. Тогда для всех* $\theta \in \Theta$*:*

$$\mathrm{Var}_\theta(\widehat{\theta}(\boldsymbol{X})) \geqslant \frac{1}{n}(\nabla\tau(\theta))^\intercal\mathbf{I}_1^{-1}(\theta)\nabla\tau(\theta)\,. \tag{14}$$

Данное неравенство обращается в равенство тогда и только тогда, когда оценка $\widehat{\theta}(\mathbf{X})$ *является линейной функцией вклада выборки, то есть*

$$\widehat{\theta}(\boldsymbol{X}) - \tau(\theta) = c(\theta)^\intercal\mathbf{U}_\theta(\boldsymbol{X})\,,\ \textit{где}\ c(\theta) = \frac{1}{n}\mathbf{I}_1(\theta)^{-1}\nabla\tau(\theta)\,.$$

Доказательство теоремы аналогично доказательству в одномерном случае.

6 Методы получения оценок

Теперь мы наконец можем перейти к основным методам получения оценок неизвестных параметров распределения.

6.1 Метод моментов

Рассмотрим задачу оценивания неизвестного параметра $\theta \in \Theta \subset \mathbb{R}^d$ распределения $\mathcal{P} \in \{\mathbb{P}_\theta : \theta \in \Theta \subset \mathbb{R}^d\}$ по выборке $\mathbf{X} = (X_1, \dots, X_n)$ из этого распределения. Допустим, что Θ – открытое подмножество $\mathbb{R}^d$. Предположим, что элементы выборки имеют конечные моменты вплоть до порядка d, то есть для любого $k = 1, \dots, d$

$$\mathbb{E}_\theta |X_1|^k < \infty \quad \text{для всех } \theta \in \Theta.$$

Метод моментов основан на простой идее: приравнять теоретические моменты $(\mathbb{E}_\theta X_1, \dots, \mathbb{E}_\theta X_1^d)$ к выборочным моментам $(\overline{X}, \dots, \overline{X^d})$, где $\overline{X^k} = \frac{1}{n}\sum\limits_{i=1}^{n} X_i^k$ – выборочный момент порядка $k \in \mathbb{N}$. Оценка метода моментов получается из решения полученной системы.

Также метод моментов позволяет рассматривать *пробные функции* $g_k(x)$, отличные от базовых функций $g_k(x) = x^k$ $(k = 1, \dots, d)$. В этом случае величины $\mathbb{E}_\theta g_k(X_1)$ уже не будут моментами случайной величины X_1, однако такое обобщение метода оказывается весьма полезным особенно в тех случаях, когда например математическое ожидание $\mathbb{E}_\theta X_1$ не определено (как для распределения Коши).

Теперь более формально определим оценку, получаемую методом моментов с использованием произвольных пробных функций $g_1(x), \dots, g_d(x)$. Пусть борелевские функции $g_1(x), \dots, g_d(x)$ таковы, что для любого $k = 1, \dots d$

$$\mathbb{E}_\theta |g_k(X_1)| < \infty \quad \text{для всех } \theta \in \Theta.$$

и набор значений

$$(\mathbb{E}_\theta [g_1(X_1)], \dots, \mathbb{E}_\theta [g_d(X_1)])$$

однозначно определяет параметр θ. Это означает, что функция $m : \Theta \to \mathbb{R}^d$, где

$$m_k(\theta) = \mathbb{E}_\theta g_k(X_1), \quad k = 1, \dots, d,$$

является биекцией между Θ и $m(\Theta)$.

Определение 29. Оценкой неизвестного параметра θ по методу моментов с *пробными функциями* $g_1(x), \dots, g_d(x)$ называется $\widehat{\theta}(\boldsymbol{X})$ – решение следующей системы уравнений относительно θ:

$$\begin{cases} m_1(\theta) = \overline{g_1(\boldsymbol{X})}, \\ \vdots \\ m_d(\theta) = \overline{g_d(\boldsymbol{X})}, \end{cases}$$

где $m_k(\theta) = \mathbb{E}[g_k(X_1)]$, а $\overline{g_k(\boldsymbol{X})} = \frac{1}{n}\sum\limits_{i=1}^{n} g_k(X_i)$. Так как $m(\theta)$ задаёт биекцию, то

$$\widehat{\theta}(\boldsymbol{X}) = m^{-1}(\overline{g_1(\boldsymbol{X})}, \dots, \overline{g_d(\boldsymbol{X})}).$$

Пример 21. Пусть $(X_1, \ldots, X_n)$ – выборка из нормального распределения $\mathcal{N}(\mu, \sigma^2), \theta = (\mu, \sigma^2) \in \mathbb{R} \times R_+$. Найти оценку θ по методу моментов. Сперва посчитаем теоретические моменты: $\mathbb{E}_\theta X_1 = \mu; \mathbb{E}_\theta X_1^2 = \mu^2 + \sigma^2$. Теперь нужно приравнять теоретические моменты к выборочным моментам

$$\begin{cases} \mu = \overline{X}, \\ \mu^2 + \sigma^2 = \overline{X^2}. \end{cases}$$

Решая систему относительно θ, получаем

$$\begin{cases} \mu = \overline{X}, \\ \sigma^2 = \overline{X^2} - (\overline{X})^2 = S^2. \end{cases}$$

Какими статистическими свойствами обладают оценки, полученные методом моментов?

Теорема 11. *Пусть $\mathbb{E}_\theta |g_k(X_1)| < \infty$ для любого $k = 1, \ldots, d$ и $\theta \in \Theta$. Пусть $\hat{\theta}_n(\boldsymbol{X})$ – оценка параметра θ по методу моментов. Пусть m^{-1} непрерывна на множестве $m(\Theta)$. Тогда*

1. *то $\widehat{\theta}_n(\boldsymbol{X})$ – сильно состоятельная оценка θ;*
2. *Если дополнительно m непрерывно дифференцируема и и матрица Якоби $\nabla m(\theta)$ невырождена при всех $\theta \in \Theta$, а также $\mathbb{E}_\theta[g_k^2(X_1)] < +\infty$ для всех $k = 1, \ldots, d$, то $\widehat{\theta}_n(\boldsymbol{X})$ – асимптотически нормальная оценка θ.*

Доказательство. 1. Согласно УЗБЧ для любого $k = 1, ..., d$

$$\overline{g_k(\boldsymbol{X})} = \frac{1}{n} \sum_{i=1}^{n} g_k(X_i) \xrightarrow{a.s.} \mathbb{E}_\theta g_k(X_1) = m_k(\theta).$$

Если у функции m существует непрерывное обратное отображение $m^{-1} : \mathrm{Im}(m) \to \Theta$, то по теореме о наследовании сходимости получаем:

$$\widehat{\theta}(\boldsymbol{X}) = m^{-1}(\overline{g_1(\boldsymbol{X})}, \ldots, \overline{g_d(\boldsymbol{X})}) \xrightarrow{a.s.} m^{-1}(m_1(\theta), \ldots, m_d(\theta)) = m^{-1}(m(\theta)) = \theta,$$

при $n \to \infty$.

2. Для доказательства асимптотической нормальности воспользуемся ЦПТ и дельта-методом. В силу центральной предельной теоремы при условии $\mathbb{E}_\theta[g_k^2(X_1)] < +\infty$ для всех $k = 1, \ldots, d$, получаем

$$\sqrt{n}\,(\overline{\boldsymbol{g}(\boldsymbol{X})} - m(\theta)) \xrightarrow{d} \mathcal{N}(0, \mathrm{Var}_\theta(\boldsymbol{g}(X_1))), \quad \text{при } n \to \infty,$$

где $\overline{\boldsymbol{g}(\boldsymbol{X})} = (\overline{g_1(\boldsymbol{X})}, \ldots, \overline{g_k(\boldsymbol{X})})$ и $\mathrm{Var}_\theta(\boldsymbol{g}(X_1))$ – матрица ковариации вектора $\boldsymbol{g}(X_1) = (g_1(X_1), \ldots, g_d(X_n))$. Теперь осталось применить многомерный дельта-метод с функцией m^{-1} и заметить, что в силу теоремы об обратной функции m^{-1} также является непрерывно дифференцируемой.

$$\sqrt{n}\,(\widehat{\theta}(\boldsymbol{X}) - \theta) \xrightarrow{d} \mathcal{N}\big(0,\, \nabla m(\theta)^{-1} \mathrm{Var}_\theta(\boldsymbol{g}(X_1)) (\nabla m(\theta)^{-1})^\intercal\big), \quad n \to \infty.$$

□

Итак, метод моментов предоставляет состоятельные и асимптотически нормальные оценки параметра. Однако у него есть целый ряд недостатков

1. **Подбор пробных функций**. Если стандартные не подошли, то возникает проблема поиска подходящих функций. Рассмотрим распределение Коши со сдвигом: у нас есть выборка $(X_1, \ldots, X_n)$, и мы взяли плотность распределения Коши со сдвигом

$$p_\theta(x) = \frac{1}{\pi(1 + (x - \theta)^2)}, \quad \theta \in \mathbb{R}.$$

   Тогда математическое ожидание $\mathbb{E}_\theta X_1$ не определено, и, соответственно, ни одна из стандартных функций не может быть использована.

2. **Асимптотическая дисперсия**. Обычно асимптотическая дисперсия оценок, полученных по методу моментов, довольно велика. Поэтому далее будут рассмотрены оценки с наименьшей возможной асимптотической дисперсией для *регулярных* статистических моделей.

6.2 Метод максимального правдоподобия.

Метод максимального правдоподобия (см. определение 20) – один из ключевых результатов в статистике. Метод получил распространение после появления в 1912 году статьи Р. ФИшера, где было доказано, что получаемые этим методом оценки являются *асимптотически наиболее точными* при выполнении условий *регулярности.*

Определение 30. *Оценкой максимального правдоподобия* (ОМП) параметра θ называется статистика

$$\widehat{\theta}_{MLE}(\boldsymbol{X}) = \arg\max_{\theta \in \Theta} \mathcal{L}(\theta).$$

Данное определение уже накладывает несколько ограничений: как минимум, то, что максимум существует и он единственен. Но в дальнейшем будем считать, что они выполнены.

Интуиция метода проста: вспомним, что правдоподобие показывает насколько вероятно данное значение параметра для конкретной выборки, то есть мы выбираем то значение θ, при которой данная выборка $\mathbf{X}$ наиболее вероятна.

Замечание 15. Обычно удобнее работать с логарифмом правдоподобия, а поскольку логарифм – монотонная функция, то часто оценкой максимального правдоподобия называют

$$\widehat{\theta}_{MLE}(\boldsymbol{X}) = \arg\max_{\theta \in \Theta} \ln \mathcal{L}(\theta). \tag{15}$$

Более того, логарифм естественно возникает из минимизации дивергенции Кульбака-Лейблера (см. ниже).

Пример 22. Пусть $\boldsymbol{X} = (X_1, \ldots, X_n)$ — выборка из нормального распределения $\mathcal{N}(\mu, \sigma^2)$ с неизвестными математическим ожиданием и дисперсией. Найдите оценку максимального правдоподобия параметра $\theta = (\mu, \sigma^2)$.

Решение. По определению функции правдоподобия

$$\mathcal{L}(\theta) = \prod_{i=1}^{n} p_\theta(X_i) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(X_i-\mu)^2}{2\sigma^2}\right\} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(X_i-\mu)^2\right\}.$$

Нужно максимизировать её одновременно по μ и по σ^2, но работать с экспонентой не очень удобно, поэтому прологарифмируем

$$\ln \mathcal{L}(\theta) = -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(X_i-\mu)^2.$$

Эта функция дифференцируема, поэтому можно достаточно легко найти всех претендентов на точки экстремума, приравняв градиент к нулю:

$$0 = \frac{\partial}{\partial\mu}\ln\mathcal{L}(\theta) = \frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i-\mu),$$
$$0 = \frac{\partial}{\partial\sigma^2}\ln\mathcal{L}(\theta) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^{n}(X_i-\mu)^2.$$

Отсюда получаем, что претендентами на точки экстремума будут

$$\widehat{\mu}(\boldsymbol{X}) = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{\boldsymbol{X}},$$
$$\widehat{\sigma}^2(\boldsymbol{X}) = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \frac{1}{n}\sum_{i=1}^{n}X_i\right)^2 = S^2.$$

Получили уже знакомые выборочное среднее и выборочную дисперсию. Далее необходимо проверить, что $\widehat{\theta}(\boldsymbol{X}) = (\overline{\boldsymbol{X}}, S^2)$ действительно максимум. Для этого нужно проверить, что гессиан в точке $(\overline{\boldsymbol{X}}, S^2)$ отрицательно определён. □

Какими статистическими свойствами обладают оценка максимального правдоподобия?

Теорема 12. *Пусть дана выборка* $\mathbf{X} = (X_1, \ldots, X_n)$ *из регулярного семейства с обобщенной плотностью* $p_\theta(x)$. *Пусть дополнительно выполнены следующие условия:*

1. *функция правдоподобия* $\mathcal{L}(\theta)$ *имеет лишь один максимум, не лежащий на границе* Θ;
2. $p_\theta(x)$ *трижды непрерывно дифференцируема по* θ *и при этом существует независящая от* θ *функция* $M(x)$ *такая, что для всех* $\theta \in \Theta$

$$\left|\frac{\partial^3}{\partial\theta^3}\ln p_\theta(x)\right| \leqslant M(x), \qquad \text{причём} \qquad \mathbb{E}_\theta M(X_1) < +\infty.$$

Тогда оценка $\widehat{\theta}_{MLE}$, *найденная как решение уравнения правдоподобия*

$$\left.\frac{\partial\mathcal{L}(\theta)}{\partial\theta}\right|_{\theta=\widehat{\theta}_{MLE}} = 0$$

является

1. *состоятельной;*
2. *асимптотически нормальной с асимптотической дисперсией* $i^{-1}(\theta)$*: для всех* $\theta \in \Theta$

$$\sqrt{n}(\widehat{\theta}_{MLE} - \theta) \xrightarrow{d} \mathcal{N}\big(0, i^{-1}(\theta)\big).$$

3. *асимптотически эффективной;*
4. *асимптотически оптимальной;*
5. *инвариантной: если* $\widehat{\theta}_{MLE}$ *– ОМП для* θ *и отображение* $\theta \mapsto g(\theta)$ *– биективно, то* $g(\widehat{\theta}_{MLE})$ *– ОМП для* $g(\theta)$*;*

Следствие 3. *Пусть выполняются условия теоремы 12. Тогда если существует эффективная оценка для* θ*, то она совпадает с оценкой максимального правдоподобия* $\widehat{\theta}_{MLE}$*.*

Доказательство. Пусть $\widehat{\theta}$ – эффективная оценка, тогда она удовлетворяет критерию эффективности (следствие 2):

$$\widehat{\theta} - \theta = c(\theta)U_\theta(\mathbf{X}) = c(\theta)\frac{\partial}{\partial\theta}\ln\mathcal{L}(\theta).$$

В точке $\theta = \widehat{\theta}_{MLE}$:

$$\widehat{\theta} - \widehat{\theta}_{MLE} = c(\theta)\frac{\partial}{\partial\theta}\ln\mathcal{L}(\theta)\bigg|_{\theta=\widehat{\theta}_{MLE}} = 0$$

Значит, $\widehat{\theta} = \widehat{\theta}_{MLE}$. □

6.2.1 Обоснование метода через дивергенцию Кульбака-Лейблера

Поймем откуда возникает метод максимизации лог-правдоподобия (15). Пусть есть выборка $\mathbf{X}$ из неизвестного распределения $\mathbb{P}_\theta$. Наша цель, найти такую оценку $\widehat{\theta}$, чтобы распределение $\mathbb{P}_{\widehat{\theta}}$ было наиболее близко к истинному распределению $\mathbb{P}_\theta$. Но как сравнивать вероятностные меры? Очевидно обычное евклидово расстояние здесь не подходит. Вместо него рассмотрим дивергенцию Кульбака-Лейблера, обобщенное расстояние (не удовлетворяет неравенству треугольника и симметрии). Рассмотрим случай абсолютно непрерывных распределений.

Определение 31 (Дивергенция Кульбака-Лейблера)**.** Пусть $\mathbb{P}_\theta$ и $\mathbb{P}_{\theta_0}$ – две абсолютно непрерывные вероятностные меры. Тогда дивергенции Кульбака-Лейблера (KL-дивергенция) определяется как

$$\mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) = \int_{-\infty}^{\infty} p_\theta(x)\log\left(\frac{p_\theta(x)}{p_{\theta_0}(x)}\right)\mathrm{d}x = \mathbb{E}_\theta\log\left(\frac{p_\theta(X)}{p_{\theta_0}(X)}\right),$$

где $p_\theta(x)$ и $p_{\theta_0}(x)$ – это плотности распределений $\mathbb{P}_\theta$ и $\mathbb{P}_{\theta_0}$ соответственно.

Дивергенция Кульбака-Лейблера показывает величину потерь информации при замене истинной вероятностной меры $\mathbb{P}_\theta$ на $\mathbb{P}_{\theta_0}$. Для дискретных распределений дивергенции Кульбака-Лейблера представляется через сумму.

Лемма 11 (Свойства KL-дивергенции)**.** *1.* $\mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) \geqslant 0$

2. $\mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) = 0 \iff p_\theta = p_{\theta_0}$ *почти всюду.*

Доказательство. 1. Вспомним интегральное неравенство Йенсена для вогнутой функции $\varphi(y) = \log y$:

$$\varphi(\mathbb{E}Y) \geqslant \mathbb{E}\varphi(Y). \tag{16}$$

Воспользуемся им в KL-дивергенции

$$\begin{aligned} -\mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) &= \int_{-\infty}^{\infty} p_\theta(x) \log\left(\frac{p_{\theta_0}(x)}{p_\theta(x)}\right)\mathrm{d}x = \mathbb{E}_\theta \log\left(\frac{p_{\theta_0}(X)}{p_\theta(X)}\right) \\ &\leqslant \log\left(\mathbb{E}_\theta \frac{p_{\theta_0}(X)}{p_\theta(X)}\right) = \log\left(\int_{-\infty}^{\infty} \frac{p_{\theta_0}(x)}{p_\theta(x)} p_\theta(x)\mathrm{d}x\right) = \log\left(\int_{-\infty}^{\infty} p_{\theta_0}(x)\mathrm{d}x\right) = \log 1 = 0. \end{aligned}$$

Значит, $\mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) \geqslant 0$.

2. Теперь докажем, что из $\mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) = 0$ следует, что $p_\theta = p_{\theta_0}$ почти всюду. Неравенство (16) обращается в равенство тогда и только тогда, когда $\varphi(y)$ – линейная функция и/или Y – это константа почти наверное. В нашем случае равенство будет достигаться только тогда, когда $Y = \frac{p_{\theta_0}(x)}{p_\theta(x)}$ – это константа почти наверное, так как $\varphi(y) = \log y$ – вогнутая. То есть получаем

$$\frac{p_{\theta_0}}{p_\theta} = \mathrm{Const}.$$

Но поскольку из свойства плотностей следует, что интеграл от них по всему пространству равен 1, то данная константа может быть равна только 1 и тогда $p_\theta = p_{\theta_0}$ почти всюду.

Теперь докажем в обратную сторону: из равенства $p_\theta = p_{\theta_0}$ почти всюду следует, что $\mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) = 0$. Достаточно подставить $p_\theta = p_{\theta_0}$ в определение KL-дивергенции и получить нужное утверждение.

□

Изучим более подробно дивергенцию Кульбака-Лейблера:

$$\begin{aligned} \mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) &= \int_{-\infty}^{\infty} p_\theta(x) \log\left(\frac{p_\theta(x)}{p_{\theta_0}(x)}\right)\mathrm{d}x = \mathbb{E}_\theta \log\left(\frac{p_\theta(X)}{p_{\theta_0}(X)}\right) = \mathbb{E}_\theta \log p_\theta(X) - \mathbb{E}_\theta \log p_{\theta_0}(X) \\ &= \text{‘const’} - \mathbb{E}_\theta \log p_{\theta_0}(X). \end{aligned}$$

Тогда из теоремы выше

$$\begin{aligned} \theta &= \arg\min_{\theta_0 \in \Theta} \mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) \\ &= \arg\min_{\theta_0 \in \Theta} -\mathbb{E}_\theta \log p_{\theta_0}(X). \end{aligned} \tag{17}$$

Поскольку истинный параметр θ неизвестен, то посчитать дивергенцию Кульбака Лейблера $\mathrm{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0})$ не представляется возможным. Оценим ее с помощью закона больших чисел

$$\widehat{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) = \text{‘const’} - \frac{1}{n}\sum_{i=1}^{n} \log p_{\theta_0}(X_i). \tag{18}$$

Тогда наилучшей оценкой, доставляющей минимум (18) будет

$$\begin{aligned}\widehat{\theta}(\mathbf{X}) &= \arg\min_{\theta_0\in\Theta} \widehat{KL}(\mathbb{P}_\theta, \mathbb{P}_{\theta_0}) \\ &= \arg\max_{\theta_0\in\Theta} \frac{1}{n}\sum_{i=1}^{n} \log p_{\theta_0}(X_i) \\ &= \arg\max_{\theta_0\in\Theta} \log \mathcal{L}(\theta_0).\end{aligned} \tag{19}$$

Заметим, что полученная оценка совпадает с оценкой максимального правдоподобия (15).

Замечание 16. В машинном обучении подход при котором задача 17 аппроксимируется задачей 19 называется подходом Монте-Карло при котором популяционный риск заменяется на эмпирический риск.

7 Оптимальные оценки

7.1 Улучшение оценок

Пусть мы знаем достаточную статистику $T(\mathbf{X})$ в модели. Тогда ее можно использовать для улучшения оценок (напомним, что мы сравниваем оценки через среднеквадратичный риск).

Теорема 13 (Рао, Блекуэлл, Колмогоров)**.** *Пусть $\hat{\theta}(X)$ — произвольная оценка параметра θ с конечным вторым моментом, а статистика $T(\mathbf{X})$ является достаточной для θ. Определим оценку*

$$\widetilde{\theta}(\mathbf{X}) := \mathbb{E}_\theta[\widehat{\theta}(\mathbf{X}) \mid T(\mathbf{X})].$$

Пусть мы рассматриваем среднеквадратичный риск $R_\theta(\widehat{\theta}) := \mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X}) - \theta)^2]$. Тогда для любого $\theta \in \Theta$

$$R_\theta(\widetilde{\theta}) \le R_\theta(\widehat{\theta})$$

То есть $\tilde{\theta}$ не хуже $\hat{\theta}$ в смысле среднеквадратичной ошибки. Причем равенство достигается тогда и только тогда, когда $\widetilde{\theta} = \widehat{\theta}$ с вероятностью 1.

Перед тем как мы перейдем к доказательству теоремы 13, напомним свойства условного математического ожидания.

Свойства УМО

1. Если $X = \varphi(Y)$, где φ – борелевская функция, то
$$\mathbb{E}(X|Y) = X = \varphi(Y)$$
2. $\mathbb{E}(\mathbb{E}(X|Y)) = \mathbb{E}X$
3. Линейность: $\mathbb{E}(aX + bZ|Y) = a\mathbb{E}(X|Y) + b\mathbb{E}(Z|Y)$
4. Если X и Y независимы, то $\mathbb{E}(X|Y) = \mathbb{E}X$.
5. Если $X = \varphi(Y)$ — борелевская функция, $\mathbb{E}|XZ| < \infty$, $\mathbb{E}|Z| < \infty$, то
$$\mathbb{E}[XZ|Y] = X\mathbb{E}[Z|Y].$$

Доказательство теоремы 13. Во-первых убедимся, что $\widetilde{\theta}$ в самом деле является статистикой, то есть условное математическое ожидание $\mathbb{E}_\theta\big(\widehat{\theta}(\mathbf{X}) \,|\, T(\mathbf{X})\big)$ не зависит от θ. Заметим, что, по определению достаточной статистики, условное распределение $\mathbf{X}$ при $T(\mathbf{X}) = t$ не зависит от θ. Следовательно, и условное распределение (а значит, и условное математическое ожидание) $\widehat{\theta}$ при $T(\mathbf{X}) = t$ не зависит от θ. Таким образом, $\widetilde{\theta} = \mathbb{E}_\theta\big(\widehat{\theta}(\mathbf{X}) \,|\, T(\mathbf{X})\big)$ в самом деле является статистикой.

Теперь докажем, что $\widetilde{\theta}$ не хуже $\hat{\theta}$ в смысле среднеквадратичной ошибки. Рассмотрим среднквадратичный риск оценки $\widehat{\theta}(\mathbf{X})$

$$\begin{aligned} R_\theta(\widehat{\theta}) &= \mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X}) - \theta)^2] = \mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X}) - \widetilde{\theta}(\mathbf{X})) + (\widetilde{\theta}(\mathbf{X}) - \theta)] \\ &= \mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X}) - \widetilde{\theta}(\mathbf{X}))^2] + \mathbb{E}_\theta[(\widetilde{\theta}(\mathbf{X}) - \theta)^2] + 2\mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X}) - \widetilde{\theta}(\mathbf{X}))(\widetilde{\theta}(\mathbf{X}) - \theta)] \\ &= \mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X}) - \widetilde{\theta}(\mathbf{X}))^2] + R_\theta(\widetilde{\theta}) + 2\mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X}) - \widetilde{\theta}(\mathbf{X}))(\widetilde{\theta}(\mathbf{X}) - \theta)] \end{aligned}$$

Покажем, что перекрёстный член равен нулю. Применяя формулу полного математического ожидания, получаем

$$\begin{aligned}\mathbb{E}_\theta[(\widehat{\theta}(\mathbf{X})-\widetilde{\theta}(\mathbf{X}))(\widetilde{\theta}(\mathbf{X})-\theta)] &= \mathbb{E}_\theta\Big[\mathbb{E}_\theta\big[(\widehat{\theta}(\mathbf{X})-\widetilde{\theta}(\mathbf{X}))(\widetilde{\theta}(\mathbf{X})-\theta)\,|\,T(\mathbf{X})\big]\Big]\\ &= \mathbb{E}_\theta\Big[(\widetilde{\theta}(\mathbf{X})-\theta)\mathbb{E}_\theta\big[(\widehat{\theta}(\mathbf{X})-\widetilde{\theta}(\mathbf{X}))\,|\,T(\mathbf{X})\big]\Big]\\ &= \mathbb{E}_\theta\Big[(\widetilde{\theta}(\mathbf{X})-\theta)\cdot 0\Big]=0 \quad \text{при всех } \theta\in\Theta.\end{aligned}$$

Следовательно

$$R_\theta(\widehat{\theta}) = \mathbb{E}[(\widehat{\theta}(\mathbf{X})-\widetilde{\theta}(\mathbf{X}))^2] + R_\theta(\widehat{\theta})$$

Отсюда

$$R_\theta(\widetilde{\theta}) \leqslant R_\theta(\widehat{\theta})$$

□

Замечание 17. Отметим, что попытка дальнейшего улучшения оценки $\widetilde{\theta}(\mathbf{X})$ бесполезна, так как $\mathbb{E}[\widetilde{\theta}(\mathbf{X})\mid T(\mathbf{X})]=\widetilde{\theta}(\mathbf{X})$.

Пример 23. Пусть $(X_1,\cdots,X_n)$ – выборка из распределения $\mathcal{N}(\theta,\sigma^2)$, где $\sigma>0$ известна. Как было выяснено ранее, $\overline{X}$ является достаточной статистикой для параметра θ. Рассмотрим несмещенную оценку X_1 параметра θ и найдем $\mathbb{E}_\theta\big[X_1\,|\,\overline{X}\big]$. В силу симметрии, условные математические ожидания $\mathbb{E}_\theta\big[X_1\,|\,\overline{X}\big],\mathbb{E}_\theta\big[X_2\,|\,\overline{X}\big],\ldots,\mathbb{E}_\theta\big[X_n\,|\,\overline{X}\big]$ совпадают. Значит,

$$n\,\mathbb{E}_\theta\big[X_1\,|\,\overline{X}\big]=\sum_{i=1}^n\mathbb{E}_\theta\big[X_i\,|\,\overline{X}\big]=\mathbb{E}_\theta\left[\sum_{i=1}^n X_i\,\Big|\,\overline{X}\right]=\mathbb{E}_\theta\big[n\,\overline{X}\,|\,\overline{X}\big]=n\,\overline{X}.$$

Таким образом, $\mathbb{E}_\theta\big[X_1\,|\,\overline{X}\big]=\overline{X}$.

Поскольку при квадратичной функции потерь не существует наилучшей оценки среди всех возможных оценок, будем рассматривать только несмещенные оценки. Теорема Рао-Блекуэлла-Колмогорова позволяет сделать важный вывод для несмещенных оценок.

Следствие 4. *Оптимальная оценка, если она существует, является функцией достаточной статистики.*

Доказательство. Пусть $\widehat{\theta}(\mathbf{X})$ – несмещенная оценка параметра $\theta\in\Theta$ с конечным вторым моментом. Проверим несмещенность $\widetilde{\theta}(\mathbf{X})$. По формуле полного математического ожидания,

$$\mathbb{E}_\theta\widetilde{\theta}=\mathbb{E}_\theta\Big[\mathbb{E}_\theta\big(\widehat{\theta}\,|\,T(\mathbf{X})\big)\Big]=\mathbb{E}_\theta\widehat{\theta}\equiv\theta \quad \text{при всех } \theta\in\Theta.$$

Пользуясь леммой 2 в соответствии с которой среднеквадратичный риск несмещенных оценок совпадает с дисперсией, мы заканчиваем доказательство. □

Перейдем теперь к рассмотрению подкласса достаточных статистик, которые позволяют непосредственно строить оптимальные несмещенные оценки.

7.2 Полная достаточная статистика и оптимальные оценки

Определение 32 (Полная достаточная статистика)**.** Статистика $T(\mathbf{X})$ называется *полной достаточной статистикой* для параметра $\theta \in \Theta$, если она является достаточной для параметра $\theta \in \Theta$ и для любой борелевской функции φ равенство

$$\mathbb{E}_\theta \varphi(T(\mathbf{X})) = 0 \quad \text{при всех } \theta \in \Theta$$

влечет $\varphi(x) = 0$ почти всюду на множестве значений $T(\mathbf{X})$.

В случае d-параметрических экспоненциальных семейств задача проверки на полноту достаточной статистики резко упрощается.

Теорема 14 (Полнота в d-параметрическом экспоненциальном семействе)**.** *Пусть дана выборка $X_1, \ldots, X_n$ регулярное экспоненциального семейства с обобщенной плотностью*

$$p_\theta(x) = \exp\left\{\sum_{k=1}^{d} \eta_k(\theta) T_k(x) - A(\theta)\right\} h(x),$$

для $\theta = (\theta_1, \ldots, \theta_d) \in \Theta$. Пусть дана выборка $\mathbf{X} = (X_1, \ldots, X_n)$. Тогда для

$$T(\mathbf{X}) = \left(\sum_{i=1}^{n} T_1(X_i), \ldots, \sum_{i=1}^{n} T_d(X_i)\right)$$

выполняется

1. *$T(\mathbf{X})$ — достаточная статистика для θ.*
2. *Если множество $\{\eta(\theta) := (\eta_1(\theta), \ldots, \eta_d(\theta)) \mid \theta \in \Theta\}$ содержит открытое множество в $\mathbb{R}^d$, то $T(\mathbf{X})$ — полная достаточная статистика.*

Если достаточная статистика $T(\mathbf{X})$ оказалась полной, то задача построения оптимальной оценки сводится к задаче поиска несмещенной оценки.

Теорема 15. *Если существует полная достаточная статистика, то всякая борелевская функция от нее является оптимальной оценкой своего математического ожидания (в классе несмещенных оценок).*

Доказательство. Пусть T является полной достаточной статистикой для параметра θ. Зафиксируем борелевскую функцию H и обозначим

$$\tau(\theta) = \mathbb{E}_\theta H(T).$$

Допустим, что $H(T)$ не является оптимальной оценкой $\tau(\theta)$, то есть существует оценка $H_2(T)$, для которой выполнены соотношения

$$\mathbb{E}_\theta H_2(T) = \tau(\theta) \quad \text{и} \quad \mathrm{Var}_\theta(H_2(T)) \leqslant \mathrm{Var}_\theta(H(T)) \quad \text{при всех } \theta \in \Theta,$$

причем существует $\theta \in \Theta$, для которого $\mathrm{Var}_\theta(H_2(T)) < \mathrm{Var}_\theta(H(T))$. Тогда

$$\mathbb{E}_\theta(H(T) - G(T)) = 0$$

По следствию из теоремы Рао-Блекуэла-Колмогорова оптимальную оценку для $\tau(\theta)$ надо искать в классе функций, зависящих от T. Но $H(T)$ единственная функция от T, несмещенно оценивающая $\tau(\theta)$.

□

8 Оценка функции распределения случайной величины

Пусть имеется выборка $\mathbf{X} = (X_1, \ldots, X_n)$ размера n из неизвестного распределения P_X, как можно оценить P_X? В некоторых задачах распределение элементов выборки не получается охарактеризовать каким-либо конечномерным параметром. Например, о функции распределения $X_1, \ldots, X_n$ может быть известно только то, что она непрерывна. Иногда, чтобы подчеркнуть широту класса допустимых распределений $\mathcal{P} = \{\mathbb{P}_X\}$, говорят о задаче *непараметрического* оценивания. В такой задаче объектом, представляющим интерес, обычно является функция распределения или плотность распределения элементов выборки.

Построим оценку функции распределения F. Для этого зафиксируем некоторое значение $x \in \mathbb{R}$ и оценим $F(x)$. Согласно определению функции распределения, имеем

$$F(x) := \mathbb{P}_X(X \leqslant x) = \mathbb{E}\mathbb{1}(X \leqslant x), \quad x \in \mathbb{R}.$$

Теперь вспомним закон больших чисел (ЗБЧ) для независимых и одинаково распределенных случайных величин.

Теорема 16. *(Закон больших чисел) Пусть $X_1, X_2, \ldots, X_n$ – выборка из распределения с конечными математическим ожиданием μ. Обозначим $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ – выборочное среднее. Тогда при $n \to \infty$*

$$\overline{X} \xrightarrow{\mathbb{P}} \mu.$$

Тогда от выборки $(X_1, ..., X_n)$ можно перейти к совокупности случайных величин

$$(\mathbb{1}(X_1 \leqslant x), ..., \mathbb{1}(X_n \leqslant x)).$$

Определение 33 (Эмпирическая функция распределения)**.** Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ есть выборка размера n из распределения $\mathbb{P}_X$. Тогда случайная величина

$$\widehat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}\{X_i \leqslant x\}, \quad x \in \mathbb{R},$$

называется *эмпирической функцией распределения* (ЭФР).

Отметим, что ЭФР является неубывающей функцией и ее значения лежат на отрезке $[0, 1]$, как и у истинной функции распределения $F(x)$, поэтому ЭФР может быть использована для оценки для $F(x)$. Отметим ряд свойств ЭФР.

Теорема 17. *Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ - выборка из распределения $\mathbb{P}_X$. Пусть $F(x) = \mathbb{P}_X(X_i \leqslant x)$ – это истинная функция распределения, а $\widehat{F}_n(x)$ – эмпирическая функция распределения, построенная по этой выборке. Тогда для любого $x \in \mathbb{R}$ выполнено:*

1. $\mathbb{E}[\widehat{F}_n(x)] = F(x)$;
2. $\mathrm{Var}(\widehat{F}_n(x)) = \frac{F(x)(1-F(x))}{n}$;
3. $n\hat{F}_n(x) \sim \mathrm{Bin}(n, F(x))$;
4. $\widehat{F}_n(x) \xrightarrow{a.s.} F(x)$ *при* $n \to \infty$;

5. $\sqrt{n}(\widehat{F}_n(x) - F(x)) \xrightarrow{d} \mathcal{N}(0, \sigma^2(x))$, *где* $\sigma^2(x) = F(x)(1 - F(x))$.

Доказательство. 1.

$$\mathbb{E}\widehat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}\mathbb{1}\{X_i \leqslant x\} = \mathbb{E}\mathbb{1}\{X_1 \leqslant x\} = \mathbb{P}(X_1 \leqslant x) = F(x).$$

2. Из независимости $X_1, \ldots, X_n$ получаем

$$\mathrm{Var}(\widehat{F}_n(x)) = \frac{1}{n^2}\sum_{i=1}^{n} \mathrm{Var}(\mathbb{1}\{X_i \leqslant x\}) = \frac{1}{n}\mathrm{Var}(\mathbb{1}\{X_1 \leqslant x\}).$$

Определим случайную величину $\eta = \mathbb{1}\{X_1 \leqslant x\}$:

$$\eta = \begin{cases} 1, & \text{с вероятностью } \mathbb{P}(X_1 \leqslant x) = F(x); \\ 0, & \text{иначе,} \end{cases}$$

то есть $\eta \sim \mathcal{B}\mathrm{er}(F(x))$. Тогда

$$\mathrm{Var}(\widehat{F}_n(x)) = \frac{1}{n}\mathrm{Var}(\mathbb{1}\{X_1 \leqslant x\}) = \frac{1}{n}\mathrm{Var}(\eta) = \frac{1}{n}F(x)(1 - F(x)).$$

3. Из того, что $\eta_i = \mathbb{1}\{X_i \leqslant x\} \sim \mathcal{B}\mathrm{er}(F(x))$ следует

$$n\widehat{F}_n(x) = \sum_{i=1}^{n} \mathbb{1}\{X_i \leqslant x\} = \sum_{i=1}^{n} \eta_i \sim \mathrm{Bin}(n, F(x)).$$

4. достаточно применить УЗБЧ Колмогорова к независимым, одинаково распределенным случайным величинам $\mathbb{1}\{X_k \leqslant x\}$, $k \in \{1, \ldots, n\}$.

5. Применяя ЦПТ для $\widehat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \eta_i$:

$$\sqrt{n}(\widehat{F}_n(x) - F(x)) = \sqrt{n}(\overline{\eta} - \mathbb{E}\eta_1) \xrightarrow{d} \mathcal{N}(0, \mathrm{Var}(\eta_1)),$$

то есть $\sigma^2(x) = \mathrm{Var}(\eta_1) = F(x)(1 - F(x))$.

□

На самом деле верен более сильный результат: $\widehat{F}_n(x)$ равномерно приближает $F(x)$ в каждой точке. Этот результат известен как теорема Гливенко-Кантелли.

Сперва определим статистику Колмогорова-Смирнова

Определение 34 (Статистика Колмогорова-Смирнова)**.**

$$D_n := \sup_{x \in \mathbb{R}} |\widehat{F}_n(x) - F(x)|$$

Случайная величина D_n показывает максимальное отклонение эмпирической функции распределения $F_n(x)$ от $F(x)$. Статистика D_n обладает следующим свойством.

Теорема 18 (Гливенко-Кантелли)**.** *Пусть* $\widehat{F}_n(x)$ *– эмпирическая функция распределения. Тогда*

$$D_n \xrightarrow{a.s.} 0, \quad n \to \infty.$$

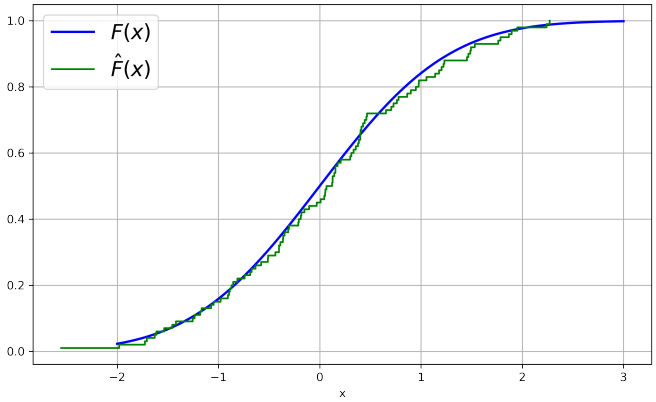


Рис. 1: Эмпирическая функция распределения приближает истинную функцию распределения

На ЭФР $\widehat{F}_n(x)$ можно смотреть как на функцию распределения некоторой дискретной случайной величины ξ, принимающей n значений: $X_1, \ldots, X_n$ – с вероятностями, равными $1/n$.

Замечание 18. Теорема Гливенко-Кантелли показывает обоснованность основной задачи математической статистики – восстановление неизвестного распределения. Например, мы можем равномерно по всем точкам на прямой восстановить функцию распределения.

Эмпирическая функция распределения. Используя понятия $k-$х порядковых статистик, определение эмпирической функции распределения 33 упрощается:

$$\widehat{F}_n(x) = \begin{cases} 0, & x < X_{(1)}; \\ \frac{k}{n}, & X_{(k)} \leqslant x < X_{(k+1)}, \quad k \in \{1, \ldots, n-1\}; \\ 1, & x \geqslant X_{(n)}\,. \end{cases}$$

То есть именно в точках $X_{(k)}$ происходят скачки ЭФР.

С помощью ЭФР найдем распределение $k-$ой порядковой статистики $X_{(k)}$ и убедимся, что оно различно для каждого $k \in \mathbb{N}$.

Утверждение 6. Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ - выборка из распределения $\mathbb{P}_X$ с функцией распределения $F(x) = \mathbb{P}_X(X_i \leqslant x)$. Тогда функция распределения $k-$ой порядковой статистики $X_{(k)}$ задается формулой

$$F_{X_{(k)}}(x) = \mathbb{P}(X_{(k)} \leqslant x) = \sum_{j=k}^{n} \binom{n}{j} \big[F(x)\big]^j \big[1 - F(x)\big]^{n-j}\,.$$

Доказательство. Воспользуемся тем, что ЭФР монотонная

$$\mathbb{P}(X_{(k)} \leqslant x) = \mathbb{P}\Big(\widehat{F}_n(x) \geqslant \frac{k}{n}\Big) = \mathbb{P}\Big(n\widehat{F}_n(x) \geqslant k\Big).$$

Из теоремы 17 имеем $n\hat{F}_n(x) \sim \mathrm{Bin}(n, F(x))$. Значит,

$$\mathbb{P}\Big(n\widehat{F}_n(x) \geqslant k\Big) = \sum_{j=k}^{n} \mathbb{P}(\widehat{F}_n(x) = j) = \sum_{j=k}^{n} \binom{n}{j} \big[F(x)\big]^j \big[1 - F(x)\big]^{n-j}.$$

□

9 Интервальное оценивание

До сих пор мы имели дело только с точечными оценками. Теперь мы переходим к интервальным. Для простоты будем считать, что мы рассматриваем параметрические семейства с одномерным параметром. Под термином интервал в дальнейшем мы будем подразумевать некоторое множество, не обязательно интервал в геометрическом смысле.

Определение 35 (Доверительный интервал)**.** Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ – выборка из распределения $\mathbb{P} \in \{\mathbb{P}_\theta \colon \theta \in \Theta\}$, где $\Theta \subseteq \mathbb{R}$. Будем называть пару статистик $(T_1(\boldsymbol{X}), T_2(\boldsymbol{X}))$ *доверительным интервалом* для параметра θ с уровнем доверия $1 - \alpha \in (0, 1)$, если

- для всех $\theta \in \Theta$ выполнено $T_1(\boldsymbol{X}) \leqslant T_2(\boldsymbol{X})$ с вероятностью 1;
- для всех $\theta \in \Theta$ выполнено

$$\mathbb{P}_\theta(T_1(\boldsymbol{X}) < \theta < T_2(\boldsymbol{X})) \geqslant 1 - \alpha. \tag{20}$$

Если в неравенстве (20) всегда достигается равенство (т.е. $\mathbb{P}_\theta(T_1(\boldsymbol{X}) < \theta < T_2(\boldsymbol{X})) = 1 - \alpha$ для всех $\theta \in \Theta$), то доверительный интервал называют *точным*.

Замечание 19. Подчеркнем, что неизвестный параметр θ не является случайной величиной, а $T_1(\boldsymbol{X}), T_2(\boldsymbol{X})$ – это случайные величины, не зависящие от θ.

При таком определении точность оценивания есть длина интервала $(T_1(\boldsymbol{X}), T_2(\boldsymbol{X}))$, а наша уверенность в оценивании — вероятность попадания параметра в этот интервал.

Определение 36. Подмножество $T(\boldsymbol{X}) \subseteq \Theta$ называется доверительной областью для θ с уровнем доверия $1 - \alpha$, если для всех $\theta \in \Theta$ выполнено

$$\mathbb{P}_\theta(\theta \in T(\boldsymbol{X})) \geqslant 1 - \alpha$$

9.1 Метод центральной статистики

Одним из основных методов поиска доверительного интервала является метод *центральной статистики*. Данный метод применим в случае выборки $\boldsymbol{X}$ из абсолютно непрерывного распределения $\mathbb{P}_\theta$.

Определение 37 (Центральная статистика)**.** Функция от выборки $G(\boldsymbol{X}, \theta)$, которая может зависеть от параметра θ, называется *центральной статистикой*, если

- $G(\boldsymbol{X}, \theta)$ непрерывна и монотонна по θ при любом фиксированном $\boldsymbol{X}$;
- $\mathbb{P}_\theta(G(\boldsymbol{X}, \theta) \leqslant t) = F_G(t)$ – непрерывная функция по t, не зависящая от θ (т.е. распределение $G(\boldsymbol{X}, \theta)$ не зависит от θ).

Таким образом, если $G(\boldsymbol{X}, \theta)$ – центральная статистика, то множество $\{\theta : t_1 < G(\boldsymbol{X}, \theta) < t_2\}$ является интервалом. Заметьте, что формально центральная статистика не является статистикой с точки зрения определения 4, так как $G(\boldsymbol{X}, \theta)$ зависит от неизвестного параметра θ.

Если для конкретной задачи нам удалось построить центральную статистику $G(\boldsymbol{X}, \theta)$, то доверительные интервалы для параметра θ строятся следующим образом:

1. Фиксируются $t_1 < t_2 \in \mathbb{R}$ такие, что выполнено

$$\mathbb{P}_\theta(t_1 \leqslant G(\boldsymbol{X}, \theta) \leqslant t_2) = F_G(t_2) - F_G(t_1) = 1 - \alpha\,.$$

Точки t_1 и t_2 есть квантили в распределении F_G. Дадим определение $\gamma-$квантиля.

Определение 38 ($\gamma-$квантиль)**.** x_γ называется $\gamma-$квантилем некоторого распределения с функцией распределения F, если

$$F(x_\gamma) = \gamma$$

Заметим, что выбор точек t_1 и t_2 определен неоднозначно. Возьмем некоторую $0 < \gamma < \alpha$ и $t_1 = x_\gamma$, тогда $t_2 = x_{1-\alpha+\gamma}$, где x_γ и $x_{1-\alpha+\gamma}$ – это $\gamma-$квантиль и $1-\alpha+\gamma-$квантиль соответственно. Квантили могут быть найдены из соответствующих таблиц с квантилями или численно, например в python'e.

2. Из условий

$$\begin{cases} G(\mathbf{X}, \theta) = t_2 \\ G(\mathbf{X}, \theta) = t_1 \end{cases}$$

можно найти статистики $T_1(\mathbf{X}, t_1)$ и $T_2(\mathbf{X}, t_2)$, такие что

$$\begin{cases} G(\mathbf{X}, T_2(\mathbf{X}, t_2)) = t_2 \\ G(\mathbf{X}, T_1(\mathbf{X}, t_1)) = t_1\,. \end{cases}$$

Из неравенств выше и определения центральной статистики следует, что

$$\mathbb{P}_\theta(t_1 \leqslant G(\boldsymbol{X}, \theta) \leqslant t_2) = \mathbb{P}_\theta(T_1(\boldsymbol{X}, t_1) \leqslant \theta \leqslant T_2(\boldsymbol{X}, t_2)) = 1 - \alpha\,.$$

Таким образом, мы получили $1 - \alpha$–доверительный интервал $(T_1(\boldsymbol{X}, t_1), T_2(\boldsymbol{X}, t_2))$ для параметра $\theta \in \Theta$.

Для разрешения проблемы неоднозначности выбора границ t_1 и t_2, можно строить *центральные* доверительные интервалы. Но наилучшим же интервалом будет тот, у которого наименьшая длина, то есть наикратчайший интервал.

Определение 39 (Центральный интервал)**.** Доверительный интервал называют *центральным*, если

$$\mathbb{P}_\theta(G(\boldsymbol{X}, \theta) \leqslant t_1) = \mathbb{P}_\theta(G(\boldsymbol{X}, \theta) \geqslant t_2) = \frac{\alpha}{2}\,.$$

Для построения центрального доверительного интервала квантили выбираются следующим образом

$$t_1 = x_{\alpha/2}, \quad t_2 = x_{1-\alpha/2}.$$

Пример 24. Пусть у нас есть выборка $\boldsymbol{X} = (X_1, \ldots, X_n)$ из распределения $\mathcal{N}(\theta, \sigma^2)$ с известным параметром σ^2. Наша задача состоит в построении доверительного интервала для неизвестного математического ожидания θ. Часто центральная статистика строится на основе точечной оценки неизвестного параметра θ. В нормальной модели $\mathcal{N}(\theta, \sigma^2)$ математическое ожидание можно оценить методом максимального правдоподобия и получить

$\widehat{\theta}_{MLE} = \overline{X} \sim \mathcal{N}(\theta, \sigma^2/n)$. Для того чтобы получить распределение, не зависящее от неизвестного параметра, проведем стандартизацию, в результате чего получим центральную статистику:

$$G(\boldsymbol{X}, \theta) = \frac{\sqrt{n}(\overline{X} - \theta)}{\sigma},$$

которая имеет нормальное распределение $\mathcal{N}(0, 1)$. $G(\boldsymbol{X}, \theta)$ строго монотонна по θ и ее распределение не зависит от θ. Тогда необходимо выбрать t_1 и t_2, такие что

$$\mathbb{P}_\theta\left(t_1 < \frac{\sqrt{n}(\overline{X} - \theta)}{\sigma} < t_2\right) = \mathbb{P}_\theta\left(\overline{X} + \frac{t_1\sigma}{\sqrt{n}} < \theta < \overline{X} + \frac{t_2\sigma}{\sqrt{n}}\right) = 1 - \alpha\,.$$

Заметим, что в данном случае наикратчайший интервал будет совпадать с центральным. Для построения центрального доверительного интервала заметим, что распределение $G(\boldsymbol{X}, \theta)$ симметрично относительно 0. Тогда достаточно ввести один квантиль

$$t_1 = x_{\alpha/2}, \quad t_2 = x_{1-\alpha/2} = -x_{\alpha/2},$$

где $x_{\alpha/2}$ – $\alpha/2$-квантиль распределения $\mathcal{N}(0, 1)$. Искомый доверительный интервал будет иметь вид

$$\left(\overline{X} + \frac{\sigma}{\sqrt{n}}x_{\alpha/2},\ \overline{X} - \frac{\sigma}{\sqrt{n}}x_{\alpha/2}\right).$$

Пример 25. Пусть теперь математическое ожидание в нормальной модели будет известно, а дисперсия σ^2 нет. То есть дана выборка $X_1, \ldots, X_n$ из распределения $\mathcal{N}(\mu, \theta^2)$. Наша задача построить центральный доверительный интервал для θ^2. Неизвестная дисперсия может быть оценена с помощью выборочной дисперсии. Воспользуемся этой оценкой, а также информацией о том, что математическое ожидание нам известно и построим центральную статистику

$$G(\boldsymbol{X}, \theta) = \frac{1}{\theta^2}\sum_{i=1}^{n}(X_i - \mu)^2,$$

имеющую распределение хи-квадрат $\chi^2(n)$. Данная центральная статистика является строго монотонной функцией от θ^2, а также ее распределение не зависит от θ^2. Распределение $\chi^2(n)$ не симметрично, поэтому понадобятся два квантиля

$$t_1 = x_{\alpha/2}, \quad t_2 = x_{1-\alpha/2}$$

где $x_{\alpha/2}$ и $x_{1-\alpha/2}$ есть $\alpha/2$-квантиль и $1 - \alpha/2$-квантиль распределения χ^2 соответственно. Таким образом, получаем

$$\mathbb{P}_\theta\left(x_{\alpha/2} < \frac{1}{\theta^2}\sum_{i=1}^{n}(X_i - \mu)^2 < x_{1-\alpha/2}\right) = \mathbb{P}_\theta\left(\frac{\sum_{i=1}^{n}(X_i - \mu)^2}{x_{1-\alpha/2}} < \theta^2 < \frac{\sum_{i=1}^{n}(X_i - \mu)^2}{x_{\alpha/2}}\right).$$

То есть искомый доверительный интервал

$$\left(\frac{\sum_{i=1}^{n}(X_i - \mu)^2}{x_{1-\alpha/2}}, \frac{\sum_{i=1}^{n}(X_i - \mu)^2}{x_{\alpha/2}}\right)$$

9.2 Асимптотические доверительные интервалы

Не во всех задачах удается легко найти центральную статистику, распределение которой известно точно. Намного проще предъявить центральную статистику, у которой было бы известно лишь предельное распределение. Доверительные интервалы, построенные по предельному распределению, мы будем называть *асимптотическими*. Таким образом, в определении (35) неравенство (20) заменится на

$$\mathbb{P}_\theta(T_1(\boldsymbol{X}) < \theta < T_2(\boldsymbol{X})) \xrightarrow{n\to\infty} 1-\alpha.$$

Пусть размер выборки n достаточно большой. Покажем, как на основе асимптотически нормальной оценки $\widehat{\theta}$, то есть такой что

$$\frac{\sqrt{n}(\widehat{\theta}-\theta)}{\sigma(\theta)} \xrightarrow{d} \mathcal{N}(0,1), \quad \text{где } \sigma^2(\theta) \text{ – это асимптотическая дисперсия,}$$

можно строить асимптотические доверительные интервалы. Пусть $\sigma^2(\theta)$ непрерывна при любом $\theta \in \Theta$.

1. Покажем, что следующая величина будет иметь распределение $\mathcal{N}(0,1)$
$$\frac{\sqrt{n}(\widehat{\theta}-\theta)}{\sigma(\widehat{\theta})} = \frac{\sqrt{n}(\widehat{\theta}-\theta)}{\sigma(\theta)} \cdot \frac{\sigma(\theta)}{\sigma(\widehat{\theta})}.$$

2. Из определения асимптотической нормальности следует состоятельность $\widehat{\theta}$. Далее, пользуясь теоремой о наследовании сходимости 4, получаем
$$\sigma(\widehat{\theta}) \xrightarrow{\mathbb{P}} \sigma(\theta)$$

3. По лемме Слуцкого 2 и из определения асимптотической нормальности следует
$$\frac{\sqrt{n}(\widehat{\theta}-\theta)}{\sigma(\widehat{\theta})} \xrightarrow{d} \mathcal{N}(0,1).$$

4. Далее по аналогии с методом центральной статистики строим асимптотический интервал для $\frac{\sqrt{n}(\widehat{\theta}-\theta)}{\sigma(\widehat{\theta})}$
$$\mathbb{P}_\theta\left(x_{\alpha/2} < \frac{\sqrt{n}(\widehat{\theta}-\theta)}{\sigma(\widehat{\theta})} < -x_{\alpha/2}\right) \xrightarrow{n\to\infty} 1-\alpha,$$
где $x_{\alpha/2}$ есть $\alpha/2$-квантиль распределения $\mathcal{N}(0,1)$. Значит асимптотически доверительный интервал для θ есть
$$\left(\widehat{\theta} + \frac{\sigma(\widehat{\theta})}{\sqrt{n}}x_{\alpha/2},\ \widehat{\theta} - \frac{\sigma(\widehat{\theta})}{\sqrt{n}}x_{\alpha/2}\right).$$

Замечание 20. Если модель удовлетворяет условиям регулярности, то в качестве асимптотически нормальной оценки можно взять оценку максимального правдоподобия $\widehat{\theta}_{MLE}$. Тогда асимптотическая дисперсия может быть вычислена как $\sigma^2(\theta) = \frac{1}{i_1(\theta)}$ (см. теорему 6.2). Более того, так как $\widehat{\theta}_{MLE}$ обладает наименьшей асимптотической дисперсией, то и доверительный интервал, построенный с ее использованием, будет наикратчайший.

Пример 26. Пусть дана выборка $(X_1, \ldots, X_n)$ из распределения с Бернулли $\mathcal{B}\text{er}(\theta)$, $\theta \in (0,1)$. Оценкой максимального правдоподобия $\widehat{\theta}_{MLE} = \overline{X}$. В данном примере можно не искать асимптотическую дисперсию через информацию Фишера, так как она будет совпадать с дисперсией в распределении $\mathcal{B}\text{er}(\theta)$ по ЦПТ 1

$$\frac{\sqrt{n}(\overline{X} - \theta)}{\sqrt{\theta(1-\theta)}} \xrightarrow{d} \mathcal{N}(0,1).$$

Теперь рассмотрим

$$\frac{\sqrt{n}(\overline{X} - \theta)}{\sqrt{\overline{X}(1-\overline{X})}} = \frac{\sqrt{n}(\overline{X} - \theta)}{\sqrt{\theta(1-\theta)}} \cdot \frac{\sqrt{\theta(1-\theta)}}{\sqrt{\overline{X}(1-\overline{X})}}$$

Пользуясь теоремой о наследовании сходимости 4 и состоятельностью оценки $\widehat{\theta}_{MLE} = \overline{X}$, получаем

$$\sqrt{\overline{X}(1-\overline{X})} \xrightarrow{\mathbb{P}} \sqrt{\theta(1-\theta)}.$$

Тогда по лемме Слуцкого 2 произведение сойдется к $\mathcal{N}(0,1)$. Значит

$$\mathbb{P}_\theta\left(x_{\alpha/2} < \frac{\sqrt{n}(\overline{X} - \theta)}{\sqrt{\overline{X}(1-\overline{X})}} < -x_{\alpha/2} \right) \xrightarrow{n\to\infty} 1 - \alpha,$$

где $x_{\alpha/2}$ есть $\alpha/2$-квантиль распределения $\mathcal{N}(0,1)$. Далее осталось выразить θ и получить асимптотически доверительный интервал для θ

$$\left(\overline{X} + \sqrt{\frac{\overline{X}(1-\overline{X})}{n}} x_{\alpha/2},\ \overline{X} - \sqrt{\frac{\overline{X}(1-\overline{X})}{n}} x_{\alpha/2} \right)$$

10 Байесовский и минимаксный подходы к построению оценок

Ранее в курсе при рассмотрении задачи точечного оценивания параметров мы так или иначе подходили к вопросу со стороны равномерного подхода: одна оценка считается не хуже другой, если при всех θ ее риск не больше. Такой строгий подход к сравнению оценок накладывал существенные ограничения на класс оценок, среди которых мы ищем наилучшую.

На практике же зачастую у нас есть некоторые *априорные* предположения о том, как устроены возможные значения параметра. В классическом примере с оцениванием вероятности θ выпадения монетки орлом чисто теоретически параметр может принимать все значения в отрезке $[0, 1]$. С точки зрения же здравого смысла, θ скорее всего будет принимать близкие к $1/2$ значения, если мы знаем, что работаем с обычной монеткой, «нечестность» которой достигается разве что за счет неидеальной формы и других физических особенностей. В такой ситуации очень важно, чтобы оценка имела небольшой риск при значениях θ, близких к $1/2$. Риск же оценки при экстремальных θ несущественен. Проводя такие логические рассуждения, мы фактически присваиваем каждому значению θ некоторый «вес», соответствующий тому, насколько нам важно получить низкие значения риска при данном значении параметра. Разумной же задачей после введения весов становится нахождение оценки, минимизирующей взвешенную сумму рисков при разных значениях θ. Формализовать же понятие веса удобнее всего в виде вероятностного распределения, такое распределение называют *априорным* и обозначают $\pi(\theta)$. После того, как была сгенерирована выборка, можно обновить распределение $\pi(\theta)$ через условное $\pi(\theta|\boldsymbol{x})$, такое распределение называют *апостериорным*. Если априорное распределение $\pi(\theta)$ имеет интерпретацию наших изначальных представлений о том, какие значения параметра более и менее вероятные, то $\pi(\theta|\boldsymbol{x})$ представляет собой обновленные знания о θ, учитывающие информацию о параметре, содержащуюся в выборке.

Теорема Байеса позволяет связать априорное и апостериорное распределение. Алгоритм можно описать следующими действиями.

1. Введем априорное распределение на Θ с обобщенной плотностью $\pi(\theta)$. Распределение задает наши изначальные предположения о том, какое должно быть истинное значение неизвестного параметра θ

2. Сгенерируем выборку
$$X_1, \dots, X_n \sim p(x|\theta), \quad \theta \sim \pi(\theta).$$
Заметим, что сейчас мы обозначаем обобщенную плотность распределения, из которого была сгенерирована выборка, как условную плотность, потому что в отличие от классического случая, θ теперь случайная величина, а выборка генерируется по-прежнему из какого-то распределения с фиксированным значением θ.

3. Обновляем наши предположения о неизвестном параметре θ, вычисляя апостериорное распределение с обобщенной плотностью $\pi(\theta|\boldsymbol{x})$. По теореме Байеса условную плотность можно расписать следующим образом
$$\pi(\theta|\boldsymbol{x}) = \frac{p(\boldsymbol{x}|\theta)\pi(\theta)}{\int\limits_{\Theta} p(\boldsymbol{x}|\theta)\pi(\theta)\mathrm{d}\theta}. \tag{21}$$

Заметим, что условная плотность $p(\boldsymbol{x}|\theta)$ – это функция правдоподобия, если вместо $\boldsymbol{x}$ подставить выборку X. Тогда из (21) получаем, что апостериорная плотность должна быть прямо пропорциональна произведению функции правдоподобия на априорную обобщенную плотность

$$\pi(\theta|\boldsymbol{x}) \propto \mathcal{L}(\theta)\pi(\theta).$$

10.1 Байесовские оценки

В байесовском подходе в качестве оценки неизвестного параметра θ берется та оценка, которая минимизирует байесовский риск.

Определение 40 (Байесовский риск)**.** Пусть $\rho(\cdot,\cdot)$ — функция потерь и $R(\widehat{\theta}(\boldsymbol{X}),\theta) = \mathbb{E}_\theta\rho(\widehat{\theta}(\boldsymbol{X}),\theta)$ — соответствующий (классический) риск оценки $\widehat{\theta}(\boldsymbol{X})$. Байесовским риском для *априорного* распределения с плотностью $\pi(\theta)$ называется

$$B_\pi(\widehat{\theta}(\boldsymbol{X})) = \mathbb{E}R(\theta,\widehat{\theta}(\boldsymbol{X})) = \int\limits_\Theta R(\theta,\widehat{\theta}(\boldsymbol{X}))\pi(\theta)\mathrm{d}\theta. \tag{22}$$

Байесовский риск является естественной формализацией взвешенного подсчета риска, про который мы говорили выше. Априорное распределение $\pi(\theta)$ соответствует тем самым изначальным предположениям о том, какие значения параметра более и менее вероятны.

Определение 41 (Байесовская оценка)**.** Байесовской оценкой для априорного распределения $\pi(\theta)$ называется оценка $\widehat{\theta}_\pi(\boldsymbol{X})$, минимизирующая байесовский риск

$$\widehat{\theta}_\pi(\boldsymbol{X}) = \arg\min_{\widetilde{\theta}\in\Theta} B_\pi(\widetilde{\theta}).$$

Введем вспомогательное определение, которое позволяет наиболее простым способом находить байесовские оценки.

Определение 42 (Апостериориорные потери)**.** Пусть $\rho(\cdot,\cdot)$ – это функция потерь, тогда апостериорными потерями называется величина

$$r(\widehat{\theta}|\boldsymbol{x}) = \mathbb{E}[\rho(\theta,\widehat{\theta})|\mathbf{X}=\boldsymbol{x}] = \int_\Theta \rho(\theta,\widehat{\theta})\pi(\theta|\boldsymbol{x})\mathrm{d}\theta.$$

Теорема 19. *Определим оценку*

$$\widehat{\theta}(\boldsymbol{x}) = \arg\min_{\widetilde{\theta}} r(\widetilde{\theta}|\boldsymbol{x}),$$

тогда $\widehat{\theta}(\boldsymbol{x})$ *– байесовская оценка,*

Доказательство. Пусть $f(\boldsymbol{x},\theta)$ – это совместная плотность. Рассмотрим байесовский риск

$$\begin{aligned}
B_\pi(\widehat{\theta}(\boldsymbol{x})) &= \int\limits_\Theta R(\theta,\widehat{\theta}(\boldsymbol{x}))\pi(\theta)\mathrm{d}\theta = \int\limits_\Theta\int_{\mathcal{X}} \rho(\theta,\widehat{\theta}(\boldsymbol{x}))p(\boldsymbol{x}|\theta)\mathrm{d}\boldsymbol{x}\pi(\theta)\mathrm{d}\theta \\
&\int_\Theta\int_{\mathcal{X}} \rho(\theta,\widehat{\theta}(\boldsymbol{x}))f(\boldsymbol{x},\theta)\mathrm{d}\boldsymbol{x}\mathrm{d}\theta \\
&= \int_\Theta\int_{\mathcal{X}} \rho(\theta,\widehat{\theta}(\boldsymbol{x}))\pi(\theta|\boldsymbol{x})f(\boldsymbol{x})\mathrm{d}\boldsymbol{x}\mathrm{d}\theta \\
&= \int_{\mathcal{X}} r(\widehat{\theta}(\boldsymbol{x})|\boldsymbol{x})f(\boldsymbol{x})\mathrm{d}\boldsymbol{x}.
\end{aligned}$$

Для любого $\boldsymbol{x} \in \mathcal{X}$ определим

$$\widehat{\theta}(\boldsymbol{x}) = \arg\min_{\widetilde{\theta}} r(\widetilde{\theta}|\boldsymbol{x}).$$

Значит она будет минимизировать и $\int_{\mathcal{X}} r(\widehat{\theta}(\boldsymbol{x})|\boldsymbol{x}) f(\boldsymbol{x}) \mathrm{d}\boldsymbol{x}$, то есть $\widehat{\theta}(\boldsymbol{x})$ – байесовская. □

Для заданного априорного распределения $\pi(\theta)$ нужно найти соответствующую байесовскую оценку $\widehat{\theta}_\pi(\boldsymbol{X})$. Но как ее искать? В общем случае это сложный вопрос, но если $\Theta \subset \mathbb{R}^n$, а функция потерь ρ квадратичная, то байесовская оценка будет равняться математическому ожиданию апостериорного распределения (апостериорному среднему). Для простоты, далее мы будем считать, что $\Theta \subset \mathbb{R}$.

Теорема 20. *Пусть выбрана квадратичная функция потерь $\rho(\theta, \widehat{\theta}) = (\theta - \widehat{\theta})^2$. Тогда байесовской оценка – это апостериорное среднее*

$$\widehat{\theta}_\pi(\boldsymbol{x}) = \int_\Theta \theta \pi(\theta|\boldsymbol{x}) \mathrm{d}\theta. \tag{23}$$

Доказательство. Воспользуемся теоремой (19) и тем фактом, что потери квадратичные

$$\widehat{\theta}_\pi(\boldsymbol{x}) = \arg\min_{\widetilde{\theta}} r(\widetilde{\theta}|\boldsymbol{x}) = \arg\min_{\widetilde{\theta}} \int_\Theta (\theta - \widetilde{\theta})^2 \pi(\theta|\boldsymbol{x}) \mathrm{d}\theta.$$

Продифференцируем по $\widetilde{\theta}$

$$\int_\Theta 2(\theta - \widetilde{\theta}) \pi(\theta|\boldsymbol{x}) \mathrm{d}\theta = 0.$$

Теперь выразим $\widetilde{\theta}$

$$\widetilde{\theta} = \frac{\int_\Theta \theta \pi(\theta|\boldsymbol{x}) \mathrm{d}\theta}{\int_\Theta \pi(\theta|\boldsymbol{x}) \mathrm{d}\theta} = \int_\Theta \theta \pi(\theta|\boldsymbol{x}) \mathrm{d}\theta.$$

□

Замечание 21. Если π — дискретное распределение, то апостериорная плотность и байесовская оценка переписываются через суммы:

$$\pi(\theta|\boldsymbol{x}) = \frac{p(\boldsymbol{x}|\theta)\pi(\theta)}{\sum\limits_\theta p(\boldsymbol{x}|\theta)\pi(\theta)};$$

$$\widehat{\theta}_\pi(\boldsymbol{x}) = \sum_\theta \theta \pi(\theta|\boldsymbol{x}).$$

10.2 Сопряженные распределения

Существенным ограничением в байесовском подходе являются вычислительные аспекты – нужно взять интеграл в знаменателе, чтобы посчитать апостериорную плотность. Если параметр θ имеет большую размерность, задача подсчета интеграла становится очень трудоемкой, поэтому хотелось бы иметь какой-то способ этот подсчет избегать. Один из таких способов — рассматривать задачу байесовского оценивания для определенного класса априорных распределений, называющихся *сопряженными*.

Определение 43 (Сопряжённые априорные распределения)**.** Если апостериорное распределение $\pi(\theta|\boldsymbol{x})$ принадлежит тому же семейству вероятностных распределений, что и априорное распределение $\pi(\theta)$ (т.е. имеет тот же вид, но с другими параметрами), то это семейство распределений называется сопряжённым семейству функций правдоподобия $p(\boldsymbol{x}|\theta)$. При этом распределение $\pi(\theta)$ называется сопряжённым априорным распределением к семейству функций правдоподобия $\pi(\theta|\boldsymbol{x})$.

Пример 27. Пусть $\boldsymbol{X}$ — выборка из распределения Бернулли $\mathrm{Ber}(\theta)$. Покажем, что семейство бета-распределений является сопряженным к семейству распределений Бернулли и найдем байесовскую оценку параметра θ.

Решение. В качестве априорного распределения возьмем бета-распределение $\mathrm{Beta}(\alpha, \beta)$ с известными произвольными параметрами α, β и посчитаем апостериорную плотность. Начинаем, как обычно, с совместной

$$\begin{aligned} p(\boldsymbol{X}|\theta)\pi(\theta) = \mathcal{L}(\theta)q(\theta) &= \theta^{\sum_i X_i}(1-\theta)^{n-\sum_i X_i} \cdot \frac{1}{\mathrm{B}(\alpha,\beta)} t^{\alpha-1}(1-\theta)^{\beta-1} \\ &= \frac{1}{\mathrm{B}(\alpha,\beta)} t^{\sum_i X_i+\alpha-1}(1-t)^{n-\sum_i X_i+\beta-1}. \end{aligned}$$

Получилось что-то очень похожее на плотность бета-распределения: на самом деле это в точности плотность распределения $\mathrm{Beta}(\sum_i X_i + \alpha, n - \sum_i X_i + \beta)$, только умноженная на нормировочную константу, не зависящую от θ.

Замечательно здесь то, что совместная плотность в свою очередь отличается от апостериорной плотности делением на $\int_\Theta p(\boldsymbol{X}|\theta)\pi(\theta)\mathrm{d}\theta$, величину, не зависящую от t. Тогда апостериорная плотность тоже отличается от плотности $\mathrm{Beta}(\sum_i X_i + \alpha, n - \sum_i X_i + \beta)$ домножением на константу. Но если две плотности $p_1(\theta)$ и $p_2(\theta)$ отличаются домножением на константу C, то $C = 1$, так как

$$\int\limits_\Theta p_1(\theta)\mathrm{d}\theta = \int\limits_\Theta p_2(\theta)\mathrm{d}\theta = 1.$$

Значит, $\pi(\cdot|\boldsymbol{X}) = \mathrm{Beta}(\sum_i X_i + \alpha, n - \sum_i X_i + \beta)$, то есть апостериорное распределение лежит в том же семействе, что и априорное, и семейства действительно сопряжены.

Наконец, зная, что байесовская оценка — математического ожидания апостериорного распределения, достаточно вспомнить математического ожидания произвольного бета-распределения. Для $\xi \sim \mathrm{Beta}(\alpha, \beta)$ верно $\mathbb{E}\xi = \frac{\alpha}{\alpha+\beta}$. Тогда байесовская оценка равна

$$\widehat{\theta}_\pi(\boldsymbol{X}) = \frac{\sum_i X_i + \alpha}{\sum_i X_i + \alpha + n - \sum_i X_i + \beta} = \frac{\sum_i X_i + \alpha}{n + \alpha + \beta}.$$

Примечательно здесь то, что байесовская оценка является выпуклой комбинацией оценки максимального правдоподобия $\overline{X}$ и математического ожидания априорного распределения $\alpha/(\alpha+\beta)$

$$\widehat{\theta}_\pi(\boldsymbol{X}) = \frac{n}{n+\alpha+\beta} \cdot \overline{X} + \frac{\alpha+\beta}{n+\alpha+\beta} \cdot \frac{\alpha}{\alpha+\beta}.$$

□

10.3 Интервальное оценивание в байесовской статистике

Байесовская статистика позволяет довольно интуитивно строить доверительные интервалы. Поскольку неизвестный параметр θ рассматривается как случайная величина, то интервал для него может быть построен напрямую через вероятность попадания в этот интервал. В качестве интервала может быть взят любой I_α, удовлетворяющий данному равенству

$$\mathbb{P}(\theta \in I_\alpha | \mathbf{X}) = \int_{I_\alpha} \pi(\theta|\mathbf{X}) \mathrm{d}\theta = 1 - \alpha.$$

В отличие от классической статистики, интервал I_α фиксированный (не случайный) при условии фиксированной выборки. В качестве I_α можно выбрать

$$I_\alpha = (\theta_{\alpha/2}, \theta_{1-\alpha/2}),$$

где $\theta_{\alpha/2}, \theta_{1-\alpha/2}$ – это $\alpha/2$ и $1-\alpha/2$ -квантили апостериорного распределения $\pi(\theta|\mathbf{X})$ соответственно.

10.4 Минимаксные оценки

Если априорная информация об оцениваемом параметре θ отсутствует, для построения оценки можно использовать так называемый *минимаксный подход*, при котором за меру точности оценки принимается максимальное значение ее риска, или максимальный риск.

Определение 44 (Максимальный риск)**.**

$$R_{\max}(\widehat{\theta}) = \sup_{\theta \in \Theta} R(\theta, \widehat{\theta}).$$

Определение 45 (Минимаксная оценка)**.**

$$\widehat{\theta} = \arg\inf_{\widetilde{\theta}} R_{\max}(\widetilde{\theta}) = \arg\inf_{\widetilde{\theta}} \sup_{\theta \in \Theta} R(\theta, \widetilde{\theta})$$

В общем случае вопрос об отыскании такой оценки весьма трудный, но в ряде случаев она может быть найдена через байесовскую оценку: предположим, что существует априорное распределение $\pi(\theta) > 0$, для которого соответствующая байесовская оценка $\widehat{\theta}_\pi$ имеет постоянный риск ($R(\theta, \widehat{\theta}_\pi) = \mathrm{const}$), тогда минимаксная оценка будет байесовской оценкой $\widehat{\theta}_\pi$. Вспомним также, что, например, в случае квадратичных потерь байесовская оценка может быть достаточно просто найдена, а именно как математическое ожидание апостериорного распределения.

Теорема 21. *Пусть $\widehat{\theta}_\pi$ – байесовская оценка для некоторого априорного распределения $\pi(\theta) > 0$ и для всех $\theta \in \Theta$*

$$R(\theta, \widehat{\theta}_\pi) \leqslant B_\pi(\widehat{\theta}_\pi),$$

то $\widehat{\theta}_\pi$ будет минимаксной оценкой, а соответствующее распределение π будет называться наименее благоприятным распределением.

Доказательство. От противного: пусть $\widehat{\theta}_\pi$ не минимаксная оценка, значит существует $\widehat{\theta}_0$ такая, что

$$R_{\max}(\widehat{\theta}_0) < R_{\max}(\widehat{\theta}_\pi). \tag{24}$$

Поскольку максимальное значение всегда не меньше (взвешенного) среднего, то для любой оценки, а значит и для $\widehat{\theta}_0$

$$B_\pi(\widehat{\theta}_0) \leqslant R_{\max}(\widehat{\theta}_0). \tag{25}$$

По условию для всех $\theta \in \Theta$, $R(\theta, \widehat{\theta}_\pi) \leqslant B_\pi(\widehat{\theta}_\pi)$, значит

$$R_{\max}(\widehat{\theta}_\pi) \leqslant B_\pi(\widehat{\theta}_\pi). \tag{26}$$

Используем (25) и (26) для (24)

$$B_\pi(\widehat{\theta}_0) \leqslant R_{\max}(\widehat{\theta}_0) < R_{\max}(\widehat{\theta}_\pi) \leqslant B_\pi(\widehat{\theta}_\pi).$$

Значит, $\widehat{\theta}_\pi$ не может быть байесовской оценкой, поскольку байесовский риск для оценки $\widehat{\theta}_0$ меньше. Получили противоречие, значит $\widehat{\theta}_\pi$ – минимаксная оценка. □

Замечание 22. Термин *наименее благоприятное распределение* отражает следующую особенность такого априорного распределения. Рассмотрим байесовский риск при любом другом априорном распределении π', тогда

$$B_{\pi'}(\widehat{\theta}_\pi) = \int_\Theta R(\theta, \widehat{\theta}_\pi)\pi'(\theta)\mathrm{d}\theta \leqslant \int_\Theta B_\pi(\widehat{\theta}_\pi)\pi'(\theta)\mathrm{d}\theta = B_\pi(\widehat{\theta}_\pi)\int_\Theta \pi'(\theta)\mathrm{d}\theta = B_\pi(\widehat{\theta}_\pi).$$

То есть байесовский риск оценки $\widehat{\theta}_\pi$ при произвольном априорном распределении π' не хуже, чем при априорном распределении π. Поэтому говорят, что распределение π доставляет наибольшие (взвешенные) средние потери.

Замечание 23. Отметим, что в условиях теоремы 21 должно выполняться равенство

$$R(\theta, \widehat{\theta}_\pi) = B_\pi(\widehat{\theta}_\pi),$$

почти наверное.

Следствие 5. *Пусть $\widehat{\theta}_\pi$ – байесовская оценка для некоторого априорного распределения $\pi(\theta) > 0$ и для всех $\theta \in \Theta$*

$$R(\theta, \widehat{\theta}_\pi) = \mathrm{const},$$

то $\widehat{\theta}_\pi$ будет минимаксной оценкой, а соответствующее распределение π будет называться наименее благоприятным распределением.

Доказательство. Рассмотрим

$$B_\pi(\widehat{\theta}_\pi) = \int_\Theta R(\theta, \widehat{\theta}_\pi)\pi(\theta)\mathrm{d}\theta = \mathrm{const}\int_\Theta \pi(\theta)\mathrm{d}\theta = \mathrm{const}.$$

Далее применяем теорему (21), так как $R(\theta, \widehat{\theta}_\pi) \leqslant B_\pi(\widehat{\theta}_\pi) = \mathrm{const}$. □

Однако не всегда минимаксная оценка будет байесовская. В таком случае весьма полезной может оказаться следующая теорема.

Теорема 22. *Пусть $\pi_m(\theta)$ – последовательность из m априорных распределений таких, что*

$$r_m := \inf_{\widetilde{\theta}} B_{\pi_m}(\widetilde{\theta}) \xrightarrow{m\to\infty} r < \infty.$$

Пусть существует оценка $\widehat{\theta}$ такая, что

$$R_{\max}(\widehat{\theta}) = r.$$

Тогда $\widehat{\theta}$ – минимаксная оценка.

Доказательство. От противного: пусть $\widehat{\theta}$ не минимаксная оценка, значит существует $\widehat{\theta}_0$ такая, что

$$R_{\max}(\widehat{\theta}_0) < R_{\max}(\widehat{\theta}). \tag{27}$$

Поскольку максимальное значение всегда не меньше (взвешенного) среднего, то для любой оценки, а значит и для $\widehat{\theta}_0$

$$R_{\max}(\widehat{\theta}_0) \geqslant B_{\pi_m}(\widehat{\theta}_0) \geqslant \inf_{\widetilde{\theta}} B_{\pi_m}(\widetilde{\theta}) := r_m \xrightarrow{m\to\infty} r = R_{\max}(\widehat{\theta}). \tag{28}$$

Получили противоречие с (27), значит значит $\widehat{\theta}$ – минимаксная оценка. □

10.5 Три подхода в сравнении оценок

Рассмотрим две оценки $\widehat{\theta}_1$ и $\widehat{\theta}_2$, для которых функция риска изображена на графике 2.

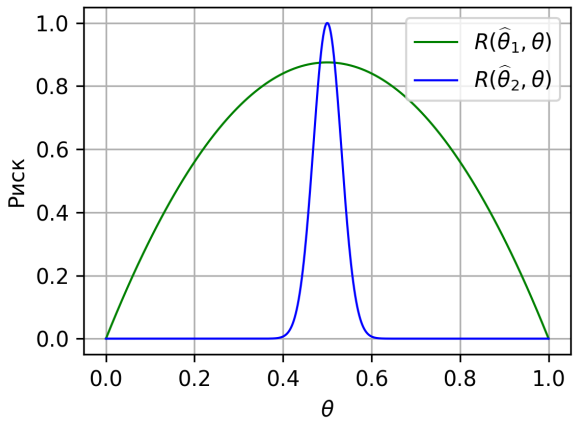


Рис. 2: График функции риска

1. **Равномерный подход:** это наш классический подход к сравнению оценок, который мы изучали в самом начале курса. При данном подходе все значения неизвестного параметра θ считаются равновероятными и оценка $\widehat{\theta}_1$ лучше, чем $\widehat{\theta}_2$ если для всех значений $\theta \in \Theta$

$$R(\widehat{\theta}_1, \theta) \leqslant R(\widehat{\theta}_2, \theta)$$

и существует хотя бы одно значение θ, при котором знак неравенства строгий. В данном подходе для рисунка 2 нельзя сказать какая оценка лучше: $\widehat{\theta}_1$ или $\widehat{\theta}_2$. Более того, в классе всех возможных оценок наилучшей оценки вообще не существует при данном подходе, поэтому мы ограничивались лишь рассмотрением класса несмещенных оценок.

2. **Байесовский подход:** мы предполагаем некоторые значения параметра θ более вероятными, чем другие и выражаем это через априорное распределение $\pi(\theta)$. В этом подходе главное, чтобы риск был меньше на наиболее вероятных значениях θ. Здесь сравниваем $B_\pi(\widehat{\theta}_1) = \mathbb{E}R(\widehat{\theta}_1, \theta)$ и $B_\pi(\widehat{\theta}_2) = \mathbb{E}R(\widehat{\theta}_2, \theta)$. Если, например, более вероятны значения в окрестности 0.5, то может получиться, что оценка $\widehat{\theta}_1$ лучше, чем $\widehat{\theta}_2$. Если же в качестве априорного распределения взять равномерное, то оценка $\widehat{\theta}_2$ будет лучше, чем $\widehat{\theta}_1$, поскольку в этом случае байесовский риск будет равняться площади под графиком

$$B_\pi(\widehat{\theta}) = \mathbb{E}R(\widehat{\theta}, \theta) = \int_\Theta R(\widehat{\theta}, \theta)\pi(\theta)\mathrm{d}\theta = \mathrm{const}\int_\Theta R(\widehat{\theta}, \theta)\mathrm{d}\theta$$

3. **Минимаксный подход:** мы стремимся избегать больших рисков, поэтому мы сравниваем оценки через максимальное значение риска. В данном подходе оценка $\widehat{\theta}_1$ будет лучше, чем $\widehat{\theta}_2$. Данный пример показывает несовершенство максимального подхода, потому что в данном примере он противоречит интуиции: априорная информация о параметре θ неизвестна, и за исключением малой окрестности вблизи 0.5 риск оценки $\widehat{\theta}_2$ почти равен нулю.

11 Проверка статистических гипотез

До сих пор нашей основной задачей было оценивание неизвестных параметров распределений. Разумеется, статистика не исчерпывается подобными задачами. Часто на практике возникает необходимость проверки тех или иных утверждений о виде и свойствах распределения наблюдаемых случайных величин, такие утверждения называются *статистическими гипотезами*. В общем случае задача проверки статистических гипотез формулируется следующим образом. Пусть дана выборка $\boldsymbol{X} = (X_1, \ldots, X_n)$ из некоторого распределения $\mathbb{P}$. Известно, что данное распределение принадлежит некоторому классу распределений $\mathcal{P}$, $\mathbb{P}_{\boldsymbol{X}} \in \mathcal{P}$. Например, в задаче параметрического оценивания $\mathcal{P} = \{\mathbb{P}_\theta\}_{\theta\in\Theta}$, однако в общем случае $\mathcal{P}$ может быть устроено и значительно сложнее. В классе распределений $\mathcal{P}$ выделяется некоторое подмножество $\mathcal{P}_0 \subset \mathcal{P}$, и требуется по выборке $\boldsymbol{X}$ проверить, справедливо ли утверждение

$$H_0 : \mathbb{P} \in \mathcal{P}_0 \,.$$

В этом случае утверждение H_0 называется *основной (нулевой) гипотезой*. При этом противоположное утверждение

$$H_1 : \mathbb{P} \in \mathcal{P} \setminus \mathcal{P}_0$$

называется *альтернативной* гипотезой. В таком случае также говорят, что проверяется гипотеза H_0 против альтернативы H_1. Если подмножество $\mathcal{P}_0$ состоит из одного элемента, то H_0 называется *простой* гипотезой, в противном случае – *сложной* гипотезой. При проверки гипотезы на основании наблюдения выборки $\boldsymbol{X}$ мы либо отклоняем гипотезу H_0 как ложную, т.е. принимаем альтернативную гипотезу H_1, либо не отклоняем H_0. Правило, в соответствии с которым мы делаем выбор в пользу одной из гипотез называется *статистическим критерием*

$$\delta : \mathcal{X} \to \{H_0, H_1\}.$$

Представим выборочное пространство $\mathcal{X}$ как объединение двух непересекающихся множеств $\mathcal{X}_0$ и $\mathcal{X}_1$, где $\mathcal{X}_1$ – область отклонения, а $\mathcal{X}_0$ – область не отклонения. То есть

- $\mathcal{X} = \mathcal{X}_0 \cup \mathcal{X}_1$
- $\mathcal{X}_0 \cap \mathcal{X}_1 = \emptyset$

Множество $\mathcal{X}_1$ мы будем называть *критической областью*. Таким образом,

$$H_0 \text{ отвергается} \quad \Longleftrightarrow \quad \boldsymbol{x} \in \mathcal{X}_1,$$

то есть мы отвергаем основную гипотезу тогда и только тогда, когда наблюдаемые случайные величины попали в критическую область. При построении статистических критериев используется общий подход: в качестве критической области $\mathcal{X}_1$ выбирается такое подмножество выборочного пространства, попадание в которое маловероятно при $\mathbb{P} \in \mathcal{P}_0$, то есть если H_0 верна.

В конкретных задачах критическая область обычно задается с помощью некоторой *тестовой статистики* $T(\mathbf{X})$, которая измеряет отклонение эмпирических данных от гипотетических (соответствующее гипотезе H_0). Распределение $T(\mathbf{X})$ должно быть известно точно или хотя бы приближенно (для больших выборок). В частности, если гипотеза H_0 сложная, то желательно, чтобы распределение $T(\mathbf{X})$ было одним и тем же для всех $\mathbb{P} \in \mathcal{P}_0$.

11.1 Ошибки первого и второго рода, уровень значимости.

Вывод, сделанный на основе статистического критерия, не обязательно оказывается правильным. Например, может оказаться, что статистический критерий отверг гипотезу H_0, хотя она была верна. Либо наоборот принял решение в пользу основной гипотезы, в то время как на самом деле имеет место альтернативная. Таким образом, приходим к понятию ошибок первого и второго рода.

Определение 46 (Ошибки 1-го и 2-го рода)**.** Пусть выдвинута основная гипотеза H_0 против альтернативны гипотеза H_1. Рассмотрим статистический критерий δ. Вероятность того, что мы отвергнем верную гипотезу H_0 называется вероятностью *ошибки первого рода*

$$\alpha(\delta) = \mathbb{P}_{H_0}(\delta(\mathbf{X}) = H_1) = \mathbb{P}_{H_0}(\mathbf{X} \in \mathcal{X}_1).$$

Вероятность того, что мы не отвергнем неверную гипотезу H_0 называется вероятностью *ошибки второго рода*

$$\beta(\delta) = \mathbb{P}_{H_1}(\delta(\mathbf{X}) = H_0) = \mathbb{P}_{H_1}(\mathbf{X} \notin \mathcal{X}_1).$$

Как было сказано ранее, статистический критерий составляется таким образом, чтобы вероятность отвергнуть основную гипотезу при ее справедливости была небольшой. Обычно фиксируется некоторая верхняя граница ошибки первого рода.

Определение 47 (Уровень значимости)**.** Пусть выдвинута гипотеза $H_0 : \mathbb{P} \in \mathcal{P}_0$, и пусть дан статистический критерий δ. Если $\alpha(\delta) \leqslant \alpha_0$ при всех $\mathbb{P} \in \mathcal{P}_0$, то говорят, что критерий δ имеет уровень значимости α_0.

Если гипотеза H_0 простая, то понятия уровня значимости критерия α_0 и ошибки первого рода $\alpha(\delta)$ совпадают. В случае сложной основной гипотезы это не так.

11.2 Параметрические гипотезы.

В ряде задач, например, в задаче параметрического оценивания, класс допустимых распределений $\mathcal{P}$ наблюдаемых случайных величин является параметрическим $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$. Пусть Θ_0 и Θ_1 – непустые непересекающиеся подмножества Θ. Далее будем рассматривать задачу проверки гипотезы вида

$$H_0 : \theta \in \Theta_0$$

против альтернативы

$$H_1 : \theta \in \Theta_1$$

Параметрическая модель позволяет учитывать дополнительные аспекты при построении статистических критериев, например, вычислять функцию мощности.

Определение 48 (Функция мощности)**.** Функция

$$W(\delta, \theta) = \mathbb{P}_\theta(\delta(\mathbf{X}) = H_1) = \mathbb{P}_\theta(\mathbf{X} \in \mathcal{X}_1), \quad \theta \in \Theta$$

называется функцией мощности.

Определение 49 (Мощность)**.** Функция

$$W(\delta,\theta)=\mathbb{P}_\theta(\delta(\mathbf{X})=H_1)=\mathbb{P}_\theta(\mathbf{X}\in\mathcal{X}_1),\quad \theta\in\Theta_1$$

называется мощностью.

Заметим, что если $\theta\in\Theta_0$, то функция мощности совпадает с ошибкой первого рода; если $\theta\in\Theta_1$ – с мощностью критерия, равной $1-\beta(\delta)$, где $\beta(\delta)$ – ошибка второго рода. Функция мощности позволяет сравнивать критерии одинакового уровня значимости: из двух критериев с одинаковым уровнем значимости лучше тот, мощность которого выше. Если альтернатива сложная (Θ_1 состоит больше, чем из одной точки), то как и при сравнении оценок возникает проблема сравнения двух функций $W(\theta,\delta_1)$ и $W(\theta,\delta_2)$. В случае если и сама гипотеза, и альтернатива простые, то такая проблема отсутствует можно и построить наиболее мощный критерий. В общем случае задача построения наилучшего критерия формулируется как задача оптимизации

$$\max_\delta W(\delta,\theta),\quad \theta\in\Theta_1,\quad \text{при условии } W(\delta,\theta)\leqslant\alpha_0,\quad \theta\in\Theta_0.$$

Также для нас будет полезно следующее свойство критериев.

Определение 50 (Несмещенность критерия)**.** Статистический критерий δ уровня значимости α_0, то есть $W(\delta,\theta)\leqslant\alpha_0,\theta\in\Theta_0$, называется несмещенным, если

$$W(\delta,\theta)\geqslant\alpha_0,\quad \theta\in\Theta_1.$$

Несмещенность означает, что попадание в критическое множество $\mathcal{X}_1$ (а следовательно и отвержение гипотезы H_0) при справедливости любой из альтернатив не менее вероятно, чем попадание в него при справедливости H_0, то есть правильное отвержение имеет не меньшую вероятность, чем неправильное.

Определение 51 (Состоятельность критерия)**.** Пусть $\mathbf{X}=(X_1,\dots,X_n)$ – выборка объема n. Статистический критерий δ уровня значимости α_0 называется состоятельным, если

$$W(\delta,\theta)\xrightarrow{n\to\infty}1,\quad \theta\in\Theta_1.$$

Состоятельность означает, что если истинной является некоторая альтернатива, то при большом числе наблюдений мы будем попадать в критическую область с вероятностью, близкой к 1, то есть отклоняя нулевую гипотезу, мы будем принимать правильное решение.

Пример 28. Пусть дана выборка $\mathbf{X}=(X_1,\dots,X_n)$ из нормального распределения $\mathcal{N}(\theta,\sigma^2)$. Построить критерий для проверки гипотезы $H_0:\theta=\theta_0$ против альтернативы $H_1:\theta=\theta_1$ ($\theta_1>\theta_0$) на уровне значимости $\alpha\in(0,1)$. Найти мощность этого критерия.

Доказательство. В данной задаче логика подсказывает выбрать выборочное среднее в качестве тестовой статистики:

$$T(\mathbf{X})=\overline{X}\sim\mathcal{N}(\theta,\sigma^2/n).$$

Тогда критическое множество может быть задано

$$\mathcal{X}_1=\{\boldsymbol{x}\in X:\overline{X}\geqslant t_\alpha\},$$

где порог t_α выбирается из уровня значимости критерия:

$$\mathbb{P}_{\theta_0}(\overline{X} > t_\alpha) = \alpha.$$

При справедливости H_0 $\overline{X} \sim \mathcal{N}(\theta_0, \sigma^2/n)$. Тогда

$$\alpha = \mathbb{P}_{\theta_0}\left(\frac{\sqrt{n}(\overline{X} - \theta_0)}{\sigma} > \frac{\sqrt{n}(t_\alpha - \theta_0)}{\sigma}\right) = 1 - \Phi\left(\frac{\sqrt{n}(t_\alpha - \theta_0)}{\sigma}\right),$$

где Φ – функция распределения стандартного нормального распределения. Значит

$$\frac{\sqrt{n}(t_\alpha - \theta_0)}{\sigma} = z_{1-\alpha},$$

где $z_{1-\alpha}$ — квантиль стандартного нормального распределения. Отсюда:

$$t_\alpha = \theta_0 + \frac{\sigma}{\sqrt{n}} z_{1-\alpha}.$$

Заметим, что критическая граница не зависит от альтернативы, а зависит лишь от знака $\theta_1 > \theta_0$. Значит, для задачи с односторонней альтернативой $\theta > \theta_0$ критерий будет точно такой же.

Рассчитаем мощность критерия, используя распределение при альтернативе $\overline{X} \sim \mathcal{N}(\theta_1, \sigma^2/n)$

$$W(\theta_1) = \mathbb{P}_{\theta_1}(\overline{X} > t_\alpha) = \mathbb{P}_{\theta_1}\left(\frac{\sqrt{n}(\overline{X} - \theta_1)}{\sigma} > \frac{\sqrt{n}(t_\alpha - \theta_1}{\sigma}\right) = 1 - \Phi\left(\frac{\sqrt{n}(t_\alpha - \theta_1)}{\sigma}\right).$$

Подставляя $t_\alpha = \theta_0 + \frac{\sigma}{\sqrt{n}} z_{1-\alpha}$, получаем:

$$W(\theta_1) = 1 - \Phi\left(\frac{\sqrt{n}(\theta_0 - \theta_1)}{\sigma} + z_{1-\alpha}\right).$$

□

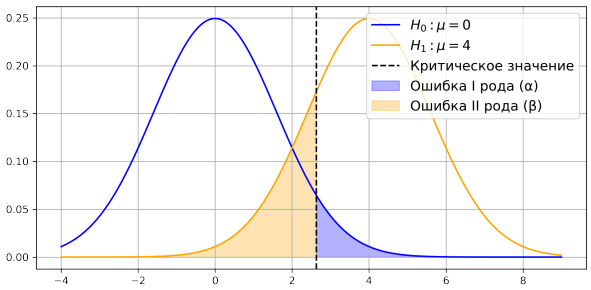


Рис. 3: Ошибки 1-го и 2-го рода

12 Критерий Неймана-Пирсона

12.1 Простые гипотезы

Рассмотрим параметрическую модель

$$\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}.$$

Пусть мы имеем дело с простой гипотезой и простой альтернативой, то есть когда $\Theta_0 = \{\theta_0\}$, а $\Theta_1 = \{\theta_1\}$

$$\begin{aligned} &H_0 : \theta = \theta_0; \\ &H_1 : \theta = \theta_1 \ (\theta_1 > \theta_0). \end{aligned} \tag{29}$$

Оказывается, что для данной задачи при любом $\alpha \in (0, 1)$ можно построить наиболее мощный критерий уровня значимости α.

Пусть дана простая выборка $\mathbf{X} = (X_1, \ldots, X_n)$ из распределения $\mathbb{P}$, и рассмотрим следующую задачу проверки простой гипотезы против простой альтернативы

$$H_0 : \mathbb{P} = \mathbb{P}_0; \tag{30}$$
$$H_1 : \mathbb{P} = \mathbb{P}_1. \tag{31}$$

Данная задача также относится к параметрическим, так как семейство $\{\mathbb{P}_0, \mathbb{P}_1\}$, состоящее всего из двух элементов, можно представить в виде

$$\{\mathbb{P}_0, \mathbb{P}_1\} = \{\mathbb{P}_\theta = \theta\mathbb{P}_1 + (1 - \theta)\mathbb{P}_0, \theta \in \{0, 1\}\}.$$

Тогда задача (30) сведется к параметрической

$$\begin{aligned} &H_0 : \theta = 0; \\ &H_1 : \theta = 1. \end{aligned}$$

Непрерывный случай. Рассмотрим непрерывный случай, когда оба распределения $\mathbb{P}_{\theta_0}, \mathbb{P}_{\theta_1}$ – абсолютно непрерывны с соответствующими плотностями p_{θ_0} и p_{θ_1}.

Определение 52 (Статистика отношения правдоподобий)**.** Статистикой отношения правдоподобий называется статистика

$$\Lambda(\boldsymbol{x}) = \frac{p_{\theta_1}(\boldsymbol{x})}{p_{\theta_0}(\boldsymbol{x})} = \frac{\prod_{i=1}^n p_{\theta_1}(x_i)}{\prod_{i=1}^n p_{\theta_0}(x_i)}.$$

Большие значения этой статистики будут свидетельствовать о том, что значение θ_1 более вероятно, чем значение θ_0. Критерий, построенный на основе статистики отношения правдоподобия, будем называть критерием Неймана-Пирсона. Рассмотрим ошибку 1-го рода и введем функцию

$$\varphi(t) = \mathbb{P}_{\theta_0}(\Lambda(\mathbf{X}) \geqslant t) \tag{32}$$

и предположим, что она непрерывна.

Теорема 23 (Нейман, Пирсон)**.** *Пусть дана выборка* $\mathbf{X} = (X_1, \ldots, X_n)$ *из распределения* $\mathbb{P}_\theta, \theta = \{\theta_0, \theta_1\}$. *Пусть* $p_{\theta_0}, p_{\theta_1} > 0$. *Допустим, что функция* φ, *определенная в* (32) *непрерывна. Зафиксируем произвольное* $\alpha \in (0,1)$ *и найдем* $t_\alpha \geqslant 0$, *удовлетворяющее равенству* $\varphi(t_\alpha) = \alpha$ *для* φ, *определенной в* (32). *Тогда в задаче* (29) *статистический критерий* δ^* *с критической областью*

$$\mathcal{X}_1^* = \{\boldsymbol{x} \in \mathbb{R}^n \mid \Lambda(\boldsymbol{x}) \geqslant t_\alpha\} \tag{33}$$

является наиболее мощным среди всех критериев уровня значимости α.

Доказательство. Пусть δ^* – это критерий Неймана-Пирсона с критической областью $\mathcal{X}_1^*$, а $\delta(\mathbf{X})$ – любой другой критерий уровня значимости α с критической областью $\mathcal{X}_1$. Тогда нужно показать

$$W(\delta^*, \theta_1) \geqslant W(\delta, \theta_1).$$

Во-первых, в силу определения t_α, критерий δ^* удовлетворяет равенству

$$\alpha(\delta^*) = \mathbb{P}_{\theta_0}(\delta^*(\mathbf{X}) = H_1) = \mathbb{P}_{\theta_0}(\mathbf{X} \in \mathcal{X}_1^*) = \mathbb{P}_{\theta_0}(\Lambda(\mathbf{X}) \geqslant t_\alpha) = \alpha.$$

Отсюда и из того, что уровень значимости критерия δ также равняется α, получаем

$$\alpha(\delta) = \mathbb{P}_{\theta_0}(\delta(\mathbf{X}) = H_1) = \mathbb{P}_{\theta_0}(\mathbf{X} \in \mathcal{X}_1) \leqslant \alpha = \mathbb{P}_{\theta_0}(\mathbf{X} \in \mathcal{X}_1^*). \tag{34}$$

Обозначим через $I(\boldsymbol{x}) = \mathbb{1}(\boldsymbol{x} \in \mathcal{X}_1)$ и $I^*(\boldsymbol{x}) = \mathbb{1}(\boldsymbol{x} \in \mathcal{X}_1^*)$ индикаторы множества $\mathcal{X}_1$ и $\mathcal{X}_1^*$ соответственно и рассмотрим функцию

$$f(\boldsymbol{x}) = (I^*(\boldsymbol{x}) - I(\boldsymbol{x}))(p_{\theta_1}(\boldsymbol{x}) - t_\alpha p_{\theta_0}(\boldsymbol{x})), \tag{35}$$

где $p_{\theta_1}(\boldsymbol{x})$ и $p_{\theta_0}(\boldsymbol{x})$ – это плотности при гипотезах H_0 и H_1 соответственно. Покажем, что $f(\boldsymbol{x}) \geqslant 0$ при всех $\boldsymbol{x} \in \mathcal{X}$: рассмотрим

1. $\boldsymbol{x} \in \mathcal{X}_1^*$: $I^*(\boldsymbol{x}) = 1$ и $p_{\theta_1}(\boldsymbol{x}) \geqslant t_\alpha p_{\theta_0}(\boldsymbol{x})$, значит оба сомножителя в формуле (35) неотрицательны, поэтому $f(\boldsymbol{x}) \geqslant 0$;
2. $\boldsymbol{x} \notin \mathcal{X}_1^*$: $I^*(\boldsymbol{x}) = 0$ и $p_{\theta_1}(\boldsymbol{x}) < t_\alpha p_{\theta_0}(\boldsymbol{x})$, значит оба сомножителя неположительны, поэтому $f(\boldsymbol{x}) \geqslant 0$.

Значит, $f(\boldsymbol{x})$ действительно неотрицательна, тогда

$$\begin{aligned}
0 &\leqslant \int_{\mathcal{X}} f(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \\
&= \int_{\mathcal{X}} (I^*(\boldsymbol{x})p_{\theta_1}(\boldsymbol{x}) - I(\boldsymbol{x})p_{\theta_1}(\boldsymbol{x}) - t_\alpha(I^*(\boldsymbol{x})p_{\theta_0}(\boldsymbol{x}) - I(\boldsymbol{x})p_{\theta_0}(\boldsymbol{x})))\mathrm{d}\boldsymbol{x} \\
&= \int_{\mathcal{X}_1^*} p_{\theta_1}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} - \int_{\mathcal{X}_1} p_{\theta_1}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} - t_\alpha\left(\int_{\mathcal{X}_1^*} p_{\theta_0}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} - \int_{\mathcal{X}_1} p_{\theta_0}(\boldsymbol{x})\mathrm{d}\boldsymbol{x}\right) \\
&= \mathbb{P}_{\theta_1}(\mathbf{X} \in \mathcal{X}_1^*) - \mathbb{P}_{\theta_1}(\mathbf{X} \in \mathcal{X}_1) - t_\alpha(\mathbb{P}_{\theta_0}(\mathbf{X} \in \mathcal{X}_1^*) - \mathbb{P}_{\theta_0}(\mathbf{X} \in \mathcal{X}_1)).
\end{aligned}$$

Отсюда и из неравенства (34) вытекает, что

$$\mathbb{P}_{\theta_1}(\boldsymbol{X} \in \mathcal{X}_1^*) \geqslant \mathbb{P}_{\theta_1}(\boldsymbol{X} \in \mathcal{X}_1),$$

то есть мощность δ^* не меньше мощности любого другого критерия с точно таким же уровнем значимости

$$W(\delta^*, \theta_1) \geqslant W(\delta, \theta_1).$$

□

Далее покажем, что критерий Неймана-Пирсона будет строго несмещенным.

Лемма 12. *Критерий Неймана-Пирсона δ^*, задаваемый критической областью (33), является строго несмещенным*

$$W(\delta^*, \theta) > \alpha.$$

Доказательство. Рассмотрим два случая

1. $t_\alpha > 1$: из определения $\mathcal{X}_1^*$ следует, что для любого $\boldsymbol{x} \in \mathcal{X}_1^*$: $p_{\theta_1}(\boldsymbol{x}) \geqslant t_\alpha p_{\theta_0}(\boldsymbol{x}) > p_{\theta_0}(\boldsymbol{x})$. Тогда

$$W(\delta^*, \theta_1) = \mathbb{P}_{\theta_1}(\boldsymbol{X} \in \mathcal{X}_1^*) = \int_{\mathcal{X}_1^*} p_{\theta_1}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} > \int_{\mathcal{X}_1^*} p_{\theta_0}(\boldsymbol{x})\mathrm{d}x = \mathbb{P}_{\theta_0}(\boldsymbol{X} \in \mathcal{X}_1^*) = \alpha.$$

2. $t_\alpha \leqslant 1$: из определения $\mathcal{X}_1^*$ следует, что при $\boldsymbol{x} \in \mathcal{X}_0 := \mathcal{X} \backslash \mathcal{X}_1^*$, $p_{\theta_1}(\boldsymbol{x}) < t_\alpha p_{\theta_0}(\boldsymbol{x}) \leqslant p_{\theta_0}(\boldsymbol{x})$. Тогда

$$W(\delta^*, \theta_1) = \mathbb{P}_{\theta_1}(\boldsymbol{X} \in \mathcal{X}_1^*) = 1 - \int_{\mathcal{X}_0} p_{\theta_1}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} > 1 - \int_{\mathcal{X}_0} p_{\theta_0}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} = \int_{\mathcal{X}_1^*} p_{\theta_0}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} = \alpha.$$

То есть в любом случае $W(\delta^*, \theta_1) > \alpha$, что и требовалось доказать. □

12.2 Сложные гипотезы

Пусть теперь альтернатива сложная односторонняя

$$\begin{aligned} H_0 &: \theta = \theta_0; \\ H_1 &: \theta > \theta_0. \end{aligned} \tag{36}$$

Теорема 24 (О равномерно наиболее мощном критерии)**.** *Пусть статистика отношения правдоподобия $\Lambda(\mathbf{X})$ является монотонной функцией от достаточной статистики $T(\boldsymbol{X})$, то есть такой, что правдоподобие представляется в виде*

$$L_{\mathbf{X}}(\theta) = g(T(\mathbf{X}), \theta)h(\mathbf{X}),$$

где g и h – некоторые функции. Тогда в задаче (36) существует равномерно наиболее мощный критерий, совпадающий с критерием Неймана-Пирсона для задачи (29).

Доказательство. Рассмотрим статистику отношения правдоподобия

$$\Lambda(\mathbf{X}) = \frac{g(T(\mathbf{X}), \theta_1)}{g(T(\mathbf{X}), \theta_0)},$$

и пусть $\Lambda(\mathbf{X})$ строго возрастающая функция от $T(\mathbf{X})$, тогда критическая область в критерии Неймана-Пирсона для задачи (29) может быть записана эквивалентным образом

$$\Lambda(\mathbf{X}) \geqslant c_\alpha \quad \Longleftrightarrow \quad T(\mathbf{X}) \geqslant t_\alpha,$$

причем граница t_α определяется из уровня значимости критерия

$$\mathbb{P}_{\theta_0}(T(\mathbf{X}) \geqslant t_\alpha) = \alpha.$$

То есть граница t_α одна и та же при любой альтернативе $\theta_1 > \theta_0$, значит и критерий будет точно такой же, как и для задачи (29). Случай строго убывающей фукнции рассматривается аналогично, но знак будет в другую сторону

$$\Lambda(\mathbf{X}) \geqslant c_\alpha \quad \Longleftrightarrow \quad T(\mathbf{X}) \leqslant t_\alpha.$$

□

Замечание 24. В условиях Теоремы (24) гипотезы (H_0, H_1) со знаками $(=, >)$ могут быть заменены на гипотезы $(=, <)$, $(\geqslant, <)$ или $(\leqslant, >)$; критерий останется таким же. В случае монотонного убывания отношения правдоподобия знак в критерии меняется на противоположный.

Замечание 25 (Экспоненциальное семейство)**.** Для распределений из экспоненциального семейства, то есть таких, для которых правдоподобие представляется в виде

$$L_{\mathbf{X}}(\theta) = \exp\{\eta(\theta)T(\mathbf{X}) - A(\theta)\}h(\mathbf{X}),$$

где $T(\mathbf{X})$ – достаточная статистика, всегда существует равномерно наиболее мощный критерий в задаче (36), если $\eta(\theta)$ – строго монотонная функция, так как тогда и $\Lambda(\mathbf{X})$ будет строго монотонной функцией от достаточной статистики $T(\mathbf{X})$.

Замечание 26 (Дискретные распределения)**.** В случае дискретных распределений не для любого $\alpha \in (0, 1)$ существует такое $t_\alpha \geqslant 0$, удовлетворяющее равенству $\varphi(t_\alpha) = \alpha$ для φ, определенной в (32). Если требуется построить критерий с уровнем значимости в точности равным α, то прибегают к рандомизации. Однако на практике зачастую строят критерий Неймана-Пирсона с уровнем значимости $\alpha_0 \leqslant \alpha$.

12.3 Критерии согласия Колмогорова

В данном пункте нас интересует проверка гипотезы о виде распределения наблюдаемых случайных величин. Нам доступна выборка $\boldsymbol{X} = (X_1, \ldots, X_n)$, состоящая из н.о.р.с.в. с функцией распределения $F_{\boldsymbol{X}}(x)$. Мы выдвигаем простую гипотезу

$$H_0 : F_{\boldsymbol{X}}(x) = F_0(x)\,,$$

где функция распределения $F_0(x)$ фиксирована. Альтернативные распределения не конкретизируются, то есть в качестве множества H_1 выступают все прочие функции распределения.

12.4 Критерий Колмогорова.

Данный критерий применим в случае непрерывных целевых функций $F(x)$.

Рассмотрим случайную величину

$$D_n(\boldsymbol{X}) = \sup_{x\in\mathbb{R}} |\hat{F}_n(x) - F_{\boldsymbol{X}}(x)|\,,$$

где $\hat{F}_n(x) = \frac{1}{n}\sum_{i=1}^n \mathbb{1}\{X_i \leqslant x\}$ - эмпирическая функция распределения, построенная по выборке $\boldsymbol{X}$. Как вам уже известно, эмпирическая функция распределения $\hat{F}_n(x)$ в заданной точке x является оптимальной оценкой истинной функции распределения $F_{\boldsymbol{X}}(x)$. Более того, имеет место следующий результат:

Теорема 25 (Гливенко-Кантелли)**.** *Пусть $X_1, \ldots, X_n, \ldots$ - последовательность н.о.р.с.в. с функцией распределения $F_{\boldsymbol{X}}(x)$, $\hat{F}_n(x) = \frac{1}{n}\sum_{i=1}^n \mathbb{1}\{X_i \leqslant x\}$. Тогда для последовательности случайных величин $D_n(\boldsymbol{X})$ выполнено*

$$\mathbb{P}(\{\lim_{n\to\infty} D_n(\boldsymbol{X}) = 0) = 1\,.$$

Таким образом, мы можем ожидать, что наблюдаемые значения случайной величины $D_n(\boldsymbol{X})$ окажутся близки к 0, если размер выборки n достаточно велик. Более того, оказывается, что верна следующая теорема об уклонениях статистики $D_n(\boldsymbol{X})$ от 0.

Теорема 26. *[А.Н. Колмогоров] Если функция распределения $F(x)$ непрерывна, то при любом фиксированном $t > 0$ выполнено*

$$\lim_{n\to\infty} \mathbb{P}(\sqrt{n} D_n(\boldsymbol{X}) \leqslant t) = K(t) = \sum_{j=-\infty}^{+\infty} (-1)^j \mathrm{e}^{-2j^2t^2}\,.$$

В качестве упражнения проверьте, что определенная выше функция $K(t)$ удовлетворяет всем свойствам функции распределения. Соответствующее ей распределение называют распределением Колмогорвоа, значения $K(t)$ при рзличных t табулированы. Обратите внимание, что предельное распределение $K(t)$ не зависит от исходной функции распределения $F_{\boldsymbol{X}}(x)$.

Напомним теперь, что мы проверяем простую гипотезу вида $H_0 : F_{\boldsymbol{X}}(x) = F_0(x)$. Основываясь на теореме Колмогорова, естественно использовать в качестве статистики критерия величину

$$D_{n,0}(\boldsymbol{X}) = \sup_{x\in\mathbb{R}} |\hat{F}_n(x) - F_0(x)|\,.$$

Если гипотеза H_0 справедлива, то значения статистики $D_{n,0}$ не должны существенно отклоняться от нуля, как следует из 26. Таким образом, критическую область критерия естественно задать в виде $\{D_{n,0} \geqslant t_\alpha\}$, т.е. большие значения $D_{n,0}$ свидетельствуют против H_0. При этом критическое значение t_α при заданном уровне значимости α рассчитывается на основе теоремы 26. А именно, определим λ_α из соотношения $K(\lambda_\alpha) = 1 - \alpha$. Тогда

$$\lim_{n\to\infty} \mathbb{P}(\sqrt{n} D_{n,0}(\boldsymbol{X}) \geqslant t | H_0) = 1 - K(\lambda_\alpha) = \alpha\,. \tag{37}$$

Таким образом, при выбранном уровне значимости α мы принимаем гипотезу H_0, если

$$D_{n,0}(\boldsymbol{X}) \leqslant t_\alpha := \lambda_\alpha/\sqrt{n}\,,$$

отвергаем в противоположном случае. На практике данный критерий можно применять, если $n \geqslant 20$. Данное количество наблюдений обеспечивает достаточно хорошую точность аппроксимации распределения статистики $\sqrt{n} D_{n,0}(\boldsymbol{X})$ при помощи распределения Колмогорова. Как следует из (37), уровень значимости данного критерия будет приближенно равен α.

13 Критерий хи-квадрат Пирсона

Критерий хи-квадрат Пирсона является наиболее универсальным методом проверки простых гипотез о виде распределения. Критерий применим как для дискретных распределений, так и для абсолютно непрерывных. Для абсолютно непрерывных распределений понадобится предварительная группировка соответствующие наблюдений, чтобы свести задачу к дискретному случаю.

13.1 Критерий согласия хи-квадрат Пирсона. Простая гипотеза

Пусть дана выборка $\boldsymbol{X} = (X_1, \ldots, X_n)$ из неизвестного распределения $F(x)$. И пусть выдвинута простая гипотеза

$$H_0 : F(x) = F_0(x)\,, \tag{38}$$

где функция распределения $F_0(x)$ фиксирована. В качестве альтернативны берутся все прочие распределения. Критерии для проверки такой гипотезы мы будем называть критериями согласия, так как альтернатива никак не конретизирована и речь идет лишь о согласии данных с H_0.

Дискретные распределения Пусть мы знаем, что элементы выборки $X_1, \ldots, X_n$ принимают целочисленные значения от 1 до N, каждое с вероятностью

$$p_j := \mathbb{P}(X_i = j), \quad i = 1, \ldots, n,\ j = 1, \ldots, N.$$

Определим частоты

$$\nu_j = \sum_{i=1}^{n} \mathbb{1}\{X_i \in j\}\,, \quad j \in \{1, \ldots, N\}\,.$$

Теперь покажем, как абсолютно непрерывный случай может быть сведен к дискретному.

Абсолютно непрерывные распределения Проведем группировку наблюдений: разобьем числовую прямую на N непересекающихся промежутков $\Delta_1, \ldots, \Delta_N$, таких что $\cup\Delta_i = \mathbb{R}$. Тогда вероятность того, что элемент выборки X_i попал в Δ_j

$$p_j := \int_{\Delta_j} \mathrm{d}F(x), \quad i = \{1, \ldots, n\},\ j = \{1, \ldots, N\}.$$

При справедливости гипотезы H_0 эти вероятности должны равняться

$$p_j^0 := \mathbb{P}(X_i = j) = \int_{\Delta_j} \mathrm{d}F_0(x), \quad i = 1, \ldots, n,\ j = \{1, \ldots, N\}.$$

Соответствующие частоты

$$\nu_j = \sum_{j=1}^{n} \mathbb{1}\{X_i \in \Delta_j\}\,, \quad j \in \{1, \ldots, N\}\,, i \in \{1, \ldots, n\} \tag{39}$$

Замечание 27. Разумеется группировка слагаемых сопряжена потерей информации. Также возникает вопрос выбора числа интервалов N и их вида. Здесь можно предложить несколько эвристических правил, в частности, $N \approx \sqrt{n}$.

Зададим векторы частот $\nu = (\nu_1, \ldots, \nu_N)$, $\boldsymbol{p} = (p_1, \ldots, p_N)$, $\boldsymbol{p}^{(0)} = (p_1^{(0)}, \ldots, p_N^{(0)})$. Тогда гипотеза (38) может быть эквивалентно переформулирована как

$$H_0 : \boldsymbol{p} = \boldsymbol{p^{(0)}} \,. \tag{40}$$

При этом, в силу УЗБЧ, выполнено

$$\frac{\nu_i}{n} = \frac{1}{n}\sum_{j=1}^{n} \mathbb{1}\{X_i \in \Delta_j\} \xrightarrow{a.s.} \mathbb{E}\mathbb{1}\{X_1 \in \Delta_j\} = \mathbb{P}(\xi_1 = i) = p_i \,.$$

Поэтому при справедливости гипотезы H_0 значения ν_j должны быть близки к np_j. Введем статистику Пирсона, значения которой должны быть малы при справедливости гипотезы H_0.

Определение 53 (Статистика Пирсона)**.**

$$T_{\chi^2} = \sum_{j=1}^{N} \frac{(\nu_j - np_j^{(0)})^2}{np_j^{(0)}} \,.$$

Очевидно, если гипотеза H_0 справедлива, значения статистики χ^2 не должны быть слишком большими. Поэтому естественно выбрать критическую область для гипотезы H_0 в виде $\{T_{\chi^2} > t_\alpha\}$, где критическое значение t_α при заданном уровне значимости α должно определяться из условия

$$\mathbb{P}_{H_0}(T_{\chi^2} > t_\alpha) = \alpha.$$

Точное распределение статистики $\chi^2_{0,n}$ неудобно для расчетов, однако, у этой статистики есть простое предельное распределение, не зависящее от $\boldsymbol{p^{(0)}}$. Справедлива следующая теорема:

Теорема 27 (Предельное распределение статистики Пирсона)**.** *Если* $0 < p_j^{(0)} < 1$ *при* $j \in \{1, \ldots, N\}$*, то при условии справедливости* H_0 *выполнено*

$$T_{\chi^2} \xrightarrow{d} \chi^2(N-1), \qquad n \to \infty,$$

где $\chi^2(N-1)$ *– распределение* χ^2 *с* $N-1$ *степенями свободы.*

Тогда критическая область критерия хи-квадрат Пирсона может быть задается следующим способом

$$\mathcal{X}_1 = \{\boldsymbol{x} : T_{\chi^2} \geqslant t_\alpha\},$$

где t_α – $1-\alpha$-квантиль в распределении $\chi^2(N-1)$, так как критическая граница t_α определяется из уровня значимости критерия

$$\alpha = \mathbb{P}_{H_0}(T_{\chi^2} \geqslant t_\alpha) = 1 - F_{T_{\chi^2}}(t_\alpha).$$

Замечание 28 (Условия применимости)**.** На практике критерий хи-квадрат хорошо работает уже для выборок объема $n \geqslant 50$ и при частотах $\nu_j \geqslant 5$ для любого $j = \{1, \ldots N\}$.

13.2 Критерий согласия хи-квадрат Пирсона. Сложная гипотеза

Пусть теперь функция распределения $F_0(x, \boldsymbol{\theta})$ задана с точностью до неизвестного параметра $(\boldsymbol{\theta}) = (\theta_1, \ldots, \theta_r)$. Например проверяется гипотеза о том, что выборка $\boldsymbol{X} = (X_1, \ldots, X_n)$ распределена по закону Бернулли.

$$H_0 : F(x) \in \mathcal{F}_0(x) = \{F_0(x, \boldsymbol{\theta}) : \boldsymbol{\theta} = (\theta_1, \ldots, \theta_r) \in \Theta \subset \mathbb{R}^r\},$$

где функция распределения $F_0(x)$ фиксирована. В качестве альтернативны берутся все прочие распределения. Критерии для проверки такой гипотезы мы будем называть критериями согласия, так как альтернатива никак не конретизирована и речь идет лишь о согласии данных с H_0. Тогда задача (40) заменится на

$$H_0 : \boldsymbol{p}(\boldsymbol{\theta}) = \boldsymbol{p^{(0)}}(\boldsymbol{\theta}).$$

Поскольку параметр $\boldsymbol{\theta}$ оценим его методом максимального правдоподобия. Для этого поймем, как распределен вектор частот $\boldsymbol{\nu}$: вектор частот $\boldsymbol{\nu} \sim M(n, \boldsymbol{p}(\boldsymbol{\theta}))$ имеет мультиномиальное (полиномиальное) распределение, которое задается следующей вероятностью

$$\mathbb{P}(\boldsymbol{\nu} = \boldsymbol{y}) = \frac{n!}{y_1! \ldots, y_N!}(p_1^{(0)}(\boldsymbol{\theta}))^{y_1} \ldots (p_N^{(0)}(\boldsymbol{\theta}))^{y_N},$$

где $\boldsymbol{y} = (y_1, \ldots, y_N), y_j \geqslant 0$ для всех $j = \{1, \ldots N\}$, $\sum_{j=1}^n y_j = n$.

Пример 29. При $N = 2$ мультиномиальное (полиномиальное) распределение $M(n, p_1, p_2)$ есть биномиальное распределение $\mathrm{Bin}(n, p_1)$.

Тогда правдоподобие параметра $\boldsymbol{\theta}$ вектора $\boldsymbol{\nu}$

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{n!}{\nu_1! \ldots, \nu_N!} \prod_{j=1}^{N} (p_j^{(0)}(\boldsymbol{\theta}))^{\nu_j}.$$

Оценка максимального правдоподобия будет равна

$$\begin{aligned}\widehat{\boldsymbol{\theta}}_{MLE} &= \arg\max_{\boldsymbol{\theta}\in\Theta} \ln \mathcal{L}(\boldsymbol{\theta}) = \arg\max_{\boldsymbol{\theta}\in\Theta} \left\{ \ln\left(\frac{n!}{\prod_{j=1}^N \nu_j!}\right) + \ln\left(\prod_{j=1}^{N} \ln\left(p_j^{(0)}(\boldsymbol{\theta})\right)^{\nu_j}\right)\right\} \\ &= \arg\max_{\boldsymbol{\theta}\in\Theta} \ln \mathcal{L}(\boldsymbol{\theta}) = \arg\max_{\boldsymbol{\theta}\in\Theta} \sum_{j=1}^{N} \nu_j \ln p_j^{(0)}(\boldsymbol{\theta}). \qquad (41)\end{aligned}$$

Подставим эту оценку в статистику T_{χ^2}

$$T_{\chi^2} = \sum_{j=1}^{N} \frac{(\nu_j - np_j^{(0)}(\widehat{\boldsymbol{\theta}}_{MLE}))^2}{np_j^{(0)}(\widehat{\boldsymbol{\theta}}_{MLE})}.$$

Теорема 28 (Предельное распределение статистики T_{χ^2})**.** *Пусть для любого* $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^r$

$$\sum_{i=1}^{N} p_i^{(0)}(\boldsymbol{\theta}) = 1, \quad 0 < p_i^{(0)}(\boldsymbol{\theta}) < 1,$$

пусть существуют непрерывные производные

$$\frac{\partial p_j^{(0)}(\boldsymbol{\theta})}{\partial \theta_k}, \quad \frac{\partial^2 p_j^{(0)}(\boldsymbol{\theta})}{\partial \theta_k \partial \theta_\ell}, \quad k, \ell = 1, \ldots, r$$

и пусть матрица $\left(\frac{\partial p_j^{(0)}(\boldsymbol{\theta})}{\partial \theta_k} \right)$ *размера* $N \times r$ *имеет ранг* r.

Тогда при справедливости H_0

$$T_{\chi^2} \xrightarrow{d} \chi^2(N - r - 1), \quad n \to \infty.$$

где $\chi^2(N - r - 1)$ - *распределение хи-квадрат с* $N - r - 1$ *степенями свободы.*

13.2.1 p-value

Пусть гипотеза отвергается при уровне значимости α, значит она будет отвергаться и при уровне $\alpha' > \alpha$. То есть существует наименьшее α_0, при котором гипотеза отвергается, назовем это α_0 p-value.

Определение 54 (p-value)**.** Пусть для любого $\alpha \in (0, 1)$ построен критерий уровня значимости α с критической областью $\mathcal{X}_\alpha$ и тестовой статистикой $T(\mathbf{X})$, тогда

$$\text{p-value} = \min_{\alpha \in (0,1)} \{T(\mathbf{X}) \in \mathcal{X}_\alpha\}$$

p-value является мерой свидетельства против гипотезы H_0: чем меньше p-value, тем более сильное свидетельство против H_0.

Золотое правило

$$\text{p-value} \leqslant \alpha \quad \Longleftrightarrow \quad H_0 \text{ отвергается}$$

Чем меньше p-value, тем более уверено можно отвергнуть H_0.

Замечание 29. p-value - случайная величина, она зависит от выборки $X = (X_1, \ldots, X_n)$.

Замечание 30. Большое p-value не говорит о том, что H_0 верна. Причины большого p-value: H_0 действительно верна либо у критерия слабая мощность.

Теорема 29. *Пусть критерий уровня значимости* α *с тестовой статистикой* $T(\mathbf{X})$ *имеет критическую форму вида*

$$\mathcal{X}_\alpha = \{\boldsymbol{x} \in \mathcal{X} : T(\boldsymbol{x}) \geqslant c_\alpha\}.$$

Тогда

$$\text{p-value} = \sup_{F \in \mathcal{F}_0} \mathbb{P}_{H_0}(T(\mathbf{X}) \geqslant T(\boldsymbol{x})).$$

14 Гипотеза однородности

Пусть имеется K серий независимых наблюдений

$$X_1^{(1)}, \dots, X_{n_1}^{(1)} \sim F_1(x)$$
$$\vdots$$
$$X_1^{(K)}, \dots, X_{n_K}^{(K)} \sim F_K(x).$$

Гипотезой однородности является утверждение, что все эти выборки были сгенерированы из одного и того же распределения, то есть

$$H_0 : F_1(x) = \dots = F_m(x) =: F(x).$$

В отличие от гипотезы о виде распределения функция $F(x)$ неизвестна и не задается нулевой гипотезой. Это задача непараметрическогй статистики. В случае справедливости нулевой гипотезы все выборки можно объединить в одну большую выборку. Также проверка гипотез однородности представляет собой A/B тестирование, при котором зачастую требуется определить, достигнуты ли какие-то улучшения.

14.1 Критерий хи-квадрат Пирсона.

Критерий хи-квадрат Пирсона – это универсальный критерий, применимый к анализу данных любой природы (как мы уже видели в предыдущем разделе метод группировки слагаемых позволяет использование этого критерия не только для дискретных случайных величин, но и абсолютно непрерывных). Поэтому для простоты рассмотрим только дискретные распределения.

Дискретные распределения. Пусть неизвестное гипотетическое распределение таково, что случайная величина X_i^k ($i = \{1, \dots, n_k\}, k = \{1, \dots, K\}$) принимают целочисленные значения от 1 до N, каждое с вероятностью

$$p_j^{(k)} := \mathbb{P}(X_i = j).$$

Определим частоты

$$\nu_j^{(k)} = \sum_{i=1}^{n} \mathbb{1}\{X_i \in j\}\,.$$

Зададим векторы частот $\nu^{(k)} = (\nu_1, \dots, \nu_N)$, $\boldsymbol{p}^{(k)} = (p_1^{(k)}, \dots, p_N^{(k)})$ для любого $k = \{\mathbb{1}, \dots, K\}$. Тогда нулевая гипотеза может быть эквивалентно переформулирована

$$H_0 : \boldsymbol{p}^{(1)} = \boldsymbol{p}^{(2)} = \dots = \boldsymbol{p}^{(K)} =: \boldsymbol{p}. \tag{42}$$

Вектор $\boldsymbol{p}$ не задается нулевой гипотезой, поэтому его необходимо оценить. Интуитивно понятно, что если нулевая гипотеза верна, то выборки можно объединить в одну большую выборку и по УЗБЧ оценить $p_j \approx \sum_{k=1}^{K} \nu_j^{(k)} / \sum_{k=1}^{K} n_k$ для $j = \{1, \dots, N\}$. Докажем это утверждение методом максимального правдоподобия.

Лемма 13. *Оценка максимального правдоподобия для неизвестного вектора вероятностей* $\boldsymbol{p}$ *в нулевой гипотезе* (42) *задается следующей формулой*

$$\widehat{p}_j = \frac{\sum_{k=1}^K \nu_j^{(k)}}{n} \quad \text{для каждого } j = \{1, \dots, N\},$$

где $n = \sum_{k=1}^K n_k$.

Доказательство. При справедливости нулевой гипотезы векторы частот имеет мультиномиальное (полиномиальное) распределение

$$\boldsymbol{\nu}^{(k)} \sim M(n_k, \boldsymbol{p})$$

Напомним что, мультиномиальное распределение задается следующей вероятностью

$$\mathbb{P}(\boldsymbol{\nu}^k = \boldsymbol{y}) = \frac{n!}{y_1! \dots, y_N!} p_1^{y_1} \dots p_N^{y_N},$$

где $\boldsymbol{y} = (y_1, \dots, y_N), y_j \geqslant 0$ для всех $j = \{1, \dots N\}$, $\sum_{j=1}^n y_j = n$. Тогда правдоподобие вектора $\boldsymbol{p}$ для $\boldsymbol{\nu}^{(1)}, \dots, \boldsymbol{\nu}^{(K)}$

$$\mathcal{L}(\boldsymbol{p}) = \prod_{k=1}^K \frac{n_k!}{\prod_{j=1}^N \nu_j^{(k)}!} \prod_{j=1}^N p_j^{\nu_j^{(k)}}$$

Оценка максимального правдоподобия вектора $\boldsymbol{p}$ будет находиться из решения оптимизационной задачи

$$\begin{aligned}
\widehat{\boldsymbol{p}} &= \arg \max_{\substack{\boldsymbol{p}:\ p_j \geqslant 0,\ j=\{1,\dots N\},\\ \sum_{j=1}^N p_j = 1}} \ln \mathcal{L}(\boldsymbol{p}) = \arg \max_{\substack{\boldsymbol{p}:\ p_j \geqslant 0,\ j=\{1,\dots N\},\\ \sum_{j=1}^N p_j = 1}} \left\{ \ln \left(\prod_{k=1}^K \prod_{j=1}^N p_j^{\nu_j^{(k)}} \right) + \ln \left(\prod_{k=1}^K \frac{n_k!}{\prod_{j=1}^N \nu_j^{(k)}!} \right) \right\} \\
&= \arg \max_{\substack{\boldsymbol{p}:\ p_j \geqslant 0,\ j=\{1,\dots N\},\\ \sum_{j=1}^N p_j = 1}} \ln \left(\prod_{k=1}^K \prod_{j=1}^N p_j^{\nu_j^{(k)}} \right) \\
&= \arg \max_{\substack{\boldsymbol{p}:\ p_j \geqslant 0,\ j=\{1,\dots N\},\\ \sum_{j=1}^N p_j = 1}} \sum_{k=1}^K \sum_{j=1}^N \nu_j^{(k)} \ln p_j
\end{aligned}$$

Решим данную задачу минимизации методом множителей Лагранжа: внесем ограничение $\sum_{j=1}^N p_j = 1$ в оптимизируемую фукнцию со штрафом $\lambda \in \mathbb{R}$

$$\min_{\lambda \in \mathbb{R}} \max_{\boldsymbol{p}:\ p_j \geqslant 0,\ j=\{1,\dots N\}} \left\{ \sum_{k=1}^K \sum_{j=1}^N \nu_j^{(k)} \ln p_j + \lambda (1 - \sum_{j=1}^N p_j) \right\}.$$

Продифференцируем по p_j и приравняем к нулю, так как теперь полученная задача без ограничений (почти)

$$\sum_{k=1}^K \nu_j^{(k)} \ln p_j + \lambda = 0$$

Тогда

$$\widehat{p}_j = \frac{\sum_{k=1}^K \nu_j^{(k)}}{\lambda}. \tag{43}$$

Поскольку λ неизвестна, воспользуемся граничным условием $\sum_{j=1}^{N} p_j = 1$: просуммируем (43) и найдем λ

$$\sum_{j=1}^{N} \widehat{p}_j = \sum_{j=1}^{N} \frac{\sum_{k=1}^{K} \nu_j^{(k)}}{\lambda} = \frac{1}{\lambda} \sum_{j=1}^{N} \sum_{k=1}^{K} \nu_j^{(k)}.$$

Значит

$$\lambda = \sum_{j=1}^{N} \sum_{k=1}^{K} \nu_j^{(k)} = \sum_{k=1}^{K} n_k = n.$$

Подставляем это выражение в (43) и завершаем доказательство. □

Преобразуем статистику Пирсона (53) для данной задачи

$$T_{\chi^2} = \sum_{k,j=1}^{K,N} \frac{(\nu_j^{(k)} - n_k \widehat{p}_j)^2}{n_k \widehat{p}_j},$$

где

$$\widehat{p}_j = \frac{\sum_{k=1}^{m} \nu_{kj}}{n}, \quad n = \sum_{k=1}^{m} n_k.$$

При справедливости гипотезы H_0 аналогично теореме (27) будет иметь место следующий предельный результат

$$T_{\chi^2} = \sum_{k,j=1}^{K,N} \frac{(\nu_{kj} - n_k \widehat{p}_j)^2}{n_k \widehat{p}_j} \xrightarrow{d} \chi^2((K-1)(N-1))$$

при всех $n_k \to \infty$, $k = 1, \ldots, K$. При справедливости гипотезы H_0 значение данной статистики не должно быть слишком большим, поэтому асимптотический критерий однородности будет выглядеть следующим образом.

Асимптотический критерий однородности.

$$H_0 \text{ отвергается} \quad \Longleftrightarrow \quad T_{\chi^2} \geqslant t_\alpha,$$

где t_α – $1-\alpha$-квантиль в распределении $\chi^2((K-1)(N-1))$, так как критическая граница t_α определяется из уровня значимости критерия

$$\alpha = \mathbb{P}_{H_0}(T_{\chi^2} \geqslant t_\alpha) = 1 - F_{T_{\chi^2}}(t_\alpha).$$

Поскольку критерий асимптотический, применять его можно лишь для больших выборок.

14.2 Параметрический случай

Эту же методику можно использовать и для проверки гипотезы о том, что гипотетические вероятности $\boldsymbol{p}^{(k)}$ имеют заданную параметрическую форму $\boldsymbol{p}^{(k)} = \boldsymbol{p}^{(k)}(\boldsymbol{\theta})$. Такая ситуация возникает, например, когда требуется проверить гипотезу о том, что K серий наблюдений

произведены над одной и той же случайной величиной с рапспределением из заданного параметрического семейства $\mathcal{P} = \{\mathbb{P}_{\boldsymbol{\theta}}, \boldsymbol{\theta} \in \Theta\}$.

Статистика Пирсона (53) для данной задачи

$$T_{\chi^2} = \sum_{k,j=1}^{K,N} \frac{(\nu_j^{(k)} - n_k p_j(\widehat{\boldsymbol{\theta}})^2}{n_k p_j(\widehat{\boldsymbol{\theta}})},$$

где

$$\widehat{\boldsymbol{\theta}} = \arg\max_{\boldsymbol{\theta}\in\Theta} \ln \mathcal{L}(\boldsymbol{\theta}) = \arg\max_{\boldsymbol{\theta}\in\Theta} \sum_{j=1}^{N} \nu_j \ln p_j^{(0)}$$

Аналогично теореме (27) будет иметь место следующий предельный результат

$$T_{\chi^2} = \sum_{k,j=1}^{K,N} \frac{(\nu_{kj} - n_k \widehat{p}_j)^2}{n_k \widehat{p}_j} \xrightarrow{d} \chi^2(K(N-1) - r).$$

при справедливости гипотезы H_0 при всех $n_k \to \infty$, $k = 1, \ldots, K$. Тогда асимптотический критерий однородности будет выглядеть следующим образом.

Асимптотический критерий однородности.

$$H_0 \text{ отвергается} \quad \Longleftrightarrow \quad T_{\chi^2} \geqslant t_\alpha,$$

где t_α – $1-\alpha$-квантиль в распределении $\chi^2(K(N-1) - r)$.

15 Линейная регрессия

До сих пор в рамках курса рассматривались задачи оценивания и статистического вывода по выборке из независимых одинаково распределенных случайных элементов. Однако имеется широкий класс прикладных задач, в которых наблюдения зависят от одного или нескольких факторов, значения которых могут отличаться для различных элементов выборки. Рассмотрим следующий пример. Допустим, что в среднем ежемесячный объем продаж Y магазина мобильных устройств зависит от устанавливаемых магазином цен P и от затрат на рекламу A по следующей формуле:

$$\mathbb{E}Y = \theta_1 + \theta_2 P + \theta_3 A + \theta_4 A^2.$$

Отметим, что фактический объем продаж Y может меняться от месяца к месяцу даже если цены устройств и затраты на рекламу оставались неизменными. Это связано с тем, что значение Y определяется также и некоторыми случайными факторами. Поэтому можно составить следующую вероятностную модель:

$$Y = \theta_1 + \theta_2 P + \theta_3 A + \theta_4 A^2 + \varepsilon, \quad \text{где } \mathbb{E}(\varepsilon \,|\, P, A) = 0.$$

Форма зависимости $\mathbb{E}Y$ от факторов P и A может быть продиктована общими соображениями, экономическими законами или результатами исследований. Например, добавление слагаемого $\theta_4 A^2$ при отрицательных значениях коэффициента θ_4 может быть обусловлено тем, чрезмерные траты на рекламу не принесут желаемого эффекта. Определение этой формы выходит за рамки предмета изучения математической статистики. Однако математическая статистика позволяет оценить значения коэффициентов $\theta_1, \theta_2, \theta_3$ и θ_4 по эмпирическим наблюдениям. Допустим, что имеется набор наблюдений $\{(P_i, A_i, Y_i) : 1 \leqslant i \leqslant n\}$, причем

$$Y_i = \theta_1 + \theta_2 P_i + \theta_3 A_i + \theta_4 A_i^2 + \varepsilon_i, \quad \text{где } \mathbb{E}(\varepsilon \,|\, P, A) = 0 \text{ для всех } i \in \{1, \ldots, n\}. \tag{44}$$

Хорошая оценка $\widehat{\boldsymbol{\theta}}_{LSE} = (\widehat{\theta}_1, \widehat{\theta}_2, \widehat{\theta}_3, \widehat{\theta}_4)^\intercal$ вектора коэффициентов $\boldsymbol{\theta} = (\theta_1, \theta_2, \theta_3, \theta_4)^\intercal$ позволит построить оценку систематической составляющей объема продаж:

$$\widehat{Y} = \widehat{\theta}_1 + \widehat{\theta}_2 P + \widehat{\theta}_3 A + \widehat{\theta}_4 A^2,$$

а следовательно, поможет определить оптимальный уровень цен и затрат на рекламу для максимизации выручки. Задача определения зависимости интересующей нас величины ("отклика") от различных факторов называется задачей регрессии. Заметим, что в модели (44) значение $\mathbb{E}Y$ зависит линейно от неизвестного вектора параметров θ, поэтому (44) относится к модели *линейной* регрессии, несмотря на то, что фактор A входит в нее нелинейно.

15.1 Линейная регрессия

В общем виде регрессионную задачу можно сформулировать следующим образом. По имеющимся данным $\{(X_i, Y_i) : 1 \leqslant i \leqslant n\}$ нужно для нового входного x предсказать y, используя регрессионную функцию $f(x)$ такую, что $y \approx f(x)$. То есть предполагаем, что случайные наблюдения $Y_1, \ldots, Y_n$ получены из модели

$$Y_i = f(X_i) + \varepsilon_i, \quad i \in \{1, \ldots, n\}, \tag{45}$$

где $\mathbb{E}(\varepsilon_i \,|\, X_1, \ldots, X_n) = 0$ для всех i от 1 до n. Далее для простоты считаем, что $X_1, \ldots, X_n$ – детерминированные величины. Тогда условие $\mathbb{E}(\varepsilon_i \,|\, X_1, \ldots, X_n) = 0$, $1 \leqslant i \leqslant n$ можно заменить на $\mathbb{E}\varepsilon_i = 0$ для всех $i \in \{1, \ldots, n\}$.

Будем предполагать, что регрессионная функция f принадлежит некоторому параметрическому семейству $\{f_{\boldsymbol{\theta}},\ \boldsymbol{\theta} \in \Theta \in \mathbb{R}^p\}$. Более того, будем рассматривать лишь модели, которые линейны по параметру $\boldsymbol{\theta}$. Важно заметить, что мы предполагаем линейность по параметру $\boldsymbol{\theta}$, в то время как по входной переменной x $f(x)$ может быть нелинейна

$$f(x) = \sum_{j=1}^{p} \psi_j(x)\theta_j = \boldsymbol{\psi}(x)^\intercal \boldsymbol{\theta}, \tag{46}$$

где $\psi_i : \mathcal{X} \to \mathbb{R}$ известны $(i = 1, \ldots, p)$, а $\boldsymbol{\psi}(x) = (\psi_1(x), \ldots, \psi_p(x))$ – вектор-функция.

Пример 30. $f(x)$ – полиномиальная функция степени $p-1$

$$f(x) = \sum_{j=1}^{p} \theta_j x^{j-1}.$$

Тогда задачу регрессии (45) можно переписать следующим образом

$$Y_i = \boldsymbol{\psi}(X_i)^\intercal \boldsymbol{\theta} + \varepsilon_i, \quad i \in \{1, \ldots, n\},$$

В матрично-векторной форме:

$$\mathbf{Y} = \Psi^\intercal \boldsymbol{\theta} + \boldsymbol{\varepsilon}, \quad \mathbb{E}\boldsymbol{\varepsilon} = \mathbf{0}. \tag{47}$$

где $\Psi = (\boldsymbol{\psi}(X_1), \ldots, \boldsymbol{\psi}(X_n)) \in \mathbb{R}^{p \times n}$ называется *матрицей плана*. Мы предполагаем, что матрица $\Psi \in \mathbb{R}^{p \times n}$ имеет полный ранг, то есть ранг Ψ равен p. Эквивалентно, мы предполагаем, что $\Psi\Psi^\intercal \in \mathbb{R}^{p \times p}$ обратима.

Наша задача состоит в оценке параметра $\boldsymbol{\theta}$ и регрессионной функции $f(x) = \boldsymbol{\psi}(x)^\intercal \boldsymbol{\theta}$. В случае, когда истинная функция f не принадлежит параметрическому классу (46), модель называют мисспецифицированной.

15.2 Метод наименьших квадратов

Широко распространенным методом оценивания вектора коэффициентов $\boldsymbol{\theta}$ в модели линейной регрессии (47) является метод наименьших квадратов. Будем рассматривать квадратичные потери и задачу минимизации эмпирического риска

$$\widehat{\boldsymbol{\theta}}_{LSE} \in \operatorname*{argmin}_{\boldsymbol{\theta} \in \Theta} \sum_{i=1}^{n} (Y_i - \boldsymbol{\psi}(X_i)^\intercal \boldsymbol{\theta})^2 = \operatorname*{argmin}_{\boldsymbol{\theta} \in \Theta} \|\mathbf{Y} - \Psi^\intercal \boldsymbol{\theta}\|^2. \tag{48}$$

Находя градиент функции $\|\mathbf{Y} - \Psi^\intercal \boldsymbol{\theta}\|^2$ и приравнивая его к нулю, получаем, что $\widehat{\boldsymbol{\theta}}_{LSE}$ удовлетворяет уравнению

$$2\Psi(\Psi^\intercal \widehat{\boldsymbol{\theta}}_{LSE} - \mathbf{Y}) = \mathbf{0}.$$

Если матрица Ψ является матрицей ранга p, то матрица $\Psi\Psi^\intercal$ невырождена и значение оценки метода наименьших квадратов $\widehat{\boldsymbol{\theta}}$ можно найти по формуле[6]

$$\widehat{\boldsymbol{\theta}}_{LSE} = (\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y}.$$

[6] В общем случае в качестве оценки $\widehat{\boldsymbol{\theta}}_{LSE}$ можно взять $(\Psi\Psi^\intercal)^\dagger \Psi Y$, где $(\Psi\Psi^\intercal)^\dagger$ – псевдообратная к $\Psi\Psi^\intercal$ матрица. Заметим, что если ранг матрицы Ψ меньше размерности вектора параметров $\boldsymbol{\theta}$, то решение задачи оптимизации (48) неединственно.

15.3 Статистические свойства и геометрическая интерпретация

Перейдем к рассмотрению статистических свойств оценки $\widehat{\boldsymbol{\theta}}_{LSE}$.

1. Линейность (по Y):
$$\widehat{\boldsymbol{\theta}}_{LSE} = (\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y} =: AY.$$

2. Несмещенность
$$\mathbb{E}_{\boldsymbol{\theta}}\boldsymbol{\theta}_{LSE} = \mathbb{E}_{\boldsymbol{\theta}}(\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y} = \mathbb{E}_{\boldsymbol{\theta}}(\Psi\Psi^\intercal)^{-1}\Psi(\Psi^\intercal\boldsymbol{\theta} + \varepsilon) = \boldsymbol{\theta}.$$

3. Дисперсия:
$$\begin{aligned}\mathrm{Var}_{\boldsymbol{\theta}}(\widehat{\boldsymbol{\theta}}_{LSE}) &= \mathrm{Var}_{\boldsymbol{\theta}}((\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y}) = \mathrm{Var}_{\boldsymbol{\theta}}((\Psi\Psi^\intercal)^{-1}\Psi(\Psi^\intercal\boldsymbol{\theta} + \varepsilon)) = \mathrm{Var}_{\boldsymbol{\theta}}((\Psi\Psi^\intercal)^{-1}\Psi\varepsilon)\\ &= \mathbb{E}_{\boldsymbol{\theta}}((\Psi\Psi^\intercal)^{-1}\Psi\varepsilon)(\Psi\Psi^\intercal)^{-1}\Psi\varepsilon)^\intercal = (\Psi\Psi^\intercal)^{-1}\Psi\mathbb{E}_{\boldsymbol{\theta}}[\varepsilon\varepsilon^\intercal]\Psi^\intercal(\Psi\Psi^\intercal)^{-1}\\ &= \sigma^2(\Psi\Psi^\intercal)^{-1}.\end{aligned}$$

Теперь перейдем к геометрической интерпретации оценки регрессионной функции $f(x) = \boldsymbol{\psi}(x)^\intercal\boldsymbol{\theta}$:
$$\widehat{f} = \Psi^\intercal\widehat{\boldsymbol{\theta}}_{LSE} = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y},$$
Обозначим
$$\Pi = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi \in \mathbb{R}^{n\times n}.$$

Определение 55 (Ортопроектор)**.** $A \in \mathbb{R}^{n\times n}$ – ортопроектор, если
$$A^\intercal = A, \quad \text{и} \quad A^2 = A.$$

Лемма 14. *Пусть* $\Pi = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi \in \mathbb{R}^{n\times n}$. *Тогда* Π – *ортопроектор.*

Доказательство. Непосредственно проверяется, что Π – ортопроектор, то есть $\Pi^\intercal = \Pi \quad$ и $\quad \Pi^2 = \Pi$:

1.
$$\Pi^\intercal = (\Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi)^\intercal = \Psi^\intercal(\Psi^\intercal(\Psi\Psi^\intercal)^{-1})^\intercal = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi = \Pi$$

2.
$$\Pi^2 = (\Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi)^\intercal \cdot (\Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi)^\intercal = (\Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi)^\intercal = \Pi.$$

□

Утверждение 7. $\widehat{f} = \Psi^\intercal\widehat{\boldsymbol{\theta}}_{LSE} \equiv \Pi\mathbf{Y}$ является проекцией вектора наблюдений на линейную оболочку строк матрицы плана Ψ, то есть на $\mathrm{Im}(\Psi^\intercal)$.

Доказательство. По лемме 14 Π является ортопроектором. Из определения ортопроектора следует, что все собственные значения матрицы Π удовлетворяют уравнению
$$\lambda^2 = \lambda,$$
то есть принимают значение либо 0, либо 1. Следовательно, все пространство $\mathbb{R}^n$ разбивается на прямую сумму собственного подпространства оператора Π, отвечающего значению 1, и его ядра. То есть Π задает ортогональную проекцию на некоторое линейное подпространство в $\mathbb{R}^n$. Покажем теперь, что Π – ортопроектор y на $\mathrm{Im}(\Psi^\intercal)$ (линейную оболочку строк матрицы плана).

1. Для начала покажем, что $\Pi u = u$ для любого $u \in \mathrm{Im}(\Psi^\intercal)$. Для любого $a \in \mathbb{R}^p$, $u := \Psi^\intercal a \in \mathrm{Im}(\Psi^\intercal)$, тогда

$$\Pi u = \Pi \Psi^\intercal a = \Psi^\intercal (\Psi\Psi^\intercal)^{-1}\Psi\Psi^\intercal a = \Psi^\intercal a = u.$$

   То есть $\Pi u = u$ для любого $u \in \mathrm{Im}(\Psi^\intercal)$.

2. осталось показать, что $\Pi v = 0$ для любого $v \in \mathrm{Im}(\Psi^\intercal)^\perp$. Рассмотрим $z \in \mathrm{Ker}(\Psi)$ и $x \in \mathbb{R}^n$

$$0 = \langle x, \Psi z\rangle = \langle \Psi^\intercal x, z\rangle = \langle \mathrm{Im}(\Psi^\intercal), z\rangle.$$

   Так как $z \in \mathrm{Ker}(\Psi)$, получаем, что $\mathrm{Im}(\Psi^\intercal) = \mathrm{Ker}(\Psi)^\perp$.

□

15.4 Оптимальная оценка. Теорема Гаусса-Маркова

Перейдем к рассмотрению статистических свойств оценки метода наименьших квадратов. Оказывается, что она является оптимальной в широком классе оценок при довольно слабых предположениях.

Теорема 30 (Гаусс, Марков)**.** *Пусть компоненты вектора $\boldsymbol{\varepsilon}$ независимы и $\mathbb{E}\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^\intercal = \sigma^2 I_n$. Тогда оценка $\widehat{\boldsymbol{\theta}}_{LSE} = (\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y}$ является оптимальной среди всех линейных несмещенных оценок параметра $\boldsymbol{\theta}$. Более того, если $\boldsymbol{\varepsilon} \sim \mathcal{N}(0, \sigma^2 I_n)$, то оценка $\widehat{\boldsymbol{\theta}}_{LSE}$ является оптимальной среди всех несмещенных оценок.*

Доказательство. 1. Рассмотрим произвольную несмещенную линейную оценку $\widetilde{\boldsymbol{\theta}} = A\mathbf{Y}$. Из условия несмещенности следует, что

$$\boldsymbol{\theta} = \mathbb{E}\widetilde{\boldsymbol{\theta}} = A\Psi^\intercal\boldsymbol{\theta} \quad \text{для всех } \boldsymbol{\theta} \in \mathbb{R}^p$$

Значит, $A\Psi^\intercal = I_p$. Рассмотрим ковариационную матрицу оценки $\widetilde{\boldsymbol{\theta}}$

$$\mathrm{Var}(\widetilde{\boldsymbol{\theta}}) = \mathrm{Var}(\widetilde{\boldsymbol{\theta}} + \widehat{\boldsymbol{\theta}}_{LSE} - \widehat{\boldsymbol{\theta}}_{LSE}) = \mathrm{Var}(\widehat{\boldsymbol{\theta}}) + \mathbb{E}\widehat{\boldsymbol{\theta}}_{LSE}(\widetilde{\boldsymbol{\theta}} - \widehat{\boldsymbol{\theta}}_{LSE})^\intercal + \mathbb{E}(\widetilde{\boldsymbol{\theta}} - \widehat{\boldsymbol{\theta}}_{LSE})\widehat{\boldsymbol{\theta}}^\intercal + \mathrm{Var}(\widetilde{\boldsymbol{\theta}} - \widehat{\boldsymbol{\theta}}).$$

Покажем, что $\mathbb{E}\widehat{\boldsymbol{\theta}}_{LSE}(\widetilde{\boldsymbol{\theta}} - \widehat{\boldsymbol{\theta}}_{LSE})^\intercal = O$, где $O \in \mathbb{R}^{p\times p}$ – матрица с нулевыми компонентами. В самом деле,

$$\begin{aligned}
\mathbb{E}\widehat{\boldsymbol{\theta}}_{LSE}(\widetilde{\boldsymbol{\theta}} - \widehat{\boldsymbol{\theta}}_{LSE})^\intercal &= \mathbb{E}(\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y}\mathbf{Y}^\intercal(A - (\Psi\Psi^\intercal)^{-1}\Psi)^\intercal \\
&= (\Psi\Psi^\intercal)^{-1}\Psi\mathbb{E}(\Psi^\intercal\boldsymbol{\theta} + \boldsymbol{\varepsilon})(\Psi^\intercal\boldsymbol{\theta} + \boldsymbol{\varepsilon})^\intercal(A - (\Psi\Psi^\intercal)^{-1}\Psi)^\intercal \\
&= \boldsymbol{\theta}(\boldsymbol{\theta})^\intercal\Psi(A - (\Psi\Psi^\intercal)^{-1}\Psi)^\intercal + (\Psi\Psi^\intercal)^{-1}\Psi\mathbb{E}\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^\intercal(A - (\Psi\Psi^\intercal)^{-1}\Psi)^\intercal \\
&= O + \sigma^2(\Psi\Psi^\intercal)^{-1}\Psi(A - (\Psi\Psi^\intercal)^{-1}\Psi)^\intercal = O.
\end{aligned}$$

Тогда

$$\mathrm{Var}(\widetilde{\boldsymbol{\theta}}) = \mathrm{Var}(\widehat{\boldsymbol{\theta}}_{LSE}) + \mathrm{Var}(\widetilde{\boldsymbol{\theta}} - \widehat{\boldsymbol{\theta}}).$$

Так как $\mathrm{Var}(\widetilde{\boldsymbol{\theta}} - \widehat{\boldsymbol{\theta}}_{LSE}) \succcurlyeq 0$, то $\mathrm{Var}(\widetilde{\boldsymbol{\theta}}) \succeq \mathrm{Var}(\widehat{\boldsymbol{\theta}}_{LSE})$, причем равенство достигается тогда и только тогда, когда $\widetilde{\boldsymbol{\theta}} = \widehat{\boldsymbol{\theta}}_{LSE}$ с вероятностью 1. Из положительной полуопределенности

матрицы $\mathrm{Var}(\widetilde{\boldsymbol{\theta}}) - \mathrm{Var}(\widehat{\boldsymbol{\theta}})$ следует, что $\mathrm{Tr}\big(\mathrm{Var}(\widetilde{\boldsymbol{\theta}})\big) \geqslant \mathrm{Tr}\big(\mathrm{Var}(\widehat{\boldsymbol{\theta}})\big)$. Используя несмещенность $\widetilde{\boldsymbol{\theta}}$ и теорему 2, получаем, что среднеквадратичная ошибка

$$\mathbb{E}\Big\|\widetilde{\boldsymbol{\theta}} - \boldsymbol{\theta}\Big\|^2 = \mathrm{Tr}\Big(\mathrm{Var}(\widetilde{\boldsymbol{\theta}})\Big).$$

Аналогично получаем, что среднеквадратичная ошибка

$$\mathbb{E}\Big\|\widehat{\boldsymbol{\theta}}_{LSE} - \boldsymbol{\theta}\Big\|^2 = \mathrm{Tr}\Big(\mathrm{Var}(\widehat{\boldsymbol{\theta}}_{LSE})\Big),$$

а значит,

$$\mathbb{E}\Big\|\widehat{\boldsymbol{\theta}}_{LSE} - \boldsymbol{\theta}\Big\|^2 = \mathrm{Tr}\Big[\mathrm{Var}(\widehat{\boldsymbol{\theta}}_{LSE})\Big] \geqslant \mathrm{Tr}\Big[\mathrm{Var}(\widetilde{\boldsymbol{\theta}}_{LSE})\Big] = \mathbb{E}\Big\|\widetilde{\boldsymbol{\theta}} - \boldsymbol{\theta}\Big\|^2,$$

что означает оптимальность оценки метода наименьших квадратов в классе всех линейных несмещенных оценок параметра $\boldsymbol{\theta}$. Заметим, что при доказательстве первого утверждения теоремы не использовалась гауссовость вектора ошибок $\boldsymbol{\varepsilon}$.

2. Теперь докажем вторую часть теоремы. Пусть $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, тогда $Y_i - \boldsymbol{\psi}(X_i)^\intercal\boldsymbol{\theta} \sim \mathcal{N}(0, \sigma^2)$, $i \in \{1, \ldots, n\}$. Напомним, что логарифм правдоподобия наблюдений $L(\mathbf{Y}, \boldsymbol{\theta})$ можно записать в виде (см. пример 2)

$$\ln p_{\boldsymbol{\theta}}(\mathbf{Y}) = -\frac{1}{2\sigma^2}\|\mathbf{Y} - \Psi^\intercal\boldsymbol{\theta}\|^2 - \frac{n}{2}\log\big(2\pi\sigma^2\big).$$

Найдем информационную матрицу Фишера:

$$I(\boldsymbol{\theta}) = -\mathbb{E}_{\boldsymbol{\theta}}\left(\frac{\partial^2 \ln p_{\boldsymbol{\theta}}(\mathbf{Y})}{\partial\boldsymbol{\theta}^2}\right) = \frac{1}{\sigma^2}\,\Psi\Psi^\intercal.$$

С другой стороны,

$$\mathrm{Var}_{\boldsymbol{\theta}}(\widehat{\boldsymbol{\theta}}_{LSE}) = \sigma^2(\Psi\Psi^\intercal)^{-1}.$$

Таким образом, $\mathrm{Var}_{\boldsymbol{\theta}}(\widehat{\boldsymbol{\theta}}_{LSE}) = I(\boldsymbol{\theta})^{-1}$.

То есть для оценки $\widehat{\boldsymbol{\theta}}_{LSE}$ достигается равенство в неравенстве Рао-Крамера, из чего следует ее эффективность, а значит и оптимальность.

□

15.5 Проверка гипотез в модели линейной регрессии

Рассмотрим модель линейной регрессии с гауссовским вектором ошибок

$$\mathbf{Y} = \Psi^\intercal\boldsymbol{\theta} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 I_n). \tag{49}$$

Здесь, как и ранее, $\mathbf{Y}, \boldsymbol{\varepsilon} \in \mathbb{R}^n$, $\boldsymbol{\theta} \in \mathbb{R}^p$, а $\Psi \in \mathbb{R}^{p\times n}$ – матрица ранга p. Предположим, что даны матрица $A \in \mathbb{R}^{r\times p}$ ранга $r \leqslant p$ и вектор $\mathbf{b} \in \mathbb{R}^r$ и выдвинута гипотеза

$$H_0 : A\boldsymbol{\theta} = \mathbf{b} \quad \text{против альтернативы} \quad H_1 : A\boldsymbol{\theta} \neq \mathbf{b}. \tag{50}$$

Необходимо проверить гипотезу H_0 на уровне значимости $\alpha \in (0, 1)$. Примером гипотезы H_0 вида (50) может быть гипотеза о равенстве двух компонент вектора $\boldsymbol{\theta}$ или гипотеза о

том, что последние r компонент $\boldsymbol{\theta}$ равны нулю. Последняя представляет и практический интерес, поскольку если с большой уверенностью можно утверждать, что r компонент $\boldsymbol{\theta}$ равны нулю, то модель (49) можно упростить без существенной потери качества оценивания, убрав соответствующие строки матрицы Ψ.

В основе идеи проверки гипотезы H_0 вида (50) лежит рассмотрение свойств оценок метода наименьших квадратов

$$\widetilde{\boldsymbol{\theta}} \in \operatorname*{argmin}_{\boldsymbol{\theta}: A\boldsymbol{\theta}=\mathbf{b}} \|Y - \Psi^{\mathsf{T}}\boldsymbol{\theta}\|^2 \quad \text{и} \quad \widehat{\boldsymbol{\theta}} \in \operatorname*{argmin}_{\boldsymbol{\theta}} \|Y - \Psi^{\mathsf{T}}\boldsymbol{\theta}\|^2 = (\Psi\Psi^{\mathsf{T}})^{-1}\Psi\mathbf{Y}.$$

Далее будет показано, что при сформулированных предположениях статистика

$$\frac{(\|\mathbf{Y} - \Psi^{\mathsf{T}}\widetilde{\boldsymbol{\theta}}\|^2 - \|\mathbf{Y} - \Psi^{\mathsf{T}}\widehat{\boldsymbol{\theta}}\|^2)/r}{\|\mathbf{Y} - \Psi^{\mathsf{T}}\widehat{\boldsymbol{\theta}}\|^2/(n-p)}$$

имеет распределение Фишера $F(r, n-p)$, но сначала получим явное выражение для оценки $\widetilde{\boldsymbol{\theta}}$.

Теорема 31 (Вид оценки в условном МНК)**.** *Пусть $\Psi \in \mathbb{R}^{p\times n}$ – матрица ранга p, $A \in \mathbb{R}^{r\times p}$ – матрица ранга $r \leqslant p$, и пусть $\mathbf{b} \in \mathbb{R}^r$. Обозначим*

$$\widetilde{\boldsymbol{\theta}} \in \operatorname*{argmin}_{\boldsymbol{\theta}: A\boldsymbol{\theta}=\mathbf{b}} \|Y - \Psi^{\mathsf{T}}\boldsymbol{\theta}\|^2 \quad \textit{и} \quad \widehat{\boldsymbol{\theta}} \in \operatorname*{argmin}_{\boldsymbol{\theta}} \|Y - \Psi^{\mathsf{T}}\boldsymbol{\theta}\|^2 = (\Psi\Psi^{\mathsf{T}})^{-1}\Psi\mathbf{Y}.$$

Тогда

$$\widetilde{\boldsymbol{\theta}} = \widehat{\boldsymbol{\theta}} - (\Psi\Psi^{\mathsf{T}})^{-1}A^{\mathsf{T}}(A(\Psi\Psi^{\mathsf{T}})^{-1}A^{\mathsf{T}})^{-1}(A\widehat{\boldsymbol{\theta}} - \mathbf{b}).$$

Доказательство. Запишем функцию Лагранжа

$$L(\boldsymbol{\theta}, \boldsymbol{\lambda}) = \|Y - \Psi^{\mathsf{T}}\boldsymbol{\theta}\|^2 + 2\boldsymbol{\lambda}^{\mathsf{T}}(A\boldsymbol{\theta} - \mathbf{b}).$$

Так как минимизация функции $\|Y - \Psi^{\mathsf{T}}\boldsymbol{\theta}\|^2$ на линейном подпространстве, задаваемом равенством $A\boldsymbol{\theta} = \mathbf{b}$, относится к задачам выпуклой оптимизации с линейными ограничениями, для ее решения достаточно найти стационарную точку $L(\boldsymbol{\theta}, \boldsymbol{\lambda})$. Приравнивая производные $L(\boldsymbol{\theta}, \boldsymbol{\lambda})$ по $\boldsymbol{\theta}$ и $\boldsymbol{\lambda}$ к нулю, получаем систему линейных уравнений

$$\begin{cases} \left.\frac{\partial L(\boldsymbol{\theta},\boldsymbol{\lambda})}{\partial \boldsymbol{\theta}}\right|_{\boldsymbol{\theta}=\widetilde{\boldsymbol{\theta}}} = 2\Psi(\Psi^{\mathsf{T}}\widetilde{\boldsymbol{\theta}} - \mathbf{Y}) + 2A^{\mathsf{T}}\boldsymbol{\lambda} = \mathbf{0}, \\ \left.\frac{\partial L(\boldsymbol{\theta},\boldsymbol{\lambda})}{\partial \boldsymbol{\lambda}}\right|_{\boldsymbol{\theta}=\widetilde{\boldsymbol{\theta}}} = 2(A\widetilde{\boldsymbol{\theta}} - \mathbf{b}) = \mathbf{0}. \end{cases}$$

Из первой части системы находим, что

$$\widetilde{\boldsymbol{\theta}} = (\Psi\Psi^{\mathsf{T}})^{-1}(\Psi\mathbf{Y} - A^{\mathsf{T}}\boldsymbol{\lambda}) = \widehat{\boldsymbol{\theta}} - (\Psi\Psi^{\mathsf{T}})^{-1}A^{\mathsf{T}}\boldsymbol{\lambda}.$$

Подставим это соотношение во вторую часть системы и найдем $\boldsymbol{\lambda}$. Из равенства

$$\mathbf{0} = A\widetilde{\boldsymbol{\theta}} - \mathbf{b} = A\widehat{\boldsymbol{\theta}} - \mathbf{b} - A(\Psi\Psi^{\mathsf{T}})^{-1}A^{\mathsf{T}}\boldsymbol{\lambda}$$

получаем, что

$$\boldsymbol{\lambda} = (A(\Psi\Psi^{\mathsf{T}})^{-1}A^{\mathsf{T}})^{-1}(A\widehat{\boldsymbol{\theta}} - \mathbf{b}).$$

Подставляя найденное значение $\widetilde{\boldsymbol{\lambda}}$ в выражение для $\widetilde{\boldsymbol{\theta}}$, приходим к формуле

$$\widetilde{\boldsymbol{\theta}} = \widehat{\boldsymbol{\theta}} - (\Psi\Psi^{\mathsf{T}})^{-1}A^{\mathsf{T}}(A(\Psi\Psi^{\mathsf{T}})^{-1}A^{\mathsf{T}})^{-1}(A\widehat{\boldsymbol{\theta}} - \mathbf{b}).$$

□

Перейдем к рассмотрению векторов остатков $(\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}})$ и $(\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}})$.

Лемма 15. *Введем*

$$\Pi = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi, \quad \Phi = A(\Psi\Psi^\intercal)^{-1}\Psi \quad \textit{и} \quad P = \Phi^\intercal(\Phi\Phi^\intercal)^{-1}\Phi.$$

Тогда

- $\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}} = (I - \Pi)\boldsymbol{\varepsilon}$;
- *если* $A\boldsymbol{\theta} = \mathbf{b}$, *то* $\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}} = (I - \Pi + P)\boldsymbol{\varepsilon}$.

Доказательство. Первое равенство следует непосредственно из определения $\widehat{\boldsymbol{\theta}}$:

$$\begin{aligned}\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}} &= (I - \Pi)\mathbf{Y} = (I - \Pi)(\Psi\boldsymbol{\theta}^* + \boldsymbol{\varepsilon}) \\ &= (I - \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi)\Psi\boldsymbol{\theta}^* + (I - \Pi)\boldsymbol{\varepsilon} = (I - \Pi)\boldsymbol{\varepsilon}.\end{aligned}$$

Докажем второе равенство. Согласно Теореме 31,

$$\begin{aligned}\Psi^\intercal\widetilde{\boldsymbol{\theta}} &= \Psi^\intercal\widehat{\boldsymbol{\theta}} - \Phi^\intercal(\Phi\Phi^\intercal)^{-1}(A\widehat{\boldsymbol{\theta}} - \mathbf{b}) \\ &= \Psi^\intercal\widehat{\boldsymbol{\theta}} - \Phi^\intercal(\Phi\Phi^\intercal)^{-1}(A(\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y} - \mathbf{b}) \\ &= \Pi\mathbf{Y} - \Phi^\intercal(\Phi\Phi^\intercal)^{-1}(\Phi\mathbf{Y} - \mathbf{b}).\end{aligned}$$

Подставляя $\mathbf{Y} = \Psi^\intercal\boldsymbol{\theta} + \boldsymbol{\varepsilon}$, получаем

$$\begin{aligned}\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}} &= (I - \Pi)\mathbf{Y} + \Phi^\intercal(\Phi\Phi^\intercal)^{-1}(\Phi\mathbf{Y} - \mathbf{b}) \\ &= (I - \Pi)\mathbf{Y} + \Phi^\intercal(\Phi\Phi^\intercal)^{-1}(\Phi\Psi^\intercal\boldsymbol{\theta}^* + \Phi\boldsymbol{\varepsilon} - \mathbf{b}) \\ &= (I - \Pi)\mathbf{Y} + \Phi^\intercal(\Phi\Phi^\intercal)^{-1}(A(\Psi\Psi^\intercal)^{-1}\Psi\Psi^\intercal\boldsymbol{\theta}^* + \Phi\boldsymbol{\varepsilon} - \mathbf{b}) \\ &= (I - \Pi)\mathbf{Y} + \Phi^\intercal(\Phi\Phi^\intercal)^{-1}(A\boldsymbol{\theta}^* + \Phi\boldsymbol{\varepsilon} - \mathbf{b}) \\ &= (I - \Pi)\mathbf{Y} + \Phi^\intercal(\Phi\Phi^\intercal)^{-1}(A\boldsymbol{\theta}^* - \mathbf{b}) + P\boldsymbol{\varepsilon}.\end{aligned}$$

Если $A\boldsymbol{\theta} = \mathbf{b}$, то второе слагаемое обращается в нуль, а следовательно, выполнено равенство

$$\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}} = (I - \Pi)\mathbf{Y} + P\boldsymbol{\varepsilon} = (I - \Pi)\boldsymbol{\varepsilon} + P\boldsymbol{\varepsilon} = (I - \Pi + P)\boldsymbol{\varepsilon}.$$

□

Лемма 16. *Матрицы* Π *и* P *– ортопроекторы.*

Доказательство. Непосредственно проверяется, что $\Pi^\intercal = \Pi$, $P^\intercal = P$ и

$$\Pi^2 = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi\Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi = \Pi.$$

Обозначив $\Phi = A(\Psi\Psi)^\intercal\Psi \in \mathbb{R}^{r\times p}$, получаем, что $P = \Phi^\intercal(\Phi\Phi^\intercal)^{-1}\Phi$, а следовательно,

$$P^2 = \Phi^\intercal(\Phi\Phi^\intercal)^{-1}\Phi\Phi^\intercal(\Phi\Phi^\intercal)^{-1}\Phi = \Phi^\intercal(\Phi\Phi^\intercal)^{-1}\Phi = P.$$

Значит, Π и P – ортопроекторы. □

Причем Π – проектор на линейную оболочку столбцов матрицы $\Psi^\intercal$, а P – на линейную оболочку столбцов $\Phi^\intercal$. Заметим, что $\mathrm{Im}(\Phi^\intercal) \subseteq \mathrm{Im}(\Psi^\intercal)$, а значит, $\mathrm{Im}(P) \subseteq \mathrm{Im}(\Pi)$. Другими словами, P – проектор на подпространство в образе Π. Используя равенство $\mathrm{Tr}(AB) = \mathrm{Tr}(BA)$, выполненное для всех матриц A и B, для которых определены произведения AB и BA, получаем, что

$$\mathrm{Tr}(\Pi) = \mathrm{Tr}(\Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi) = \mathrm{Tr}((\Psi\Psi^\intercal)^{-1}\Psi\Psi^\intercal) = \mathrm{Tr}(I_p) = p$$

и

$$\mathrm{Tr}(P) = \mathrm{Tr}(\Phi^\intercal(\Phi\Phi^\intercal)^{-1}\Phi) = \mathrm{Tr}((\Phi\Phi^\intercal)^{-1}\Phi\Phi^\intercal) = \mathrm{Tr}(I_r) = r.$$

Таким образом, Π – проектор на линейное подпространство в $\mathbb{R}^n$ размерности p, а P – ортопроектор на собственное подпространство в $\mathrm{Im}(\Pi)$ размерности r.

Лемма 17. *Пусть вектор X имеет нормальное распределение $\mathcal{N}(\mu, \Sigma_n)$. Тогда для произвольной матрицы $B \in \mathbb{R}^{m\times n}$ вектор BX имеет нормальное распределение $\mathcal{N}(B\mu, B\Sigma_n B^\intercal)$.*

Доказательство. Хаактеристическая функция для вектора $\xi \sim N(\mu, \Sigma)$:

$$\varphi_\xi(t) = \mathbb{E}_\xi e^{i<t,\xi>} = \exp\{i < t, \mu > -\frac{1}{2} < t, \Sigma t >\}$$

Характеристическая функция для вектора $A\xi$:

$$\varphi_{A\xi}(t) = \mathbb{E}e^{i<t,A\xi>} = \mathbb{E}e^{i<A^\intercal t,\xi>} = \varphi_\xi(A^\intercal t) =$$

$$= \exp\{i < A^\intercal t, \mu > -\frac{1}{2} < A^\intercal t, \Sigma A^\intercal t >= \exp\{i < t, A\mu > -\frac{1}{2} < t, A\Sigma A^\intercal t >\}$$

$$\Rightarrow A\xi \sim N(A\mu, A\Sigma A^\intercal)$$

□

Лемма 18. *Пусть вектор X имеет стандартное нормальное распределение $\mathcal{N}(0, I_n)$ и пусть B – ортопроектор. Тогда $Q = X^\intercal BX$ имеет распределение хи-квадрат $\chi^2(\mathrm{tr}\, B)$.*

Доказательство. Приведем B к диагональному виду через собственное разложение

$$B = UDU^{-1},$$

где матрица $D = \mathrm{diag}\{\lambda_1, \ldots, \lambda_n\}$ – диагональная матрица из собственных значений матрицы B. Так как B – симметричная матрица, то матрица U будет ортогональная

$$UU^\intercal = I = U^\intercal U \longrightarrow U^\intercal = U^{-1}.$$

Значит

$$B = UDU^\intercal.$$

Рассмотрим

$$Q = X^\intercal BX = X^\intercal UDU^\intercal X = \langle X, UDU^\intercal X\rangle = \langle U_\intercal X, DU^\intercal X\rangle.$$

Обозначим $Z = U^\intercal X$. По лемме 17 Z будет иметь также стандартное нормальное распределение $\mathcal{N}(0, I_n)$. У ортопроектора все собственные значения

$$\lambda_i = \begin{cases} 0 \\ 1 \end{cases}, \quad i = 1 \ldots, n$$

Значит,

$$Q = Y^\intercal DY = \sum_{i=1}^{n} \lambda_i Y_i^2 = \sum_{i:\lambda_i=1}^{n} Y_i^2 \sim \chi^2(\operatorname{tr} D) = \chi^2(\operatorname{tr} B).$$

□

Лемма 19. *Пусть* $\Pi = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi$. *Тогда* $\frac{1}{\sigma^2}\|\Pi\boldsymbol{\varepsilon}\|^2$ *имеет распределение хи-квадрат* $\chi^2(p)$.

Доказательство. Так как Π – это ортопроектор, получаем

$$\frac{1}{\sigma^2}\|\Pi\boldsymbol{\varepsilon}\|^2 = \frac{1}{\sigma^2}\langle\Pi\boldsymbol{\varepsilon}, \Pi\boldsymbol{\varepsilon}\rangle = \frac{1}{\sigma^2}\boldsymbol{\varepsilon}\Pi\boldsymbol{\varepsilon}.$$

Далее заметим, что вектор $\frac{1}{\sigma}\boldsymbol{\varepsilon} \sim \mathcal{N}(0, I_n)$ имеет стандартное нормальное распределение. Тогда по лемме 18 получаем требуемое утверждение. □

Теорема 32. *Пусть имеет место модель линейной регрессии* (49) *с гауссовским вектором ошибок. Пусть* $A\boldsymbol{\theta} = \mathbf{b}$. *Тогда случайные величины* $\frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}}\|^2 - \frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2$ *и* $\frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2$ *независимы и имеют распределения* $\chi^2(r)$ *и* $\chi^2(n-p)$ *соответственно.*

Доказательство. В силу Леммы 15, $\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2 = \|(I - \Pi)\boldsymbol{\varepsilon}\|^2$ и

$$\begin{aligned}\|\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}}\|^2 - \|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2 &= \|(I - \Pi + P)\boldsymbol{\varepsilon}\|^2 - \|(I - \Pi)\boldsymbol{\varepsilon}\|^2 \\ &= \boldsymbol{\varepsilon}^\intercal(I - \Pi + P)\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}^\intercal(I - \Pi)\boldsymbol{\varepsilon} \\ &= \boldsymbol{\varepsilon}^\intercal P\boldsymbol{\varepsilon} = \|P\boldsymbol{\varepsilon}\|^2.\end{aligned}$$

Заметим, что $P\boldsymbol{\varepsilon}$ и $(I - \Pi)\boldsymbol{\varepsilon}$ являются линейными преобразованиями гауссовского вектора $\boldsymbol{\varepsilon} \sim \mathcal{N}(0, \sigma^2 I_n)$. При этом

$$\mathbb{E}P\boldsymbol{\varepsilon}((I - \Pi)\boldsymbol{\varepsilon})^\intercal = \sigma^2 P(I - \Pi)^\intercal = O,$$

то есть $P\boldsymbol{\varepsilon}$ и $(I - \Pi)\boldsymbol{\varepsilon}$ являются некоррелированными, а значит, независимыми. Следовательно, случайные величины $\|\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}}\|^2 - \|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2$ и $\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2$ также являются независимыми. Аналогично Лемме 19 получаем, что $\frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}}\|^2 - \frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2 \sim \chi^2(r)$ и $\frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2 \sim \chi^2(n-p)$.

□

Следствие 6. *В условиях Теоремы 32 статистика*

$$\frac{(\|\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}}\|^2 - \|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2)/r}{\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2/(n-p)}$$

имеет распределение Фишера $F(r, n-p)$.

Следствие 6 позволяет сформулировать критерий для проверки гипотезы $H_0 : A\boldsymbol{\theta} = \mathbf{b}$. Если H_0 верна, то

$$T = \frac{(\|\mathbf{Y} - \Psi^\intercal\widetilde{\boldsymbol{\theta}}\|^2 - \|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2)/r}{\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2/(n-p)} \sim F(r, n-p).$$

Наоборот, большие значения тестовой статистики T свидетельствуют в пользу гипотезы H_1. Поэтому будем отвергать гипотезу H_0 в том и только том случае, когда T превышает $(1-\alpha)$-квантиль распределения Фишера $F(r, n-p)$.

15.6 Интервальное оценивание в модели наименьших квадратов

Рассмотрим задачу построения доверительных множеств для вектора $\boldsymbol{\theta}^*$ в модели (49) и каждой из его компонент. Как и ранее, считаем, что $\det(\Psi\Psi^\intercal) \neq 0$.

Лемма 20. *В условиях модели (49), случайные векторы $\widehat{\boldsymbol{\theta}} = (\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y}$ и $(\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}})$ независимы. Более того, $\frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2$ имеет распределение $\chi^2(n-p)$.*

Доказательство. Во-первых, заметим, что

$$\widehat{\boldsymbol{\theta}} = (\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y} = (\Psi\Psi^\intercal)^{-1}\Psi(\Psi^\intercal\boldsymbol{\theta}^* + \boldsymbol{\varepsilon}) = \boldsymbol{\theta}^* + (\Psi\Psi^\intercal)^{-1}\Psi\boldsymbol{\varepsilon}$$

и

$$\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}} = \mathbf{Y} - \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi\mathbf{Y} = (I - \Pi)\mathbf{Y},$$

где $\Pi = \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi$ – ортогональный проектор на $\mathrm{Im}(\Psi^\intercal)$. Так как $(I - \Pi)\Psi^\intercal = \Psi - \Psi^\intercal(\Psi\Psi^\intercal)^{-1}\Psi\Psi^\intercal = O$, имеем

$$(I - \Pi)\mathbf{Y} = (I - \Pi)(\Psi^\intercal\boldsymbol{\theta}^* + \boldsymbol{\varepsilon}) = (I - \Pi)\boldsymbol{\varepsilon}$$

и, более того,

$$\mathbb{E}(I - \Pi)\boldsymbol{\varepsilon}\big((\Psi\Psi^\intercal)^{-1}\Psi\boldsymbol{\varepsilon}\big)^\intercal = \mathbb{E}(I - \Pi)\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^\intercal\Psi^\intercal(\Psi\Psi^\intercal)^{-1} = \sigma^2(I - \Pi)\Psi^\intercal(\Psi\Psi^\intercal)^{-1} = O.$$

То есть векторы $\widehat{\boldsymbol{\theta}}$ и $(\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}})$ некоррелированы и получены из нормального случайного вектора $\boldsymbol{\varepsilon}$ линейными преобразованиями. Значит, они независимы. Доказательство того, что $\frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2 \sim \chi^2(n-p)$, полностью аналогично доказательству Леммы 19.

□

Пример 31 (Доверительный интервал для компонент вектора $\boldsymbol{\theta}$ при известной σ^2.)**.** Обратимся теперь к задаче построения доверительных интервалов для компонент вектора $\boldsymbol{\theta}$. Для начала предположим, что параметр σ^2 известен. Тогда

$$\widehat{\boldsymbol{\theta}} = \boldsymbol{\theta} + (\Psi\Psi^\intercal)^{-1}\Psi\boldsymbol{\varepsilon} \sim \mathcal{N}(\boldsymbol{\theta}, \sigma^2(\Psi\Psi^\intercal)^{-1}),$$

из чего делаем вывод, что для любого $j \in \{1, \ldots, p\}$

$$\widehat{\theta}_j - \theta_j \sim \mathcal{N}(0, \sigma^2(\Psi\Psi^\intercal)^{-1}_{jj}),$$

то есть

$$\frac{\widehat{\theta}_j - \theta_j}{\sigma\sqrt{(\Psi\Psi^\intercal)^{-1}_{jj}}} \sim \mathcal{N}(0,1)$$

является центральной статистикой. Построим с ее помощью доверительный интервал для $\widehat{\theta}_j$ при некотором фиксированном $j \in \{1, \ldots, p\}$. Зафиксируем $\gamma \in (0,1)$. Тогда

$$\left(\widehat{\theta}_j - \sigma\mathcal{N}_{(1+\gamma)/2}(0,1)\sqrt{(\Psi\Psi^\intercal)^{-1}_{jj}}, \widehat{\theta}_j + \sigma\mathcal{N}_{(1+\gamma)/2}(0,1)\sqrt{(\Psi\Psi^\intercal)^{-1}_{jj}}\right)$$

является искомым γ-доверительным интервалом.

Пример 32 (Доверительный интервал для компонент вектора $\boldsymbol{\theta}$ при неизвестной σ^2.)**.** В случае, когда значение σ неизвестно, воспользуемся результатом Леммы 20, согласно которой

$$\frac{\widehat{\theta}_j - \theta_j}{\sigma\sqrt{(\Psi\Psi^\intercal)^{-1}_{jj}}} \sim \mathcal{N}(0,1), \quad \frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2 \sim \chi^2(n-p),$$

причем эти случайные величины независимы. Значит, в данном случае в качестве центральной статистики можно взять

$$\frac{(\widehat{\theta}_j - \theta_j)\sqrt{n-p}}{\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|\sqrt{(\Psi\Psi^\intercal)^{-1}_{jj}}},$$

которая имеет распределение Стьюдента $\mathrm{t}(n-p)$. Тогда для любого $\gamma \in (0,1)$

$$\left(\widehat{\theta}_j - \widehat{\sigma}\ \mathrm{t}_{(1+\gamma)/2}\sqrt{(\Psi\Psi^\intercal)^{-1}_{jj}},\ \widehat{\theta}_j + \widehat{\sigma}\ \mathrm{t}_{(1+\gamma)/2}\sqrt{(\Psi\Psi^\intercal)^{-1}_{jj}}\right), \quad \text{где} \quad \widehat{\sigma} = \frac{\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|}{\sqrt{n-p}},$$

является γ-доверительным интервалом для θ_j.

Пример 33 (Доверительное множество для $\boldsymbol{\theta}$)**.** Используя леммы 19 и 20 несложно построить доверительное множество для $\boldsymbol{\theta}$. В самом деле, случайные векторы $\Psi^\intercal\widehat{\boldsymbol{\theta}} = \Psi^\intercal\boldsymbol{\theta} + \Pi\boldsymbol{\varepsilon}$ и $(\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}})$ независимы, и, более того,

$$\|\Psi^\intercal\widehat{\boldsymbol{\theta}} - \Psi^\intercal\boldsymbol{\theta}\|^2 = \frac{1}{\sigma^2}\|\Pi\boldsymbol{\varepsilon}\|^2 \sim \chi^2(p), \quad \frac{1}{\sigma^2}\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2 \sim \chi^2(n-p),$$

а значит,

$$\frac{(n-p)\|\Psi^\intercal\widehat{\boldsymbol{\theta}} - \Psi^\intercal\boldsymbol{\theta}\|^2}{p\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2} \sim F(p, n-p).$$

Следовательно,

$$\mathbb{P}\left(\frac{(n-p)\|\Psi^\intercal\widehat{\boldsymbol{\theta}} - \Psi^\intercal\boldsymbol{\theta}\|^2}{p\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2} \leqslant F_\gamma(p, n-p)\right) = \gamma,$$

а значит, эллипсоид

$$\left\{\boldsymbol{\theta} : \frac{(n-p)\|\Psi^\intercal\widehat{\boldsymbol{\theta}} - \Psi^\intercal\boldsymbol{\theta}\|^2}{p\|\mathbf{Y} - \Psi^\intercal\widehat{\boldsymbol{\theta}}\|^2} \leqslant F_\gamma(p, n-p)\right\}$$

является γ-доверительным множеством для параметра $\boldsymbol{\theta}^*$.

Список литературы

Ю.И Ивченко, Г.И. Медведев. *Математическая статистика.* 2010.