Машинное обучение 1
Экзамен
Вариант 1

Задача 1 (2.5 балла). Ответьте на вопросы о линейных методах (и не только):

1. Ниже приведены функции потерь для задачи бинарной классификации. Они заданы через M — отступ на объекте. Объясните для каждой функции потерь, к какими проблемам при обучении модели она может привести.

   - $L_1(M) = \max(0, 1 + M)$;
   - $L_2(M) = \log(1 + \exp(M))$;
   - $L_3(M) = (1 + M)^2$;
   - $L_4(M) = \sin(M)$.

2. Рассмотрим следующий способ кодирования категориального признака x_j для задачи бинарной классификации:

   $$g(x_j, X) = \frac{1}{\sum_{i=1}^{\ell}([y_i = +1] + [y_i = -1])} \sum_{i=1}^{\ell} [x_{ij} = x_j] y_i [y_i = +1],$$

   где ℓ — число объектов. Какие вы видите потенциальные проблемы у такого подхода? Как их исправить?

3. Рассмотрим линейную модель регрессии, обучаемую на MSE (без регуляризации) идеальным методом оптимизации, который всегда находит глобальный минимум ошибки. Будем называть этот подход базовым. Ответьте на вопросы, обоснуйте ваши ответы:

   - Будем теперь обучать модель стохастическим градиентным спуском, причём делать им только 5 шагов. Как изменится смещение относительно базового подхода?
   - Удалим из выборки половину признаков. Считаем, что эти признаки были информативными, то есть несли в себе уникальную информацию о целевой переменной. Как изменятся смещение и разброс?
   - Добавим к функционалу ошибки L_2-регуляризатор (то есть сумму квадратов весов). Что произойдёт со смещением и разбросом?

Задача 2 (2.5 балла). Ответьте на вопросы о регуляризации:

1. Рассмотрим регуляризатор $R_{\alpha,\beta}(w) = \frac{1}{1+\exp(\alpha\|w\|_2^2+\beta)}$. При каких значениях α и β он будет действовать как настоящий регуляризатор (то есть штрафовать модель за большие веса)?

2. Снова рассмотрим регуляризатор $R_{\alpha,\beta}(w)$ и предположим, что гиперпараметры α и β принимают только адекватные значения, выведенные вами в прошлом пункте. Как эти гиперпараметры будут влиять на работу регуляризатора? Что будет происходить при увеличении α? А при увеличении β?

3. На лекциях разбирались L_1- и L_2-нормы для регуляризации. Какой эффект по сравнению с ними будет иметь $L_{0.5}$-регуляризатор $\sum_{j=1}^{d} \sqrt{|w_j|}$? А $L_{\min}$-регуляризатор $\min_{j=1,\ldots,d} |w_j|$? А L_Π-регуляризатор $\prod_{j=1}^{d} |w_j|$? Обоснуйте ответы. Какие сложности могут возникнуть при обучении на каждый из этих регуляризаторов?

Задача 3 (1.25 балла). Ответьте на вопросы о решающих деревьях и композициях моделей:

1. Вы собираетесь обучать градиентный бустинг над деревьями для предсказания стоимости квартиры. Руководитель поставил вам требование: если вы возьмёте какой-либо объект и будете увеличивать признак «площадь» (при фиксированных остальных признаках), то прогноз модели должен монотонно расти. Гарантированно добиться этого достаточно сложно, но предложите какой-нибудь подход, который заметно повысит шансы на монотонность зависимости прогноза от площади.

2. В LightGBM для ускорения обучения используется эвристика GOSS. Перед обучением базовой модели $b_N(x)$ все объекты обучающей выборки сортируются по убыванию модуля сдвига $|s_i|$. После этого в выборке оставляют первые $a * 100\%$ объектов, а из следующих по порядку объектов оставляют случайные $b*100\%$ штук, где $a, b \in (0, 1)$. При этом просемплированным $b*100\%$ выставляется вес $\frac{1-a}{b}$. Зачем это делается? Что может произойти, если не проставить такие веса?

Задача 4 (2.5 балла). Напомним, что разложение ошибки на шум, смещение и разброс выглядит так:

$$L(\mu) = \underbrace{\mathbb{E}_{x,y}\Big[\big(y - \mathbb{E}[y \,|\, x]\big)^2\Big]}_{\text{шум}} +$$

$$+ \underbrace{\mathbb{E}_x\Big[\big(\mathbb{E}_X\big[\mu(X)\big] - \mathbb{E}[y \,|\, x]\big)^2\Big]}_{\text{смещение}} + \underbrace{\mathbb{E}_x\Big[\mathbb{E}_X\Big[\big(\mu(X) - \mathbb{E}_X\big[\mu(X)\big]\big)^2\Big]\Big]}_{\text{разброс}}.$$

Пусть $x \in \mathbb{R}^d$, и значение каждого признака на объекте x независимо генерируется из нормального распределения: $x_i \sim \mathcal{N}(0, 1)$, $i = 1, \ldots, d$. Будем считать, что объекты в выборке независимы, а $\mathbb{E}[y|x] = x^T x$. Найдите смещение константного алгоритма: $\mu(X)(x) = C = \text{const}$.
Напомним, что для стандартного распределения $\mathbb{E}[x^2] = 1,\ \mathbb{E}[x^4] = 3$.

Задача 5 (1.25 балла). Ответьте на вопросы по задаче кластеризации:

1. Вам удалось заполучить правильные ответы для задачи кластеризации, но в весьма необычном формате. Вам дан набор индексов $T = (i_n, j_n)_{n=1}^N$ такой, что если $(i, j) \in T$, то объекты x_i и x_j должны оказаться в одном кластере. Также дан набор индексов $F = (i_m, j_m)_{m=1}^M$ такой, что если $(i, j) \in F$, то объекты x_i и x_j должны оказаться в разных кластерах. Предложите метрику, которая отражает соответствие кластеризации, выданной вашим алгоритмом, описанной разметке.

2. У вас есть выборка, состоящая из объектов как с вещественными признаками, так и с категориальными. Вы хотите кластеризовать ее с помощью K-Means. Как можно адаптировать этот метод для учета категориальных признаков?