Машинное обучение 1
Экзамен
Вариант 1

Задача 1 (2.5 балла). Ответьте на вопросы о линейных моделях:

1. Запишите формулу для линейной регрессии. Почему мы не можем использовать линейную регрессию для решения задачи классификации напрямую? Предложите не менее двух вариантов, как можно изменить формулу линейной регрессии, чтобы она была способна решить задачу классификации. Поясните, почему каждое изменение должно помочь решить задачу.

2. Известно, что модель бинарной линейной классификации делит пространство на две части гиперплоскостью. Для каждого объекта в обучающей выборке мы можем посчитать скалярное произведение признаков и весов модели, а также отступ классификатора на данном объекте. Поясните, как можно проинтерпретировать значение скалярного произведения и отступа для конкретного объекта. Попробуйте провести рассуждение с использованием понятия гиперплоскость.

3. Известно, что в случае переобучения модели линейной регрессии вам может помочь регуляризация, которая штрафует слишком большие веса. Ниже перечислено несколько вариантов регуляризации. Для каждого из них прокомментируйте, является ли он осмысленным или же он приведёт к некорректной работе алгоритма — перестанет штрафовать большие веса. Через w оозначен вектор весов модели.

   - $\lambda||w||_2^2$
   - $\lambda||w||_1$
   - $\lambda||-w||_2^2$
   - $\lambda||w||_2^2 + \mu||w||_1$
   - $0.5||w||_1$
   - $\lambda||w||_2^2 - \mu||w||_1$

4. Считается, что для обучения линейной модели после кодирования категориального признака методом One-Hot Encoding нужно убрать один из получившихся новых признаков (столбцов). Объясните, почему. Можно ли решить эту же проблему другими методами? Если да, то назовите хотя бы один такой метод и коротко объясните, почему он, действительно, решает проблему.

Задача 2 (2.5 балла). Ответьте на вопросы о решающих деревьях и композициях моделей:

1. Иногда в Random Forest используют дополнительную рандомизацию: при построении вершины выбирается (как обычно) случайное подмножество признаков, для каждого признака оттуда генерируется случайный набор порогов, и лучший предикат ищется только среди этих признаков и порогов. Как это изменение влияет на смещение и разброс композиции? Обоснуйте ваш ответ (здесь предполагаются рассуждения, а не строгий формальный вывод).

2. Рассмотрим следующий способ обучения базовой модели в градиентном бустинге для функции потерь $L(y, z)$:

   $$\frac{1}{\ell}\sum_{i=1}^{\ell} L(s_i, b_N(x_i)) \to \min_{b_N}; \quad s_i = \left.\frac{\partial L(y_i, z)}{\partial z}\right|_{z=b_{N-1}(x_i)}$$

   Найдите все ошибки в этих формулах. Объясните, почему это ошибки.

3. Мы решаем задачу регрессии, где целевая переменная представляет собой количество осадков в миллиметрах, а все признаки являются метеорологическими измерениями.

   (а) Предположим, что вы обучаете обычное решающее дерево на этом наборе данных, используя MSE в качестве функции потерь. Может ли дерево давать прогнозы, которые физически нереалистичны (например, отрицательные осадки)? Объясните, почему это может или не может произойти и какие подходы могут помочь это предотвратить, в случае, если это возможно.

   (б) Поясните, как прогнозы отдельных деревьев в случайном лесе и в градиентном бустинге могут отличаться с точки зрения физического реализма. Какие механизмы в этих методах помогают уменьшить риск нереалистичных прогнозов?

Задача 3 (2.5 балла). Ответьте на вопросы о регуляризации:

1. Рассмотрим регуляризатор $R_{\alpha,\beta}(w) = \frac{1}{1+\exp(\alpha\|w\|_2^2+\beta)}$. При каких значениях α и β он будет действовать как настоящий регуляризатор (то есть штрафовать модель за большие веса)?

2. Снова рассмотрим регуляризатор $R_{\alpha,\beta}(w)$ и предположим, что гиперпараметры α и β принимают только адекватные значения, выведенные вами в прошлом пункте. Как эти гиперпараметры будут влиять на работу регуляризатора? Что будет происходить при увеличении α? А при увеличении β?

3. На лекциях разбирались L_1- и L_2-нормы для регуляризации. Какой эффект по сравнению с ними будет иметь $L_{0.5}$-регуляризатор $\sum_{j=1}^{d}\sqrt{|w_j|}$? А $L_{\min}$-регуляризатор $\min_{j=1,\ldots,d}|w_j|$? А L_Π-регуляризатор $\prod_{j=1}^{d}|w_j|$? Обоснуйте ответы. Какие сложности могут возникнуть при обучении на каждый из этих регуляризаторов?

Задача 4 (1.25 балла). Рассмотрим модель $b(x)$, которая выдаёт уверенность в положительности объекта x, причём выходы этой модели лежат на отрезке $[0,1]$. Известно, что AUC-ROC можно увеличить, если добавить в выборку лёгкие отрицательные объекты — то есть такие объекты x_i, для которых $y_i = -1$ и $b(x_i) \approx 0$.

Для борьбы с этим эффектом введём метрику AUC-ROC@k, которая равна площади под ROC-кривой, построенной лишь по k объектам с наибольшими значениями $b(x)$. Ответьте на вопросы:

1. Чему будет равно значение AUC-ROC@k для идеальной модели?

2. Чему будет равно значение AUC-ROC@k для случайной модели?

Задача 5 (2.5 балла). Рассмотрим одномерную выборку $X = (x_1, \ldots, x_\ell)$, $x_i \in \mathbb{R}$, ответы для объектов которой генерируются из зашумлённой линейной модели:

$$y = w_* x + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0,1).$$

Будем считать, что выборка X фиксирована и не является случайной, а случайность, соответственно, присутствует лишь в ответах:

$$p(y_i \,|\, x_i) = \mathcal{N}(w_* x, \sigma^2).$$

Решать задачу будем с помощью линейных моделей вида $a(x) = wx$. Метод обучения $\mu(X)$ находит вес $\hat{w}$ путём минимизации регуляризованной среднеквадратичной ошибки:

$$\hat{w} = \arg\min_{w\in\mathbb{R}} \left\{ \sum_{i=1}^{\ell} (wx_i - y_i)^2 + \lambda w^2 \right\}.$$

Найдите смещение и разброс для фиксированного тестового объекта x. К чему они будут стремиться при $\lambda \to 0$ и при $\lambda \to +\infty$? Кто из них будет давать основной вклад в среднеквадратичный риск в каждом из случаев?

Задача 6 (1.25 балла). Ответьте на вопросы по задаче кластеризации:

1. Вам удалось заполучить правильные ответы для задачи кластеризации, но в весьма необычном формате. Вам дан набор индексов $T = (i_n, j_n)_{n=1}^N$ такой, что если $(i, j) \in T$, то объекты x_i и x_j должны оказаться в одном кластере. Также дан набор индексов $F = (i_m, j_m)_{m=1}^M$ такой, что если $(i, j) \in F$, то объекты x_i и x_j должны оказаться в разных кластерах. Предложите метрику, которая отражает соответствие кластеризации, выданной вашим алгоритмом, описанной разметке.

2. У вас есть выборка, состоящая из объектов как с вещественными признаками, так и с категориальными. Вы хотите кластеризовать ее с помощью K-Means. Как можно адаптировать этот метод для учета категориальных признаков?