Машинное обучение 1
Контрольная работа

Задача 1 (1.5 балла). Ответьте на вопросы (везде требуется вывод или обоснование):

1. Рассмотрим функцию потерь $L_c(y, z) = e^{-yz}$. Позволяет ли она корректно оценивать вероятности? Напомним, что для этого должно быть выполнено условие $\arg\min_{b\in\mathbb{R}}\mathbb{E}(L(y, b)\,|\,x) = p(y = +1\,|\,x)$.

2. Представьте, что вы совсем устали и решили, что с этого момента используете только константные модели $a(x) = c$, где $c \in \mathbb{R}$. Вам дали обучающую выборку $X = (x_i, y_i)_{i=1}^{\ell}$ для бинарной классификации $y_i \in \{-1, +1\}$, вы по ней построили модель $a(x) = 5$. Возможно ли откалибровать эту модель так, что она станет выдавать корректную вероятность на обучающей выборке? Если да, то как это сделать? Если нет, то почему?

3. Вы неплохо отдохнули и решили перейти от константных моделей к решающим пням (то есть к деревьям глубины 1, представляющим из себя один предикат и два листа). Вам снова дали некоторую обучающую выборку для задачи бинарной классификации, и вы построили по ней решающий пень. Можно ли его сделать калиброванным для обучающей выборки, изменяя лишь прогнозы в листьях? Если да, то как это сделать? Если нет, то почему?

Задача 2 (1 балл). Рассмотрим обобщённую задачу метода опорных векторов:

$$\begin{cases} \|w\|^p + C\sum\limits_{i=1}^{\ell}\xi_i^q \to \min\limits_{w,b,\xi} \\ y_i\left(\langle w, x_i\rangle + b\right) \geqslant 1 - \xi_i, \quad i = 1, \ldots, \ell, \\ \xi_i \geqslant 0, \quad i = 1, \ldots, \ell. \end{cases} \tag{0.1}$$

Считайте, что $p > 0$, $q > 0$. Ответьте на вопросы:

1. Запишите эту задачу оптимизации в безусловном виде.

2. Как гиперпараметры p и q влияют на задачу? Опишите, как будет меняться решение при уменьшении и увеличении каждого из этих гиперпараметров.

Задача 3 (2.5 балла). Напомним формулу для пересчёта входных векторов $x_1, \ldots, x_n$ в выходные $z_1, \ldots, z_n$ в механизме self-attention:

$$z_j = \sum_{p=1}^{n} \frac{\exp\left(\langle q_j, k_p\rangle/\sqrt{d}\right)}{\sum_{s=1}^{n}\exp\left(\langle q_j, k_s\rangle/\sqrt{d}\right)} v_p.$$

Ответьте на вопросы:

1. Известно, что в блоке self-attention используется «многоголовое» внимание. Допустим, мы решили понизить сложность нашей архитектуры и добавили ограничение: в каждой «голове» используются одни и те же матрицы. Иными словами, если W_K^i, W_Q^i, W_V^i — матрицы из i-й головы, то $W_K^1 = W_K^2 = \cdots = W_K^n$, и аналогично для W_Q и W_V. Имеет ли смысл такое ограничение? К чему приведёт его использование?

2. Продолжаем исследовать возможности упрощения self-attention. Теперь избавимся от параметров в принципе и сделаем все матрицы единичными: $W_K = W_Q = W_V = I$. Получится, что они никак не меняют векторы, поступающие на вход. Будет ли self-attention иметь смысл в таком случае?

3. Мы прекратили лезть в матрицы параметров, но теперь хотим упростить механизм за счёт суммирования. Новая версия выглядит так:

$$z_j = \sum_{p=1}^{n} [|p-j| \leqslant 5] \frac{\exp\left(\langle q_j, k_p\rangle / \sqrt{d}\right)}{\sum_{s=1}^{n} \exp\left(\langle q_j, k_s\rangle / \sqrt{d}\right)} v_p.$$

Будет ли она хорошо работать? Какие проблемы в ней можно ожидать?

Задача 4 (2.5 балла). Ответьте на вопросы по решающим деревьям и композициям:

1. Допустим, мы решили использовать следующую функцию хаотичности (impurity) при построении решающего дерева:

$$H(R) = \max_{(x_i, y_i) \in R} y_i.$$

Чем она плоха? Какие разбиения будут предпочитаться при обучении дерева?

2. Представьте, что мы решили обучать градиентный бустинг так:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (b_N(x_i) - s_i)^2 \to \min_{b_N}; \quad s_i = \sum_{n=1}^{N-1} \left.\frac{\partial L(y_i, z)}{\partial z}\right|_{z=b_n(x_i)}$$

Чем плох такой подход? Попробуйте подумать, как будут меняться s_i по мере роста N. Исправьте приведённые выше формулы, чтобы получилась стандартная процедура градиентного бустинга.

3. Известно, что градиентный бустинг является в некотором смысле аналогом градиентного спуска: каждая базовая модель приближает антиградиент ошибки на обучающей выборке. А как модифицировать бустинг, чтобы он стал аналогом mini-batch градиентного спуска? Запишите формулы для сдвигов и для обучения базовой модели в этом случае. Поясните, почему это правда будет аналог.

Задача 5 (2.5 балла). Напомним, что разложение ошибки на шум, смещение и разброс выглядит так:

$$L(\mu) = \underbrace{\mathbb{E}_{x,y}\Big[\big(y - \mathbb{E}[y \,|\, x]\big)^2\Big]}_{\text{шум}} +$$

$$+ \underbrace{\mathbb{E}_x\Big[\big(\mathbb{E}_X\big[\mu(X)\big] - \mathbb{E}[y \,|\, x]\big)^2\Big]}_{\text{смещение}} + \underbrace{\mathbb{E}_x\Big[\mathbb{E}_X\Big[\big(\mu(X) - \mathbb{E}_X\big[\mu(X)\big]\big)^2\Big]\Big]}_{\text{разброс}}.$$

Допустим, мы решаем задачу классификации, где наши данные описываются единственным целочисленным признаком x, для которого нам известно распределение:

$$\mathbb{P}(x = k) = \frac{1}{Z} \begin{cases} \frac{1}{k^2}, & k > 0 \\ \frac{1}{(1-k)^2}, & k \leq 0 \end{cases},$$

где $Z > 0$ – это нормировочная константа, необходимая для того, чтобы все вероятности складывались в единицу.

Предположим также, что целевая переменная имеет периодическую зависимость от признака и задаётся по следующей формуле: $y_i = (x_i + \xi_i) \,\%\, 2$, где $\xi_i \in \mathrm{Ber}(0.1)$ (распределение Бернулли с вероятностью успеха 0.1), а через «$z \,\%\, 2$» обозначается взятие остатка от деления на 2.

Рассмотрим метод обучения вида $\mu(X)(x) = [\cos(\pi x) < 0]$. Найдите шум, смещение и разброс описанного метода.