Семинар 5

Достаточные статистики и экспоненциальное семейство

Теоретическая справка

Определение 1 (Обобщённая плотность)**.** *Пусть X — случайная величина.*

1. *Если X абсолютно непрерывна с плотностью $f_\theta(x)$, то* обобщённая плотность *совпадает с обычной плотностью.*

2. *Если X дискретна со значениями $(x_k)_{k\in\mathbb{N}}$, то её* обобщённой плотностью *называется*

$$f_\theta(x) = \begin{cases} \mathbb{P}_\theta(X = x_k), & x = x_k; \\ 0, & \text{иначе.} \end{cases}$$

Единое обозначение f_θ позволяет формулировать результаты одновременно для дискретных и непрерывных распределений.

Определение 2 (Функция правдоподобия)**.** *Пусть $\mathbf{X} = (X_1, \ldots, X_n)$ — выборка из распределения с обобщённой плотностью $f_\theta(x)$.* Функцией правдоподобия *называется*

$$L(\theta) = \prod_{i=1}^{n} f_\theta(X_i),$$

рассматриваемая как функция от θ при фиксированной выборке.

Определение 3 (Достаточная статистика)**.** *Статистика $T = T(\mathbf{X})$ называется* достаточной *для параметра $\theta \in \Theta$, если для любого борелевского множества B и любого t условная вероятность*

$$\mathbb{P}_\theta\big(\mathbf{X} \in B \mid T(\mathbf{X}) = t\big)$$

не зависит от θ. Другими словами, вся информация о параметре θ содержится в $T(\mathbf{X})$.

Теорема 1 (Критерий факторизации)**.** *Пусть дана выборка $\mathbf{X} = (X_1, \ldots, X_n)$ из параметрического семейства $\{f_\theta(x) : \theta \in \Theta\}$. Статистика $T(\mathbf{X})$ достаточна для θ тогда и только тогда, когда функция правдоподобия представима в виде*

$$L(\theta) = g\big(T(\mathbf{X}), \theta\big) \cdot h(\mathbf{X}),$$

где g зависит от выборки только через $T(\mathbf{X})$, а h не зависит от θ.

Определение 4 (Минимальная достаточная статистика)**.** *Достаточная статистика $T(\mathbf{X})$ называется* минимальной*, если для любой достаточной статистики $S(\mathbf{X})$ существует измеримая функция φ такая, что $T(\mathbf{X}) = \varphi(S(\mathbf{X}))$.*

Замечание 1. *Минимальная достаточная статистика единственна с точностью до взаимно однозначного преобразования.*

Теорема 2 (Критерий минимальности)**.** *Достаточная статистика $T(\mathbf{X})$ является минимальной для θ тогда и только тогда, когда для любых двух выборок $\mathbf{x} = (x_1, \ldots, x_n)$ и $\mathbf{y} = (y_1, \ldots, y_n)$ выполняется*

$$\frac{f_\theta(\mathbf{x})}{f_\theta(\mathbf{y})} \text{ не зависит от } \theta \quad \Longleftrightarrow \quad T(\mathbf{x}) = T(\mathbf{y}).$$

Определение 5 (d-параметрическое экспоненциальное семейство)**.** *Пусть* $\theta \in \Theta \subseteq \mathbb{R}^d$. *Распределение* $\mathbb{P}_\theta$ *принадлежит* экспоненциальному семейству*, если его обобщённая плотность представима в виде*

$$f_\theta(x) = \exp\left\{ \sum_{k=1}^{d} \eta_k(\theta) T_k(x) - A(\theta) + H(x) \right\},$$

где $\eta_1, \ldots, \eta_d$, $T_1, \ldots, T_d$, H *— некоторые функции, а* $A(\theta)$ *— нормировочная константа.* Важно: *носитель* $\{x : f_\theta(x) > 0\}$ *не должен зависеть от* θ.

Лемма 1. *Если* $X_1, \ldots, X_n$ *— выборка из экспоненциального семейства, то распределение вектора* $\mathbf{X}$ *также принадлежит экспоненциальному семейству, причём*

$$f_\theta(\mathbf{x}) = \exp\left\{ \sum_{k=1}^{d} \eta_k(\theta) \sum_{i=1}^{n} T_k(x_i) - nA(\theta) + \sum_{i=1}^{n} H(x_i) \right\}.$$

По критерию факторизации вектор-статистика $T(\mathbf{X}) = \left(\sum_{i=1}^n T_1(X_i), \ldots, \sum_{i=1}^n T_d(X_i) \right)$ *является достаточной для* θ.

Замечание 2. *Размерность достаточной статистики в экспоненциальном семействе совпадает с размерностью параметра.*

Замечание 3. *Если носитель распределения зависит от параметра (например,* $\mathrm{U}([0, \theta])$ *или распределение со сдвигом), то такое распределение* не принадлежит *экспоненциальному семейству.*

Задачи

1 Относятся ли следующие семейства распределений к экспоненциальным?

а) $\mathrm{Bin}(n, \theta)$, $\theta \in (0, 1)$, с обобщённой плотностью

$$f_\theta(x) = C_n^x \theta^x (1 - \theta)^{n-x}, \quad x \in \{0, 1, \ldots, n\};$$

б) $\mathrm{Pois}(\theta)$, $\theta > 0$, с обобщённой плотностью

$$f_\theta(x) = \frac{\theta^x e^{-\theta}}{x!}, \quad x \in \mathbb{Z}_+;$$

в) $\mathrm{Exp}(\theta)$, $\theta > 0$.

2 Пусть $X_1, \ldots, X_n$ — выборка из экспоненциального распределения $\mathrm{Exp}(\theta)$ с параметром $\theta > 0$. Найдите минимальную достаточную для θ статистику.

3 Пусть $X_1, \ldots, X_n$ — выборка из нормального распределения $\mathcal{N}(\mu, \sigma^2)$. Найдите достаточную для двумерного параметра $\theta = (\mu, \sigma^2)$ статистику через

а) критерий факторизации;

б) экспоненциальное семейство.

4 Пусть $X_1, \ldots, X_n$ — выборка из равномерного распределения $\mathrm{U}([0, \theta])$. Принадлежит ли распределение экспоненциальному семейству? Найдите достаточную для параметра $\theta > 0$ статистику, пользуясь критерием факторизации.

5 Пусть $X_1, \ldots, X_n$ — выборка из равномерного распределения $\mathrm{U}([\theta, \theta+1])$. Принадлежит ли распределение экспоненциальному семейству? Найдите достаточную для параметра θ статистику, пользуясь критерием факторизации.

6 Пусть $X_1, \ldots, X_n$ — выборка из гамма-распределения $\mathrm{Gamma}(\alpha, \beta)$ с параметрами $\alpha, \beta > 0$ и плотностью

$$f(x) = \frac{\beta^\alpha x^{\alpha-1}}{\Gamma(\alpha)} e^{-\beta x} \mathbf{1}\{x \geqslant 0\}.$$

Найдите достаточную для параметра $\theta = (\alpha, \beta)$ статистику через

а) экспоненциальное семейство;

б) критерий факторизации.

7 Пусть $X_1, \ldots, X_n$ — выборка из бета-распределения $\mathrm{Beta}(\alpha, \beta)$ с параметрами $\alpha, \beta > 0$ и плотностью

$$f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1}(1-x)^{\beta-1}, \quad x \in [0, 1].$$

Найдите достаточную для параметра $\theta = (\alpha, \beta)$ статистику через

а) экспоненциальное семейство;

б) критерий факторизации.