Vision-Language-Action Models

Весенний семестр 2026

Яндекс Образование × ФКН

01

Что такое VLA?

Три кита

01

Vision

Визуальное восприятие сцены: объекты, их положение, окружение и текущее состояние робота.

02

Language

Понимание инструкции человека: цель задачи, нужные объекты и ограничения выполнения.

03

Action

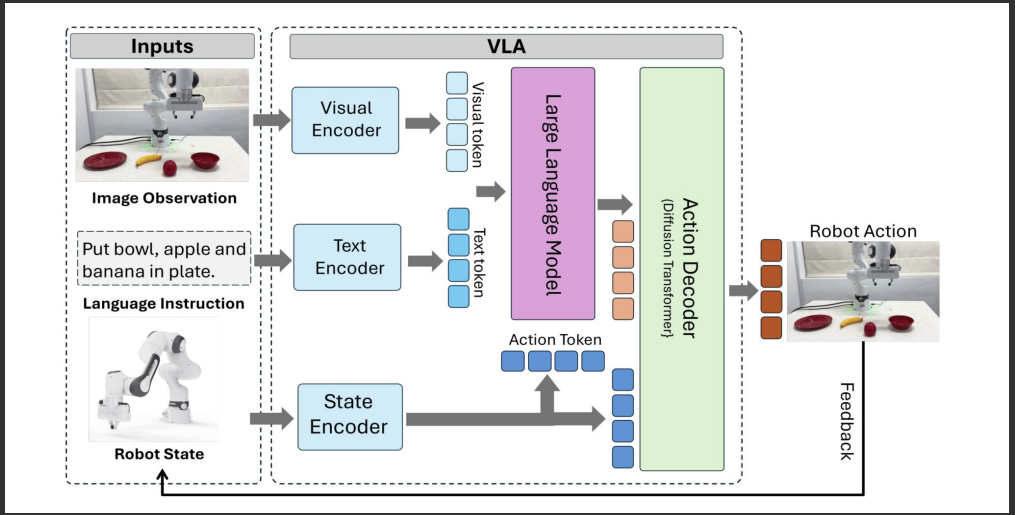
Преобразование восприятия и команды в последовательность действий робота: движения, траекторию и управление.

02

Архитектура

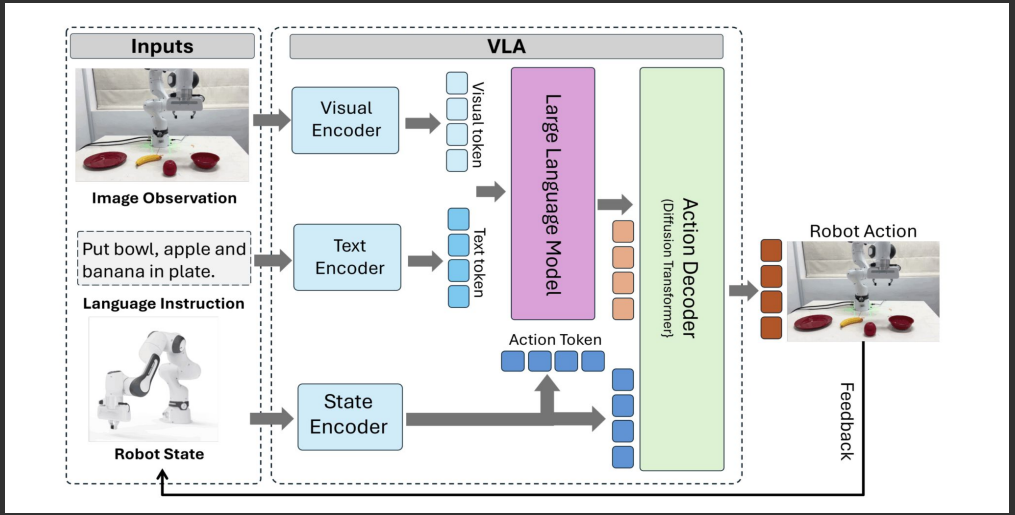
Visual Encoder

Visual Encoder преобразует изображение в набор патч-токенов. Обычно используется ViT или CLIP-подобная структура, выдающая стабильные визуальные эмбеддинги. Эти токены далее трактуются так же, как текстовые токены внутри модели

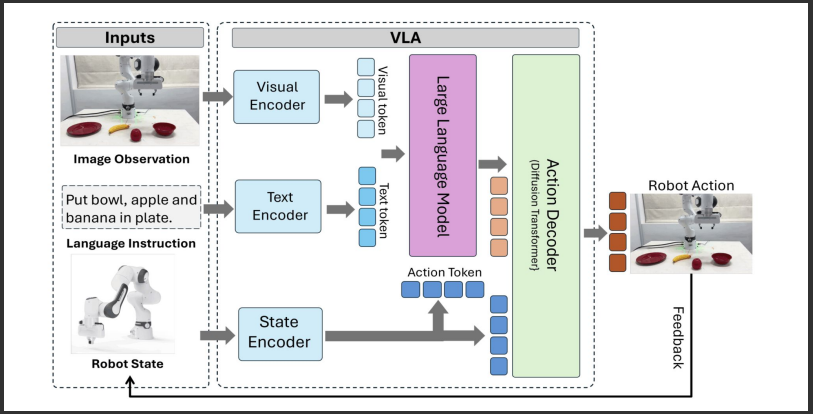


State Encoder

- State Encoder преобразует внутреннее состояние робота в эмбеддинги, которые можно передать в LLM. Используются **компактные MLP** или небольшие **трансформеры**
- Входные данные включают **joint-углы, скорости, силы, моменты, состояние захвата и динамические параметры платформы**. При необходимости добавляется короткая история действий для временного контекста.



Language & reasoning core



- **LLM объединяет визуальные токены, текст и состояние робота через единый attention.** Все модальности участвуют в общих вычислениях, что позволяет модели формировать сцено-ориентированное представление. Это избавляет от необходимости в отдельном планировщике или символическом представлении сцены.
- **LLM фактически выступает семантическим центром модели.** Она интерпретирует задачу, уточняет контекст и подготавливает скрытое состояние для генерации действий. Это ключевое отличие от CLIP и SayCan, где reasoning вынесен наружу.

Action Decoder

- **Action Decoder преобразует скрытое состояние VLA-модели в управляющее действие робота.** Он принимает выход LLM (объединяющий зрение, текст и состояние) и переводит его в формат, пригодный для исполнения.
- **Действие может быть представлено как дискретная последовательность токенов или как непрерывный вектор управления.** Выбор представления определяет точность, плавность движения и требования к контроллеру.

Action Decoder: Token-based Action Decoder

Что это: действие кодируется токенами (последовательностью дискретных символов), которые декодируются LLM-головой.

Где используется: RT-2, OpenVLA.

Особенность современных моделей:
непрерывные действия робота сначала **дискретизируются** в конечный словарь action-токенов

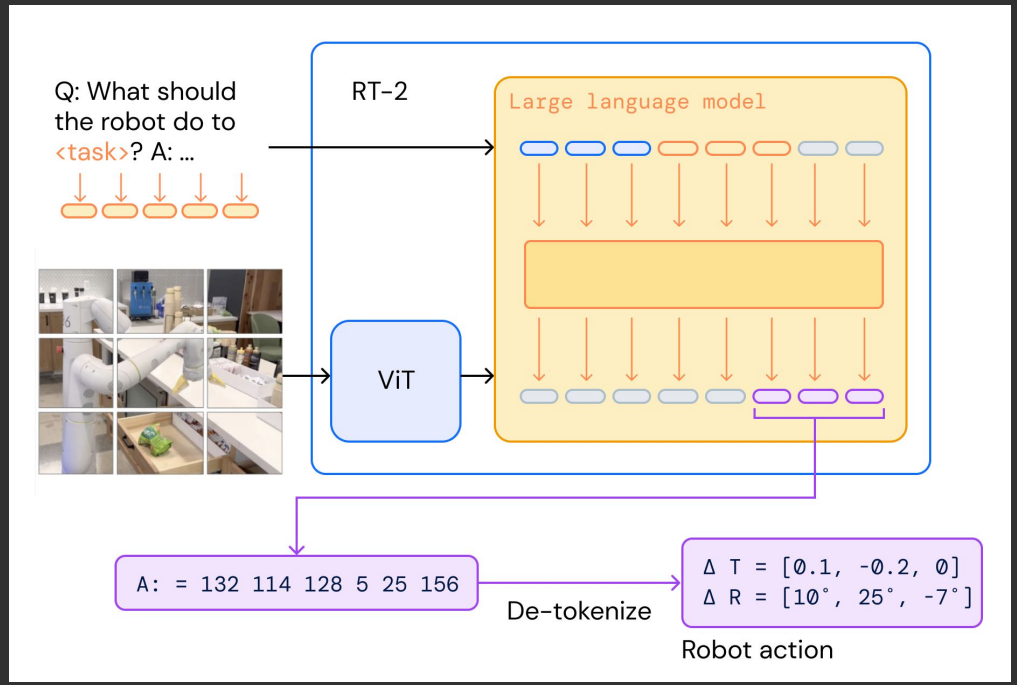
(XYZ-дельты, углы, состояние захвата и т.д.).

Это позволяет использовать тот же autoregressive decoder, что и для текста, и объединять язык, зрение и действия в одной токенной модели.

Плюсы: легко встроить в LLM-архитектуру, можно генерировать действия тем же autoregressive механизмом, что и текст, удобно объединять язык, зрение и действия в одной модели.

Минусы: ограниченная точность, ступенчатость и необходимость carefully спроектированного словаря токенов.

Action Decoder: Token-based Action Decoder



Action Decoder: Diffusion-based Action Decoder

Что это: действие генерируется итеративно через denoise-процесс, как в DDPM или DDIM, но применённый к траекториям робота.

Где используется: GROOT, Diffusion Policy, RDT-серии.

Особенность GROOT:
GROOT использует диффузионную голову для генерации *мини-траектории*, а не одного шага действия.
Это резко улучшает стабильность и точность сложных манипуляций (многоступенчатые движения, нестабильные grasp-ы, трудные позы).

Диффузия обеспечивает:

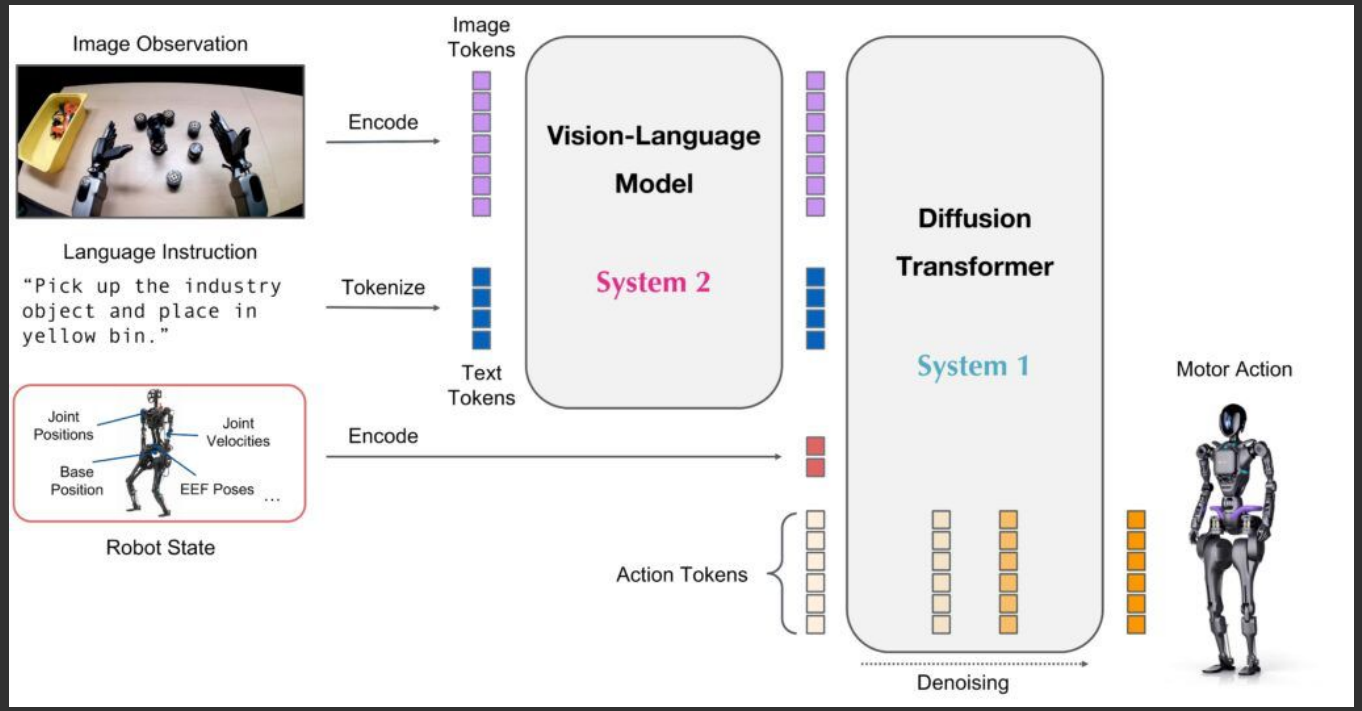
- устойчивость к шумным демонстрациям

- высокую точность

- способность моделировать сложные распределения действий.

Главный минус - высокая задержка (до 10-30 итераций денойза).

Action Decoder: Diffusion-based Action Decoder



03

Данные

Данные

Основная структура:
картинка(и) + инструкция → действие
Изображение даёт текущий контекст сцены, инструкция задаёт цель, действие — эталонный управляющий шаг.

Наблюдение обычно - один **RGB кадр**; реже используется **RGB-D** или короткий видеоконтекст.

Действие представляется либо **токенами** (RT-2, Pi·0), либо **непрерывным вектором** (TinyVLA), либо **мини-траекторией** (GROOT). Тип представления зависит от архитектуры декодера.

Современные модели обучаются на **сотнях тысяч - миллионах эпизодов**, объединяющих **реальные демонстрации**, **симуляцию** и **web-изображения**.
Большой и разнообразный датасет критичен для генерализации.

04

Обучение

Обучение

Основной метод обучения - supervised Behavioral Cloning (BC).
Модель учится воспроизводить эталонные действия по паре *изображение + инструкция*. Для действий в токенах оптимизируется кросс-энтропия, для непрерывных - MSE/Huber.

Используются дополнительные регуляризации для устойчивости.
Делают языковые парафразы инструкций, визуальные аугментации, сглаживание траекторий и alignment-лоссы между модальностями

LoRA применяется для эффективного дообучения больших моделей.
LoRA обучают только узкие адаптеры, не трогая основные веса LLM/ViT, что позволяет дообучать VLA на своих роботических данных без катастрофического забывания.

05

А что на практике?



LeRobot

1. **LeRobot — это open-source фреймворк для обучения и файнтюнинга VLA-моделей.**
   Он задаёт единый формат данных, даталодеры, преобразования действий и стандартные API для обучения.
2. **Обеспечивает готовые пайплайны для BC, VLA, RT-стиля моделей и LoRA-файнтюнинга.**
   Это позволяет дообучать большие модели на собственных демонстрациях без переписывания инфраструктуры.
3. **Поддерживает гетерогенные датасеты (BridgeData, BC-Z, JAXRobo, RT-подобные наборы).**
   Все эпизоды приводятся к единому виду: изображение, состояние, инструкция, действие.

06

Что вам доступно?

01

SO-101: follower и leader + две камеры

02

Дообученная на нашей постановке задачи модель smolVLA (обучающая выборка состоит из данных, собранных в симуляторе MuJoCo)

03

Докер-образ для удобной настройки необходимого для работы с SO-101 окружением.

04

скрипты для калибровки + скрипты для записи датасета

05

GPU для обучения

06

Советы менторов

07

Hints

Что можно попробовать?

01 Собрать датасет на реальных данных и хорошо их почистить

02 Попробовать другую модель (должна запускаться на видеокарте 5090!!)

03 Собрать разнообразные сцены в симуляторе и подумать про sim2real

Удачи!